

Estudo de um Método para Detecção de Múons no Experimento ATLAS Baseado em Rede Neural Convolutacional

Thiago C. A. Paschoalin* Andrei de O. Almeida* Maico da S. Lima*
Luciano M. de A. Filho**

* Centro Federal de Educação Tecnológica de Minas Gerais
(CEFET-MG), Unidade Leopoldina, MG, (e-mails:
thiago.paschoalin@cefetmg.br; andrei.almeida@cefetmg.br;
maicolima.leopoldina@cefetmg.br).

** Universidade Federal de Juiz de Fora (UFJF), Juiz de Fora, MG
(e-mail: luciano.andrade@engenharia.ufjf.br)

Abstract: The development of new digital signal processing techniques is crucial in high-energy physics experiments. In this context, the ATLAS experiment upgrade for Phase-II of the high-luminosity LHC, particle detection system of the biggest hadrons collider of the world, will allow experiments with higher event rates, leading to the signal pile-up effect. The ATLAS hadronic calorimeter (TileCal) can be used to help the detection of muon particles resulted from proton-proton collisions. Classical techniques for signal reconstruction in this new phase suffer from decreased performance, requiring new strategies that has better results in this new environment, and the least square(LS) method has already been explored as an alternative. In this paper, a Convolutional Neural Network (CN) is proposed for simulated muon detection system using selected cells from TileCal, and its performance is compared with detection using LS. The CN was able to reduce the false alarm rate with 98% of detection probability at the two cells studied compared to LS, reaching reductions up to 84% in a specific module.

Resumo: O desenvolvimento de novas técnicas de processamento digital de sinais é muito importante nos experimentos de física de altas energias. Neste cenário, a atualização do experimento ATLAS para Fase-II do LHC de alta luminosidade, sistema de detecção de partículas do maior colisionador de hádrons do mundo, fará com que seja possível experimentos com maior taxa de eventos, ocasionando o efeito de empilhamento de sinais. O calorímetro hadrônico do ATLAS (TileCal) pode ser utilizado para auxiliar na detecção de partículas de múon resultantes das colisões de prótons-prótons. As técnicas clássicas para reconstrução dos sinais nesta nova fase têm sua performance prejudicada, necessitando de novas estratégias que trabalhem melhor neste novo ambiente, e o método dos mínimos quadrados (*Least Square* ou LS) já foi estudado com uma alternativa. Neste trabalho, uma rede neural convolutacional (CN) é proposta para o sistema de detecção de múons simulados usando algumas células do TileCal e compara-se com o desempenho utilizando o LS. A CN foi capaz de reduzir a taxa de falso alarme para uma probabilidade de detecção de 98% nas duas células estudadas quando comparado com o LS, chegando a reduções de até 84% em um módulo específico.

Keywords: Neural Network; Muon; Detection; Calorimetry.

Palavras-chaves: Rede Neural; Múon; Detecção; Calorimetria.

1. INTRODUÇÃO

Em geral, circuitos para processamento de sinais elétricos vêm sendo implementados predominantemente em sistemas digitais. Técnicas avançadas de filtros digitais são desenvolvidas e as redes neurais se expandem em larga escala com novas formas sofisticadas de Inteligência Artificial. Atualmente já existem novos *hardwares* desenvolvidos capazes de se trabalhar com as redes neurais artificiais, que demandam um grande poder de processamento (Boybat et al., 2022). Desta forma, sistemas de processamento de dados em tempo real, também conhecidos como *streaming* ou *free-running* (Akida et al., 2018), aliados com técnicas

computacionais, tornam-se viáveis do ponto de vista de *hardware* e custo, incluindo experimentos modernos de física de altas energias (Chiedde and on behalf of the ATLAS liquid argon calorimeter group, 2022), (Albertsson et al., 2018).

O experimento ATLAS (*A Toroidal LHC ApparatuS* - Dispositivo Instrumental Toroidal para o LHC) é um sistema de detecção de partículas presente no acelerador *Large Hadron Collider* ou Grande Colisionador de Hádrons (LHC). O LHC é atualmente o principal acelerador de partículas do mundo, tanto em dimensão quanto em energia e está localizado no complexo do CERN (*Conseil*

Européen pour la Recherche Nucléaire - Organização Europeia para a Investigação Nuclear) (Solans Sanchez, 2013). O processo de colisões de partículas permite o estudo de diversos fenômenos físicos importantes nas teorias de modelo padrão, bem como a compreensão da expansão do universo. Um marco relevante aconteceu em 2012 quando uma partícula com propriedades consistentes com o bóson de Higgs foi observada pela primeira vez (The ATLAS Collaboration, 2012), (The ATLAS Collaboration, 2022), o que levou ao prêmio Nobel de física no ano seguinte. O LHC possui ao todo quatro experimentos ao longo de seu comprimento e o ATLAS é um que foi projetado para analisar partículas resultantes de colisões próton-próton ocorridas no centro do dispositivo. Este trabalho será focado neste último experimento, em especial no sistema de calorímetro hadrônico conhecido como TileCal, o qual passará por uma atualização em um futuro próximo. Ao ocorrer uma colisão, as partículas geradas interagem com as estruturas do sistema, absorvendo a energia das mesmas e possibilitando sua quantificação, passo importante para determinação das propriedades essenciais das partículas.

O múon é uma partícula prevista pelo modelo padrão de física de altas energias. Essa é uma partícula elementar e instável que normalmente decai em um elétron, um anti-neutrino e um neutrino. (Amsler et al., 2008)

O TileCal inicialmente não foi projetado para a identificação de múons, apesar de estar em planos futuros a sua utilização para auxiliar a identificação deste tipo de partícula (bib, 1992). Essa era uma tarefa realizada exclusivamente pelo espectrômetro de múons, também presente no experimento ATLAS. Posteriormente, foi desenvolvido um módulo eletrônico externo chamado de TMDB (*Tile Muon Digitizer Board*) que digitaliza e processa células estratégicas do TileCal, tornando possível a fusão dos dados provenientes do TileCal e com espectrômetro de múons (Ferraz, 2018).

O ATLAS passará por uma atualização significativa, seguindo os planos de atualização do experimento para o LHC de alta luminosidade (HL-LHC), que está compreendida entre duas fases: Fase-I e Fase-II. O HL-LHC trabalhará com altas luminosidades e, consequentemente, uma grande quantidade de colisões simultâneas, o que se torna necessária uma atualização para que o sistema seja capaz de operar nessas condições. A Fase-II compreenderá melhorias na arquitetura eletrônica de leitura, já que até 200 interações simultâneas próton-próton em cada colisão podem ocorrer (Hristova and the ATLAS Collaboration, 2018). Adicionalmente, a TMDB não fará mais parte do processo de detecção de múon no TileCal, forçando o desenvolvimento de novas estratégias.

O efeito de empilhamento de sinal (*pile-up*) se torna mais significativo com o aumento da luminosidade, alterando performances de técnicas já estabelecidas. O empilhamento de sinal adiciona distorções significativas ao pulso, prejudicando a capacidade dos filtros de estimação de energia.

Atualmente, o processo de detecção de múon através do TileCal utiliza o método do Filtro Casado ou *Matched Filter*. Esse algoritmo visa maximizar a SNR (Relação Sinal Ruído) para ruído Gaussiano, com o auxílio do pulso de referência. Para condições de alta luminosidade e maior

empilhamento de sinal, o ruído vai se distanciando de uma distribuição gaussiana e distorcendo o pulso de referência, que são as bases para o cálculo desse tipo de método (Dias et al., 2021).

Um método discutido em (Gonçalves et al., 2023) apresenta uma abordagem usando os mínimos quadrados ou *Least Square* (LS), onde apresenta uma proposta de um método linear e simples do ponto de vista computacional. O método proposto apresentou melhores resultados quando comparado com o método original, além de se mostrar flexível para situações de empilhamento de sinal e ser de fácil implementação. Esta abordagem será utilizada como base de comparação com o método que será proposto neste trabalho.

Neste cenário, o método de rede neural convolucional é explorado como estratégia para detecção de múon na estrutura do TileCal. As redes neurais artificiais, antes vistas com certa desconfiança por parte da comunidade acadêmica, já está mais difundida e vem apresentando resultados interessantes em diversos problemas de outras naturezas. Ao utilizar a rede neural convolucional, treinada com dados corretos de exemplos, busca-se uma melhora na identificação deste tipo de partícula de interesse imerso em situações com empilhamento de sinais, reduzindo a taxa de falsos positivos, podendo ser uma possível estratégia para a atualização da Fase-II do LHC.

Na seção seguinte, é apresentado o ambiente de trabalho utilizado para o estudo feito neste artigo. Na Seção 3, o problema de empilhamento de sinais é discutido com maior profundidade. A Seção 4 descreve o métodos proposto para detecção de múon no TileCal. Os resultados de desempenho e análises importantes estão presentes na Seção 5. Por fim, a Seção 6 aborda discussões finais sobre o que foi discutido e futuros trabalhos.

2. INFRAESTRUTURA ATUAL E ATUALIZAÇÃO ESPERADA DO TILECAL

A fim de estudar colisões do tipo próton-próton de variados valores de energia no LHC, foi projetado o experimento ATLAS. As colisões acontecem quando feixes de até 10^{11} são acelerados e se chocam a uma taxa de 40 milhões de vezes por segundo. Essa interação de feixe de prótons gera uma energia de centro de massa de 14 TeV, com uma luminosidade teórica de $10^{34} \text{ cm}^{-2} \text{ s}^{-1}$ (The ATLAS Collaboration, 2008) - medida que quantifica a relação de número de eventos ocorridos em um segundo e a área da seção deste feixe. O TileCal é um calorímetro hadrônico, o que significa que tem a capacidade de medir a energia de hádrons quando os mesmos interagem com os núcleos atômicos. Após a colisão no centro de massa, as partículas geradas em forma de cascata percorrem as estruturas do TileCal, onde o aço diminui a sua energia e emitem luz durante a interação com as telhas cintilantes. Diversas fibras óticas que estão ligadas a estas telhas cintilantes transportam o sinal luminoso emitido, onde o conjunto delas formam o sinal de uma célula. O fotomultiplicador (PMT) tem a função de transformar a luz proveniente das fibras óticas em um pulso elétrico proporcional à intensidade da luz. Esse processo descrito é ilustrado pela Fig. 1.




Figura 1. Processo de coleta dos sinais absorvidos para o TileCal

O sinal elétrico gerado possui um pulso analógico padrão e é formado pelo circuito de condicionamento (*shapper*), gerando sinal elétrico com uma forma determinada com seu valor de amplitude proporcional à energia detectada nas telhas cintilantes. O Conversor Analógico-Digital (ADC) que opera com uma frequência de amostragem de 40 MHz, discretiza o pulso em amostras com janelas de 150 ns, totalizando 7 amostras digitais (Anderson et al., 2005). É importante a padronização deste pulso para muitas técnicas de estimação de energia.

O espectrômetro de múons presente no ATLAS foi desenvolvido inicialmente como o único capaz de identificar este tipo de partículas. De acordo com estudos de (bib, 1992) o TileCal pode ser utilizado para auxiliar na identificação de múons gerados nas colisões. Em 2018, a chamada TMDB (*Tile Muon Digitizer Board*) entrou em operação com objetivo de digitalizar e processar as células D do barril estendido do Tilecal (D5 e D6), permitindo uma dupla checagem de informações de múon do TileCal com o espectrômetro de múons (Ferraz, 2018). Esse novo módulo foi desenvolvido utilizando FPGA (*Filed Programmable Gate Array*), que permite um processamento em tempo real dos dados gerados pelas células. Ao todo, o sistema é formado por 16 TMDBs.

O ATLAS está programado para receber uma grande atualização, como descrita no resumo de Hristova and the ATLAS Collaboration (2018), seguindo os planos do LHC de alta luminosidade (HL-LHC). A atualização é dividida entre a Fase-I e a Fase-II, juntamente com a programação do LHC. Entre 2019-2022, O LHC iniciou a Fase-I desta gradativa atualização, enquanto a Fase-II, antes programada para 2023-2025, foi postergada para 2026. Essa segunda fase, englobará o comissionamento da configuração final da máquina HL-LHC.

A frequência de colisão dos feixes de prótons é de 40 MHz, o que leva um intervalo de 25 ns entre cada colisão. Para a Fase-II, o processo da eletrônica de leitura será atualizado e o detector será menos complexo e a sua eletrônica reduzida, devido ao dados serem transmitidos para fora do detector. A luz gerada pelas telhas cintilantes serão transportadas através de *links* e receptores de qualidade elevada

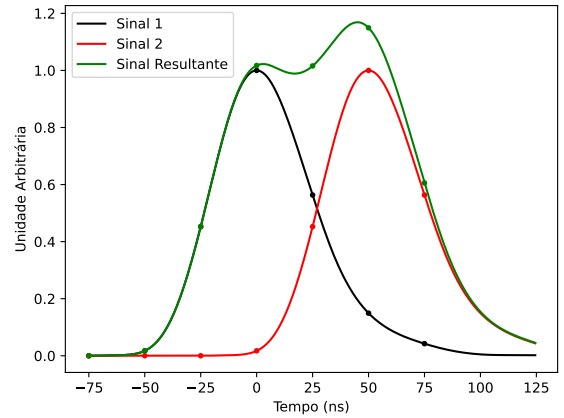


Figura 2. Efeito de empilhamento de sinal. O sinal em preto é um sinal de interesse, mas logo em seguida, um novo sinal (vermelho) de uma colisão adjacente é observada na mesma janela. O sinal resultante em verde é um sinal distorcido.

e com velocidade de transmissão maiores, permitido que a eletrônica de leitura seja realocada para o exterior do detector sem o prejuízo de perda de informações. Essa mudança tem como objetivo transformar o processamento em *free-running* ou modo ininterrupto (Hristova and the ATLAS Collaboration, 2018) com os algoritmos online de estimação de energia dando resultado para cada evento. Nesta atualização, a eletrônica de leitura do TileCal será substituída permitindo o tráfego de apenas de informação digital até o sistema de filtragem global (*Global Trigger*) do ATLAS (Gomez Delegido, 2023).

O LHC foi projetado inicialmente para valores menores de luminosidade e atualmente o valor de número de colisões por cruzamento de feixe (μ) alcançados é de aproximadamente 75 (Hristova and the ATLAS Collaboration, 2018). Para o LHC de alta luminosidade, a máquina é projetada para atingir luminosidades entre 5 e $7 \times 10^{34} \text{cm}^{-2} \text{s}^{-1}$ (Aad et al., 2021). Assim, o μ é projetado para atingir o valor de 200 no último modo operacional do HL-LHC, um aumento significativo aos operados atualmente. A ocupação maior do detector, pode trazer dificuldades de operação no detector, pois as flutuações causadas pelo empilhamento de sinal em alta luminosidade pode interferir negativamente na energia estimada (The ATLAS Collaboration, 2008).

3. O EFEITO DE EMPILHAMENTO DE SINAL

O pulso padrão do TileCal é mais extenso que o espaçamento do feixe do LHC. Desta forma, canais de leitura com mais ocupação observam colisões seguidas em uma mesma janela de amostragem. A amplitude do pulso e o momento em que o seu pico ocorre são informações importantes para medição da energia e tempo de voo das partículas, respectivamente. Mas o efeito de empilhamento de sinais degrada a estimação de tais parâmetros. O sinal é mais distorcido quando o empilhamento de sinais é maior, prejudicando a precisão na tarefa de estimação (Damazio, 2013) e (Gonçalves, 2022). A Figura 2 demonstra um exemplo de empilhamento de sinais.

O LHC na Fase-II de atualização terá a eletrônica de leitura dos canais TileCal sendo alterada para suportar eventos de alta luminosidade, com projeto de capacidade de até 200 interações simultâneas próton-próton (Chiedde and on behalf of the ATLAS liquid argon calorimeter group, 2022). O diâmetro do feixe de prótons será maior, mais colisões serão geradas, o que aumenta a estatística na probabilidade de detecção de eventos físicos desejados. Mas, apesar desta vantagem, existe maiores chances de ocorrer eventos importantes dentro de um mesmo canal de leitura do sistema de calorimetria do ATLAS, tornando o efeito de empilhamento de sinais mais evidente. (Gonçalves, 2022)

Essas novas condições adversas fazem com que os filtros digitais amplamente utilizados na eletrônica atual de leitura se tornem menos eficientes à medida que a forma do pulso do sinal se torna distorcida.

4. ESTRATÉGIAS PARA DETECÇÃO DE MÚONS USANDO O TILECAL

Seguindo a ideia da TMDB atualmente em funcionamento, as células D do barril estendido serão usadas para detectar partículas de múons geradas nas colisões. Dois métodos serão comparados a fim verificar a performance de cada um. O primeiro é o Método dos Mínimos Quadrados ou *Least Square*, discutido em Gonçalves et al. (2023). Foi mostrado que esse método apresenta melhores resultados em eventos de alta luminosidade, quando comparados com filtros clássicos já implementados no TileCal. O segundo método é o método proposto por esse artigo, que se baseia em uma rede neural convolucional capaz de identificar o momento onde ocorre um sinal de múon.

4.1 Considerações preliminares

Considere uma sequência de sinais digitais \mathbf{r} . Observando cada uma das amostras da sequência, é possível verificar duas hipóteses possíveis (Sotto-Maior Peralva, 2015):

- Hipótese H_0 : Somente ruído, $r[k] = n[k]$
- Hipótese H_1 : Sinal mais ruído, $r[k] = s[k] + n[k]$

Onde k é a amostra de observação do momento, \mathbf{s} é o sinal de interesse e \mathbf{n} é o ruído presente na amostra. No caso de física de altas energias, mais especificamente em detecção de múons, o sinal de interesse \mathbf{s} pode ser substituído pelo produto $A\mathbf{g}$, no qual o A é a amplitude ou energia da partícula e \mathbf{g} é o pulso de referência para um sinal de múon.

A detecção de múon se baseará na capacidade da técnica em identificar situações onde a hipótese H_1 ocorre como eventos reais de múon enquanto na hipóteses H_0 deve ser ignorada como um sinal de interesse. Neste trabalho, apenas a detecção de eventos é importante, enquanto a estimação correta da energia do múon não é o alvo. Serão abordados o método de mínimos quadrados e o método da rede neural convolucional

4.2 Método de mínimos quadrados

O estimador de mínimos quadrados $\hat{\theta}$ tem como objetivo minimizar o desvio entre o valor real da energia da partícula e o valor estimado. Foi colocado anteriormente que

a estimação da energia não é o foco deste trabalho, mas este método se baseia na mensuração da energia associada aquela amostra. Através do valor encontrado, é possível definir um valor limite de energia onde a amostra analisada é considerada um sinal de múon ou apenas o ruído está presente.

O estimador $\hat{\theta}$ deve ser encontrado minimizando a soma do quadrado dos erros $\mathbf{e} = \mathbf{x} - \mathbf{a}$, onde \mathbf{x} é o valor de energia dado pelo estimador e \mathbf{a} é o valor real da amplitude ou energia do sinal. Para encontrar os valores do estimador $\hat{\theta}$ é necessário definir uma janela de observação p . Ao fim do processo de minimização dos erros, haverá um vetor com p elementos que serão os pesos de um filtro FIR, ou seja, o método se torna um método linear de estimação.

Esta técnica, também chamada de *Least Square* (LS), está descrito em Gonçalves et al. (2023), onde se faz a comparação entre o esse método e o método clássico de Filtro Ótimo (OF) em cenários de alta luminosidade, como acontecerá na Fase-II da atualização do LHC.

4.3 Rede Neural Convolucional

Uma rede neural supervisionada necessita de dados corretos para que a mesma execute a tarefa proposta da melhor forma possível, pois o sua aprendizagem é baseada em exemplos (Haykin, 2009). A proposta deste trabalho é utilizar uma rede neural convolucional para detectar múons e comparar com o método linear LS.

Em primeiro momento é necessário a definição de qual será a janela de observação de amostras. Em uma análise preliminar, constatou-se que uma janela de 11 amostras se mostrou suficiente na identificação de múons, mas outros tamanhos de janelas podem ser utilizadas.

Uma observação importante é que cada célula possui dois canais associados, o esquerdo e o direito. Para entrada da rede neural, as amostras da janela de observação serão concatenadas para então serem usadas como entrada na rede neural proposta. Desta forma, os dados de entrada totalizarão 22 amostras, duas vezes o tamanho da janela de observação.

As redes neurais são muito utilizadas em classificação e reconhecimento de imagens, com isso, o uso da rede neural convolucional com duas dimensões se torna mais interessante. Em casos de processamento de sinais em que as informações necessitam de apenas uma componente, a rede convolucional de uma dimensão é adequado pois necessita de um poder de processamento menor já que não envolve cálculos matriciais. (Kiranyaz et al., 2021)

Definiu-se uma rede neural com duas camadas de convolução, uma camada oculta e uma camada de saída. A primeira camada de convolução foi ajustada com 16 filtros, janela de convolução de 11 e função de ativação como Tangente Hiperbólica. A fim de realizar o primeiro *downsample*, a primeira operação de *MaxPooling* possui uma janela de tamanho dois. Já para segunda camada de convolução, escolheu-se 8 filtros com janela de convolução unitária, mantendo a mesma função de ativação. Em seguida, a operação de *MaxPooling* se manteve com as mesmas características da anterior.

Com a estrutura de convolução pronta, faz-se necessário o ajuste da camada oculta, que nesta proposição utilizou-se 10 neurônios, também com função de ativação como Tangente Hiperbólica. Por fim, a camada de saída ficou com 1 neurônio de saída que determina se o evento analisado é um evento com um sinal de múon ou apenas um evento contendo ruído. A função de ativação manteve-se como Tangente Hiperbólica. A tabela 1 resume a topologia camada de convolução e a tabela 2 sintetiza as camadas oculta e de saída escolhidas para essa rede neural.

Tabela 1. Configuração Camada Convolutio-
nal.

Camada	Filtros	Tamanho da Janela	F. Ativação
Conv1D (1 ^a)	16	11	TANH
MaxPolling (1 ^a)	-	2	-
Conv1D (2 ^a)	8	1	TANH
MaxPolling (2 ^a)	-	2	-

Tabela 2. Configuração da Camada Oculta e
Camada de saída.

Camada	Neurônios	Função de Ativação
Camada Oculta	10	TANH
Camada de Saída	1	TANH

4.4 Desenvolvimento da Rede Neural Convolucional e processamento das amostras

A detecção de múons para cada módulo do TileCal é realizada através do processamento pela rede neural convolucional das amostras decorrentes dos dois canais da célula D5 ou da célula D6. Para isso, a rede neural deve ser treinada corretamente com eventos onde ocorrem uma partícula de múon e eventos onde apenas ruído está presente. Desta forma, a saída da rede neural terá o valor desejado 1 para esse primeiro tipo de eventos descritos e o valor desejado de 0 para o segundo tipo de eventos.

Para o treinamento da rede neural, o otimizador utilizado foi o Adam, que é baseado em gradientes de funções objetivas estocásticas. A função de perda escolhida é a do Erro Médio Quadrático ou MSE (*Mean Square Error*), enquanto a métrica de acurácia foi selecionada.

A técnica de validação cruzada k-fold é utilizada para evitar possíveis *overfittings* e melhorar os resultados desejados. Com um número de k-fold de 10, o conjunto de dados a serem analisados é separado em conjunto de treinamento (90%) e conjunto de teste (10%). O resultado da média de acurácia é obtido após a validação cruzada terminar.

Com a rede neural terminando o processo de treinamento, as amostras dos dois canais da célula são processadas por este modelo proposto e o resultado do neurônio de saída será um valor entre 0 e 1. A determinação se o evento analisado é um evento de múon ou não, dependerá do valor limite compreendido entre o intervalo de saída da rede e será diferente para cada módulo afim de obter a menor taxa de falso alarme em uma determinada probabilidade de detecção fixada.

5. RESULTADOS

Nesta seção serão apresentados os resultados de detecção de sinais de múon utilizando o TileCal.

5.1 Dados Utilizados

Como os dados da Fase II ainda não estão disponíveis, a utilização de simulações faz-se necessária para aproximar ao máximo do cenário em que os eventos estarão imersos. Para a simulação do ruído nas células utilizou o software *Tile Pulse Simulator* presente no *Framework Athena*, desenvolvido pelo CERN. Nele é possível gerar dados de simulação *Minimum Bias* com o calorímetro em ambientes de alta luminosidade ($\mu = 200$) onde o problema do empilhamento de sinais estão mais presentes.

A característica de depósito de energia das partículas de múon nas células são conhecidas através da análise de dados de colisões do tipo próton-próton do ano de 2022. Com a distribuição de energia de cada célula é possível sortear valores de amplitude seguindo sua característica estatística. A fim de popular os sinais com eventos de múon, foram determinados a posições onde teriam partículas de múon utilizando uma distribuição uniforme, que no total foram aproximadamente 9,1% em relação ao número total de amostras.

Um pulso padrão com a amplitude sorteada e centralizado na posição determinada é adicionado nas amostras de ruído, para cada um dos eventos de múons selecionados. Dessa forma, os métodos deverão identificar corretamente essas posições onde ocorreram passagem deste tipo de partícula.

5.2 Resultados de Detecção

De modo a avaliar o método proposto, foi utilizado a curva ROC (*Receiver Operating Characteristic*). Nela, é possível observar graficamente a relação entre a probabilidade de detecção do sinal (PD) e a taxa de falso alarme (FA) de um método de detecção onde existe apenas a possibilidade de ser ou não um evento de interesse. A PD pode ser encontrada através da porcentagem de eventos identificados corretamente dentro do universo total de sinais recebidos, enquanto a taxa de FA representa a razão do número de eventos identificados incorretamente e o número total de sinais. Através da curva ROC também é possível extrair o parâmetro de área sob a curva (AUC) que é um indicador que auxilia na análise. Valores mais altos de AUC representam melhores desempenhos do método de detecção.

O principal fator para comparação dos métodos será na análise da taxa de FA para uma PD fixa de aproximadamente 98%, que é o valor determinado no projeto TileMuon já utilizado na TMDB nos dias atuais. Quanto menor a taxa de FA para esse valor de PD, melhor é a detecção do sinal de interesse. Os gráficos de performance estão ampliados entre a PD de 98% para uma melhor visualização e melhor comparação dos métodos.

Como utilizou-se a técnica de correlação cruzada para o método proposto de rede neural convolucional, a curva ROC correspondente a esse métodos contempla uma região sombreada que representa a melhor e pior performance dentre os números de k-fold, bem como uma linha intermediária que representa a média de todas as possibilidades analisadas.

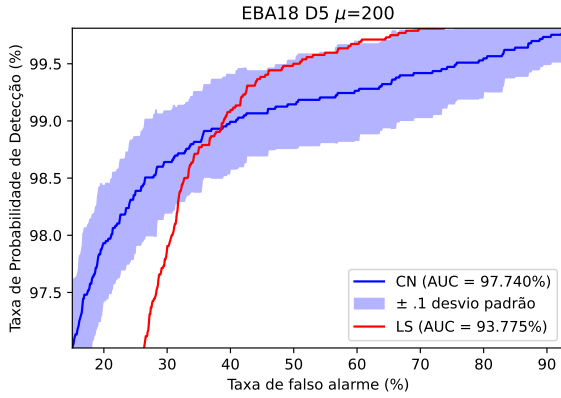


Figura 3. Curva ROC para célula D5, lado A, módulo 18

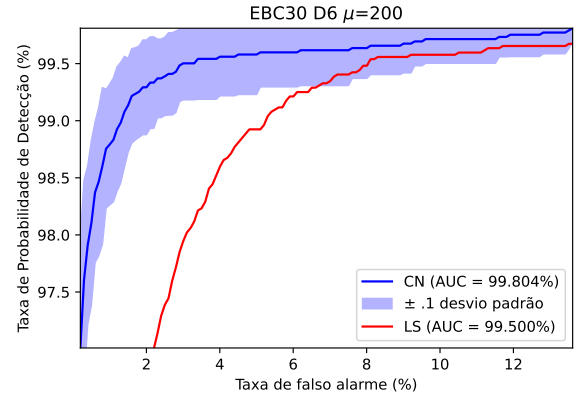


Figura 5. Curva ROC para célula D6, lado C, módulo 30

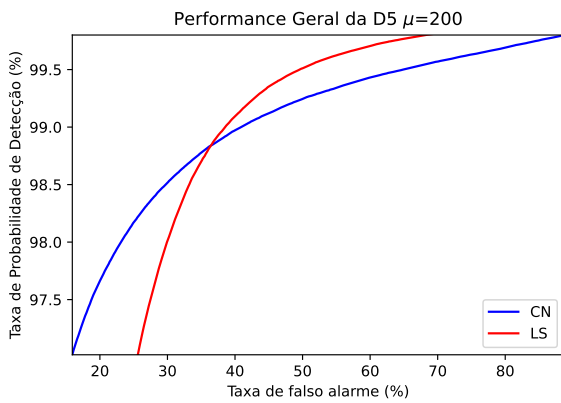


Figura 4. Curva ROC Global para célula D5

A figura 3 está representando o resultado para célula D5, do lado A e módulo 18 do TileCal. É possível observar que até uma PD um pouco maior que 98,5%, a taxa média de FA da rede neural apresenta menor valor. Na tabela 3 essa diferença fica mais evidente para uma PD de 98%, onde o valor de FA da rede convolucional reduz em aproximadamente 31% em relação ao método de mínimos quadrados. A AUC do método proposto também é menor do que o método linear.

Tabela 3. Resultados para Célula D5, lado A, módulo 18

Método	AUC	FA(%) para PD 98%
CN	97,74	21,22
LS	93,78	30,73

Ao analisar a curva ROC global da célula D5 da figura 4 e sua tabela 4, é possível observar que o resultado de performance dos métodos se mantém próximos ao do EBA18. Para o resultado global, levou-se em conta todos os módulos dos dois lados do barril estendido, totalizando 128 módulos. A taxa de FA da CN continua menor para uma mesma PD e a sua AUC também é maior em relação ao LS.

Tabela 4. Resultados Globais Célula D5

Método	AUC	FA(%) para PD 98%
CN	97,77	23,12
LS	93,89	30,03




Figura 6. Curva ROC Global para célula D6

Passando para análise da célula D6, na figura 5 está representada a curva ROC do lado C, módulo 30. É possível observar na tabela 5 que a redução da taxa de FA para esse módulo da célula D6 chegou a aproximadamente 84% quando compara-se o modelo CN com o LS. A AUC também indica uma melhor detecção para o modelo proposto.

Tabela 5. Resultados para célula D6, lado C, módulo 30

Método	AUC	FA(%) para PD 98%
CN	99,80	0,50
LS	99,50	3,10

Os resultados globais da curva ROC da célula D6, presentes na figura 6 e na tabela 6, demonstram a mesma tendência que o resultado do módulo específico analisado anteriormente.

Tabela 6. Resultados Globais Célula D6

Método	AUC	FA(%) para PD 98%
CN	99,72	0,40
LS	99,47	3,00

Quando compara-se os resultados das células D5 e D6 percebe-se que para ambos, a detecção apresentou melhores resultados para a CN em relação ao LS. Percentualmente, a célula D6 apresentou maiores reduções na taxa de FA mas observando o valor absoluto, essa taxa já apresenta valores reduzidos para o LS. Na célula D5, a taxa de FA

é bem mais elevada do que a da D6, e sua redução causa mais impacto na performance do sistema de detecção. Um dos motivos para grande diferença de valores de taxa de FA para as duas células é devido ao fato da célula D5 apresentar maior quantidade de eventos de múons de baixa energia.

6. CONCLUSÃO

Em um ambiente de alta luminosidade que o ATLAS passará a operar, a detecção de múon assistido pelo TileCal terá um desafio a mais devido ao efeito de empilhamento de sinais. Desta forma, este trabalho conseguiu demonstrar uma técnica utilizando rede neural convolucional que melhora a detecção dos múons utilizando as células D5 e D6. Foi possível observar que o método proposto para detecção se mostrou superior ao método dos mínimos quadrados, um dos fortes candidatos para a estimação de energia na Fase-II do LHC de alta luminosidade. A rede neural foi capaz de reduzir a taxa de falso alarme para uma probabilidade de detecção de 98%, o que pode trazer uma melhoria no processo.

Um estudo futuro importante é a análise do custo computacional desta duas técnicas, comparando-as. O LS é simples do ponto de vista de *hardware* pois sua implementação é de um filtro FIR, enquanto a CN é mais custoso devido a quantidade de cálculos complexos envolvidos.

REFERÊNCIAS

- (1992). ATLAS: letter of intent for a general-purpose pp experiment at the large hadron collider at CERN. URL <https://cds.cern.ch/record/291061>.
- Aad, G. et al. (2021). Artificial neural networks on fpgas for real-time energy reconstruction of the atlas calorimeters. *Computing and Software for Big Science*, 5(1), 19.
- Akidau, T., Chernyak, S., and Lax, R. (2018). *Streaming Systems: The What, Where, When, and How of Large-Scale Data Processing*. O'Reilly Media.
- Albertsson, K. et al. (2018). Machine learning in high energy physics community white paper. *Journal of Physics: Conference Series*, 1085(2), 022008. doi:10.1088/1742-6596/1085/2/022008. URL <https://dx.doi.org/10.1088/1742-6596/1085/2/022008>.
- Amsler, C. et al. (2008). Physics letters. B667, 1. URL <https://pdg.lbl.gov/2009/download/rpp-2008-plB667.pdf>.
- Anderson, K. et al. (2005). Design of the front-end analog electronics for the atlas tile calorimeter. *Nuclear Instruments and Methods in Physics Research Section A: Accelerators, Spectrometers, Detectors and Associated Equipment*, 551(2-3), 469–476.
- Boybat, I. et al. (2022). Editorial: Hardware for artificial intelligence. *Frontiers in Neuroscience*, 16. doi:10.3389/fnins.2022.979495. URL <https://www.frontiersin.org/journals/neuroscience/articles/10.3389/fnins.2022.979495>.
- Chiedde, N. and on behalf of the ATLAS liquid argon calorimeter group (2022). Machine learning for real-time processing of atlas liquid argon calorimeter signals with fpgas. *Journal of Instrumentation*, 17(04), C04010. doi:10.1088/1748-0221/17/04/C04010. URL <https://dx.doi.org/10.1088/1748-0221/17/04/C04010>.
- Damazio, D.O. (2013). Signal processing for the atlas liquid argon calorimeter: Studies and implementation. In *2013 IEEE Nuclear Science Symposium and Medical Imaging Conference (2013 NSS/MIC)*, 1–4. IEEE.
- Dias, C.C. et al. (2021). Estimação de energia assistida por redes neurais para o calorímetro de telhas do atlas no lhc. In C.J.A. Bastos Filho, H.V. Siqueira, D.D. Ferreira, D.W. Bertol, and R.C.L. Oliveira (eds.), *Anais do 15o Congresso Brasileiro de Inteligência Computacional*, 1–8. SBIC, Joinville, SC.
- Ferraz, V.A. (2018). *Detecção Online Eficiente de Eventos Raros Utilizando Detectores Finamente Segmentados*. Ph.D. thesis, Universidade Federal do Rio de Janeiro.
- Gomez Delegido, A.J. (2023). Upgrade of atlas hadronic tile calorimeter for the high luminosity lhc. *Nuclear Instruments and Methods in Physics Research Section A: Accelerators, Spectrometers, Detectors and Associated Equipment*, 1047, 167860. URL <https://www.sciencedirect.com/science/article/pii/S0168900222011524>.
- Gonçalves, G.I. (2022). Energy reconstruction techniques in tilecal under high pile-up conditions. In *Communications in Computer and Information Science*, 140–151.
- Gonçalves, G.I. et al. (2023). Modelos lineares assistidos por redes neurais para estimação online da energia do calorímetro de telhas do atlas. In E. Simas, D.D. Ferreira, and L.R. Oliveira (eds.), *Anais do XVI Congresso Brasileiro de Inteligência Computacional (CBIC'2023)*, 1–8. SBIC, Salvador, BA. doi:10.21528/CBIC2023-179.
- Haykin, S. (2009). *Neural Networks and Learning Machines*. Number v. 10 in Neural networks and learning machines. Prentice Hall. URL https://books.google.com.br/books?id=K7P361KzI_QC.
- Hristova, I. and the ATLAS Collaboration (2018). Future plans of the atlas collaboration for the hl-lhc. *Few-Body Systems*, 59(6), 137. doi:10.1007/s00601-018-1459-7. URL <https://doi.org/10.1007/s00601-018-1459-7>.
- Kiranyaz, S. et al. (2021). 1d convolutional neural networks and applications: A survey. *Mechanical Systems and Signal Processing*, 151, 107398. doi: <https://doi.org/10.1016/j.ymssp.2020.107398>. URL <https://www.sciencedirect.com/science/article/pii/S0888327020307846>.
- Solans Sanchez, C. (2013). Status of the atlas calorimeters: their performances after two years of lhc operation and plans for future upgrades. In *Proceedings of 36th International Conference on High Energy Physics, PoS(ICHEP2012)*, 496. Sissa Medialab, Trieste, Italy.
- Sotto-Maior Peralva, B. (2015). *Reconstrução de Energia para Calorímetros Finamente Segmentados*. Ph.D. thesis, Universidade Federal de Juiz de Fora.
- The ATLAS Collaboration (2008). The ATLAS experiment at the CERN large hadron collider. *Journal of Instrumentation*, 3(08), S08003.
- The ATLAS Collaboration (2012). Observation of a new particle in the search for the standard model higgs boson with the atlas detector at the lhc. *Physics Letters B*, 716(1), 1–29.
- The ATLAS Collaboration (2022). A detailed map of higgs boson interactions by the atlas experiment ten years after the discovery. *Nature*, 607(7917), 52–59.