

# Estimação de Energia para Calorimetria em Cenários de Alta Luminosidade

Mariana S. Oliveira, Augusto S. Cerqueira, Luciano M. Andrade Filho e Bernardo S. M. Peralva

**Resumo**— Este artigo avalia técnicas de estimação de energia para canais de calorímetros em cenários de empilhamento de sinais, focando em três métodos: Filtro de Wiener, rede MLP e rede CNN. Utilizou-se simulações Monte Carlo para gerar os dados e os métodos foram aplicados em cenários com diferentes níveis de ocupação. Os resultados mostraram que o Filtro de Wiener é uma alternativa para estimação *online* e *offline* em condições de baixa ocupação, enquanto a MLP e a CNN oferecem melhores resultados em cenários com variações de ocupação e para estimação *offline*, devido à complexidade de implementação.

**Palavras-Chave**— Estimação, Calorimetria, Filtro de Wiener, Redes Neurais.

**Abstract**— This paper evaluates energy estimation techniques for calorimeter channels in stacking scenarios of signals, focusing on three methods: Wiener filter, MLP network, and CNN network. Monte Carlo simulations were used to generate the data and the methods were applied in scenarios with different levels of occupation. The results showed that the Wiener Filter is an alternative to online and offline estimation in conditions of low occupancy, while MLP and CNN offer better results in scenarios with occupancy variations and to offline estimation, due to the complexity of implementation.

**Keywords**— Estimation, Calorimetry, Wiener Filter, Neural Networks.

## I. INTRODUÇÃO

Nas últimas décadas, os sistemas de instrumentação eletrônica passaram por uma significativa transformação devido ao grande avanço no desenvolvimento de sensores, na microeletrônica, na eletrônica digital e na crescente utilização de técnicas avançadas de processamento digital de sinais e de inteligência computacional. Essas transformações impulsionaram o desenvolvimento de diversos setores, tais como o industrial, elétrico, saúde, agrícola, científico, meio ambiente, entre outros [1].

Por outro lado, novos desafios têm surgido na área, como o crescente volume de informações provenientes dos sensores em diversas áreas de aplicação. A física experimental de altas energias é um exemplo disso, introduzindo elementos complicadores adicionais, como a presença de altos índices de radiação e altas taxas de eventos [2]. Nesse contexto, o HL-LHC (do inglês, *High Luminosity Large Hadron Collider*), colisionador que poderá abrir novas fronteiras para a física experimental de altas energias, impõe grandes desafios para os

Mariana Oliveira, e-mail: mariana.oliveira2015@engenharia.ufjf.br, Augusto Cerqueira, e-mail: augusto.santiago@ufjf.br, Luciano Andrade Filho, e-mail: luciano.andrade@ufjf.br, Programa de Pós-graduação em Engenharia Elétrica, Universidade Federal de Juiz de Fora, Juiz de Fora-MG; Bernardo Peralva, e-mail: bernardo@iprj.uerj.br, Departamento de Modelagem Computacional, Universidade do Estado do Rio de Janeiro, Nova Friburgo-RJ.

seus experimentos, que têm as funções de absorver, detectar, medir e registrar os produtos das colisões [3].

Desde as primeiras colisões do LHC (do inglês, *Large Hadron Collider*) em 2010, o experimento ATLAS tem desempenhado um papel crucial na busca por novos conhecimentos sobre a física fundamental [4]. Ao longo dos anos, os requisitos de operação do LHC foram aprimorados a cada *Run* (período de operação), impulsionando um desenvolvimento contínuo dos experimentos. Esse programa de atualização visa preparar o ATLAS [5] e demais experimentos do LHC, para o HL-LHC, cuja operação está prevista para iniciar em 2029 e se estender até 2041.

O programa de atualização para o HL-LHC representa um passo importante para a física experimental de altas energias. Seu objetivo principal é preparar o colisionador e seus experimentos para o aumento gradativo da luminosidade do feixe de partículas, que, em termos simplificados, significa um crescimento do número de colisões a cada cruzamento de feixe (ou instante de colisão). Essa intensificação das interações, permitirá aos pesquisadores refinar seus estudos e ampliará as possibilidades de novas descobertas.

O aumento da luminosidade impacta fortemente os experimentos do LHC por dois fatores principais: bombardeio intensificado de partículas de alta energia nos componentes dos experimentos, elevando significativamente a exposição à radiação; e o aumento no número de eventos registrados pelos milhares de canais de leitura, o que gera o problema do empilhamento de sinais, onde múltiplos eventos se sobreponem no mesmo canal, dificultando a identificação e reconstrução precisa dos eventos físicos.

Este trabalho apresenta um estudo sobre técnicas de processamento digital de sinais e inteligência computacional para a estimação de energia dos canais da calorimetria do HL-LHC, visando mitigar o efeito do empilhamento de sinais. São avaliadas redes neurais multicamadas, redes neurais convolucionais e o Filtro de Wiener.

## II. ESTIMAÇÃO DE ENERGIA NOS CANAIS DOS CALORÍMETROS DO ATLAS

Os calorímetros têm a dupla função de absorver e amostrar a energia das partículas incidentes [6], provenientes das colisões, que no caso do LHC ocorrem a cada 25 ns. As informações dos calorímetros são então utilizadas para o desenvolvimento de complexos sistemas de filtragem online dos eventos, que descartam a grande maioria dos dados gerados como ruído de fundo, e também para reconstrução do evento físico de interesse que é armazenado pelo sistema de aquisição de dados.

As partículas provenientes das colisões interagem com os materiais dos calorímetros, que servem como absorvedor e amostrador da energia depositada. A energia amostrada das partículas é então convertida em sinal elétrico e transmitida ao circuito de *front-end* que tem como função amplificar e conformar o sinal para posterior conversão analógica-digital. Desta forma, a energia depositada em cada célula do calorímetro deve ser estimada a partir do sinal digital. Por isso, os circuitos de *front-end* buscam condicionar o sinal amostrado em forma de pulso, onde somente a amplitude varia em função da energia depositada.

A reconstrução completa dos eventos de interesse e a subsequente análise física é realizada de forma *offline*. É possível utilizar as estimativas *online* da energia depositada nos canais dos calorímetros, mas também é possível realizar uma nova estimativa *offline* a partir das amostras do sinal de cada canal dos calorímetros que também ficam disponíveis para análise.

Assim, o problema da estimativa de energia em canais de calorímetros se reduz a estimativa de amplitude de um pulso rápido, a partir das suas amostras digitais, em uma janela de tamanho fixo. Nesse cenário, o método descrito a seguir se apresenta como um bom candidato, tanto que foi utilizado na calorimetria do ATLAS em suas primeiras *Runs*.

#### A. Filtro Ótimo (OF)

O OF [7] modela a janela do sinal ( $\mathbf{x}$ ), no instante  $n$ , adquirido nos canais do calorímetro, como:

$$x[n] = Ag[n - \tau] + r[n] + ped, \quad (1)$$

onde  $A$  representa a amplitude,  $g[n]$  as amostras contendo o pulso de referência normalizado,  $r[n]$  é o ruído,  $\tau$  representa um possível desvio de fase e  $ped$  é a linha de base do pulso. A proposta é realizar a estimativa a partir de uma soma ponderada, dada por:

$$\hat{A}_{OF} = \sum_{n=0}^{N-1} x[n]w[n], \quad (2)$$

onde  $N$  representa o comprimento da janela e  $w[n]$  são os pesos.

O objetivo do método é achar o valor dos pesos que minimizem a variância do estimador, sujeito a algumas restrições. Resolvendo o problema de otimização utilizando multiplicadores de Lagrange, chega-se ao seguinte sistema de equações lineares através do qual é possível obter o valor ótimo dos pesos:

$$\begin{pmatrix} \mathbf{C} & -\mathbf{g}^T & -\dot{\mathbf{g}}^T & -\mathbf{1}^T \\ \mathbf{g} & 0 & 0 & 0 \\ \dot{\mathbf{g}} & 0 & 0 & 0 \\ \mathbf{1} & 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} \mathbf{w}^T \\ \lambda \\ \xi \\ \nu \end{pmatrix} = \begin{pmatrix} \mathbf{0}^T \\ 1 \\ 0 \\ 0 \end{pmatrix}, \quad (3)$$

onde  $\mathbf{C}$  é a matriz de covariância do ruído ( $N \times N$ ),  $\mathbf{g}$  é o vetor com as amostras do pulso de referência ( $N$ ),  $\mathbf{1}$  é um vetor de uns ( $N$ ),  $\mathbf{w}$  é o vetor com os pesos ( $N$ ),  $\lambda$ ,  $\xi$ ,  $\nu$  são os coeficientes de Lagrange,  $\mathbf{0}$  é um vetor de zeros de ( $N$ ).

#### B. Empilhamento de Sinais e o HL-LHC

Ao término da *Run 2* do LHC, a luminosidade já havia duplicado seu valor nominal, gerando já algum impacto no desempenho dos métodos de estimativa de energia dos canais dos calorímetros do ATLAS devido ao empilhamento de sinais. Atualmente o LHC está na *Run 3* e continua operando com o dobro da luminosidade nominal.

Com a previsão de início da operação do HL-LHC para 2029, o qual irá operar com uma luminosidade de cinco a sete vezes superior à nominal do LHC, torna-se ainda mais crucial desenvolver novos métodos de estimativa de energia para os canais de calorimetria do ATLAS, a fim de minimizar os efeitos do empilhamento de sinais.

Ao analisar o desenvolvimento do OF, é possível notar que a modelagem do sinal do calorímetro (Equação (1)) não contempla a possibilidade de empilhamento de sinais, que pode ser interpretado como ruído, afetando a matriz  $\mathbf{C}$  e, consequentemente, os pesos do filtro. Mesmo incorporando o efeito do empilhamento de sinais no ruído, o desempenho do OF se mostra comprometido conforme será visto mais adiante.

### III. MÉTODOS DE ESTIMAÇÃO PARA O CENÁRIO COM EMPILHAMENTO DE SINAIS

Nesta seção, serão apresentadas algumas técnicas que podem ser utilizadas para estimativa de energia de canais da calorimetria do ATLAS em cenários com empilhamento de sinais.

#### A. Filtro de Wiener

O Filtro de Wiener [8] é uma alternativa linear para estimativa de energia em cenários de alta luminosidade. Devido a sua simplicidade de implementação, ele pode ser utilizado tanto para estimativa *online* quanto *offline*.

A proposta é estimar os coeficientes  $w_{wie}[n]$  de um filtro digital de resposta ao impulso finita, onde a saída  $y[n]$  fornece a estimativa da amplitude desejada  $d[n]$  para uma janela de tamanho limitado do sinal de entrada  $x[n]$ . Desta forma, a saída do Filtro de Wiener pode ser escrita a partir da soma de convolução entre os coeficientes do filtro e o sinal de entrada, conforme pode ser visto a seguir:

$$y[n] = \sum_{k=0}^{N-1} w_{wie}[k]x[n-k], \quad (4)$$

onde  $N$  representa o comprimento do filtro.

Para obter os coeficientes ótimos do filtro, é preciso definir o vetor de erro  $e[n] = d[n] - y[n]$  e determinar como função custo a ser minimizada o erro médio quadrático ( $J(w_{wie})$ ), conforme:

$$J(w_{wie}) = E[e[n]^2]. \quad (5)$$

Substituindo (4) em (5), derivando e igualando a zero para chegar ao mínimo da função, chega-se ao seguinte resultado:

$$\sum_{i=0}^{N-1} w_{wie}[i]E[x[n-k]x[n-i]] = E[x[n-k]d[k]], \quad (6)$$

para  $k = 0, 1, \dots, N-1$ .

A Equação (6) pode ser reescrita matricialmente, conforme:

$$\mathbf{R}\mathbf{w}_{wie} = \mathbf{p}, \quad (7)$$

onde  $\mathbf{R}$  é a matriz de autocorrelação do sinal de entrada de tamanho  $N \times N$ ,  $\mathbf{w}_{wie}$  é o vetor coluna de pesos do Filtro de Wiener de comprimento  $N$  e  $\mathbf{p}$  é o vetor coluna de correlação cruzada entre o sinal de entrada e a saída desejada de comprimento  $N$ .

Então, os pesos do Wiener para estimação podem ser encontrados da seguinte forma:

$$\mathbf{w}_{wie} = \mathbf{R}^{-1}\mathbf{p} \quad (8)$$

É importante salientar que essa solução assume que o processo estocástico relativo ao sinal de entrada do filtro possui média zero, o que não é verdadeiro para o caso da estimativa de energia nos canais da calorimetria do ATLAS. Então, é preciso adicionar um coeficiente ao filtro, conectado a uma entrada de valor 1, para atuar como polarização do estimador, incluindo-o dentro do processo de estimação. Finalmente, a estimativa do Wiener  $\hat{A}_{wie}$  pode ser encontrada:

$$\hat{A}_{wie} = \sum_{i=0}^{N-1} w[i]x[i] + w[N]. \quad (9)$$

### B. Rede Neural Perceptron Multicamadas como Regressor

Considerando a maior complexidade do problema de estimação em cenários de empilhamento de sinais, técnicas mais complexas ganham espaço, principalmente para o cenário *offline*.

O problema de estimação de energia nos canais da calorimetria pode ser visto como um mapeamento do espaço de entrada  $x[n]$  de dimensão  $N$  (tamanho da janela) no espaço de saída  $y[n]$  de dimensão 1 que representa a estimativa da amplitude do sinal. Desta forma, uma rede perceptron multicamadas (MLP) pode ser utilizada para realizar esse mapeamento [9].

Neste trabalho, será considerada uma rede neural totalmente conectada com apenas uma camada oculta de neurônios e com um neurônio de saída com função de ativação linear.

### C. Rede Convolucional

Aprendizado profundo ganhou bastante espaço nas últimas duas décadas em diversas áreas de aplicação, melhorando resultados que anteriormente eram referência na área de inteligência computacional [10].

Portanto, será avaliada a utilização de uma rede convolucional (CNN) para realizar a estimação de energia dos canais da calorimetria do ATLAS. Por simplicidade de análise, consideraremos uma CNN com topologia fixa e um total de 46145 parâmetros a serem ajustados para uma janela de entrada com 7 amostras.

A complexidade computacional da rede CNN, mesmo durante sua operação, limita sua aplicação ao caso *offline*.

## IV. RESULTADOS

Nesta seção, faremos uma análise comparativa dos métodos propostos para estimar a energia nos canais da calorimetria do ATLAS no contexto do HL-LHC. Para facilitar a interpretação dos resultados, nossa análise será focada no calorímetro hadrônico central do ATLAS, conhecido como Tilecal [11].

Como o HL-LHC só entra em operação em 2029, para viabilizar a análise é necessário a utilização de dados provenientes de simulações computacionais. Desta forma, os dados utilizados neste trabalho advêm de simulação Monte Carlo, utilizando como sinal da nova eletrônica de *front-end* do Tilecal como referência.

### A. Conjunto de Dados

Inicialmente, é importante mencionar que os sinais da calorimetria do ATLAS são amostrados a uma taxa de 40 MHz e de forma sincronizada com BCs (do inglês, *Bunch Crossing*) do HL-LHC que ocorrerão a cada 25 ns.

A simulação utilizada pode ser dividida em duas etapas. Inicialmente, simula-se a deposição de energia no canal do calorímetro, em que cada *hit* de energia é associado a uma probabilidade de ocorrência, chamada de ocupação. A energia é distribuída de forma aleatória para cada *hit*, seguindo uma distribuição exponencial, conforme observado no Tilecal. O resultado é uma sequência com milhares de amostras  $d[n]$  que representam o valor da energia depositada em cada BC.

A segunda etapa da simulação realiza a convolução do pulso de referência do TileCal com a sequência de amostras gerada na etapa anterior e adiciona ruído branco gaussiano, com energia equivalente ao ruído do novo *front-end* do TileCal, resultando numa sequência de milhares de amostras  $x[n]$  contendo milhares de sinais de um canal do calorímetro. A Figura 1 apresenta 18 amostras da energia depositada  $d[n]$  em cada BC (vermelho) e o sinal resultante no canal do TileCal  $x[n]$  (azul), onde o eixo horizontal representa o número do BC (ou da amostra do sinal) e o eixo vertical a amplitude em contagens de ADC.

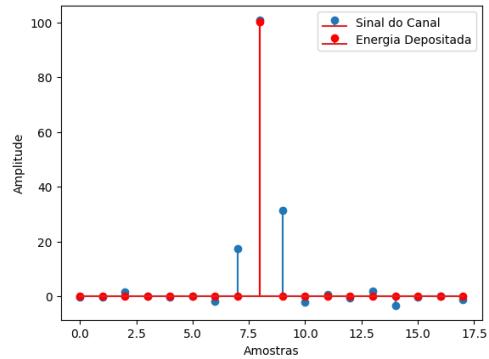


Fig. 1. 18 amostras resultantes da simulação ilustrando a deposição de energia em um BC (vermelho) e o sinal resultante do canal do TileCal (azul).

Assim, para a análise dos métodos de estimação, devemos janelar o sinal  $x[n]$  para formar a matriz de dados de entrada  $\mathbf{X}$  de dimensão  $M \times N$ , onde  $M$  é o número de eventos e  $N$  é o comprimento da janela utilizada para estimação. Para o

sinal janelado, o alvo corresponde a deposição de energia no BC central da janela, por isso o comprimento da janela deve ser ímpar.

Foram gerados bancos de dados com 150000 amostras (BCs), para os seguintes valores de ocupação: 10%, 30%, 35%, 40% e 80%. A energia foi sorteada seguindo uma distribuição exponencial com média de 30 contagens de ADC, de forma a garantir a ocorrência de eventos de baixa energia que se apresentam como desafios maiores para os métodos de estimação.

Para correta avaliação dos métodos de estimação abordados, os conjuntos de dados foram separados em treino e teste, sendo 30% dos eventos reservados para teste. Para determinação dos melhores parâmetros da rede neural MLP de uma camada oculta, foi utilizada validação cruzada com 10 dobradas.

A normalização dos dados de entrada foi realizada utilizando o conjunto de treinamento como referência. Cada amostra foi submetida à subtração da média e à divisão pelo desvio padrão. Os parâmetros obtidos no conjunto de treinamento foram então empregados para normalizar o conjunto de teste. Já a normalização dos dados de saída consistiu na divisão por um fator constante.

### B. Análise do Filtro Ótimo

Para o projeto e avaliação do OF para o cenário do HL-LHC, iniciaremos com um banco de dados com 40% de ocupação.

Como foi visto em (3), para obtenção dos pesos ótimos  $w$  do filtro OF, precisamos do pulso de referência  $g$  e da matriz de covariância do ruído  $C$  do sinal de entrada. O pulso de referência do Tilecal é conhecido, entretanto, a matriz de covariância do ruído precisa ser obtida a partir de um conjunto de dados. Portanto, a matriz  $C$  foi estimada a partir do conjunto de dados de treinamento e o desempenho do método foi avaliado no conjunto de teste.

A Figura 2 mostra o gráfico da dispersão entre a energia depositada no canal (valor verdadeiro) e a energia estimada pelo OF, para uma janela com 25 amostras, que melhora o desempenho do método em relação a janelas menores. A energia está representada em contagens de ADC. O comportamento do gráfico indica uma dispersão grande em quase toda a faixa dinâmica analisada, consequência dos sinais empilhados nas janelas analisadas. A tendência do OF em cenários com empilhamentos de sinais é de subestimar a energia depositada, conforme pode ser observado na figura. O desvio padrão do erro de estimação foi de 5,1 contagens de ADC.

### C. Análise do Filtro de Wiener

O projeto do filtro de Wiener requer um conjunto de dados de entrada  $X$  e da saída desejada  $d$ . Desta forma, também foram utilizados dois conjuntos de dados, um de treino, para obtenção dos coeficientes do filtro e outro, de teste, para avaliação do desempenho do método.

Para comparar o desempenho do filtro de Wiener com o OF, foi utilizado o mesmo banco de dados com 40% de ocupação. A Figura 3 mostra o gráfico da dispersão entre a energia depositada no canal e a energia estimada pelo Wiener, para uma janela com 7 amostras, suficiente para que o método

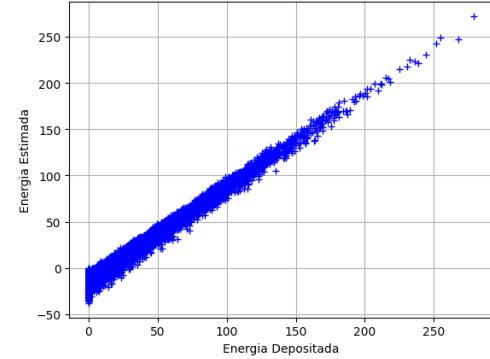


Fig. 2. Gráfico de dispersão entre a energia depositada no eixo horizontal e a energia estimada pelo OF, considerando uma janela com 25 amostras.

apresente desempenho superior ao OF. O desvio padrão do erro de estimação foi de 1,6 contagens de ADC.

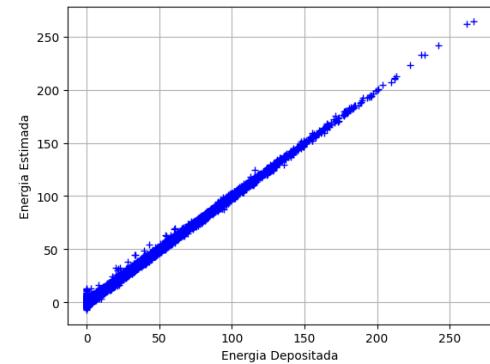


Fig. 3. Gráfico de dispersão entre a energia depositada no eixo horizontal e a energia estimada pelo Wiener, considerando uma janela com 7 amostras.

É importante observar que quando são combinados bancos de dados com diferentes níveis de ocupação, como 30%, 35% e 40%, o desvio padrão do erro do Wiener sobe para 2,1 contagens de ADC. Para um conjunto de dados com 10% e 40% de ocupação, o desvio padrão do erro de estimação sobe para 4,4 contagens de ADC.

### D. Análise da rede MLP

A análise da rede MLP com uma camada oculta mostrou que os melhores resultados foram alcançados com a função de ativação *relu* dos neurônios da camada oculta. Também foi observado que uma janela de entrada com 7 amostras era suficiente. Finalmente, os melhores resultados foram obtidos quando o número de neurônios da camada oculta chegava a algumas centenas ou milhares.

Para bancos de dados com diferentes níveis de ocupação, a rede MLP obteve resultados melhores do que os de Wiener. Por exemplo, para um banco com ocupações de 30%, 35% e 40% o desvio padrão do erro foi de 1,8 contagens de ADC (1000 neurônios na camada oculta). Para um banco com ocupações de 10% e 40%, o desvio padrão foi de apenas 1,7 contagens de ADC (5000 neurônios na camada oculta). A Figura 4 mostra o erro de estimação da rede MLP, sendo importante observar

que a escala de energia está normalizada (multiplicar por 80 para converter para contagens de ADC).

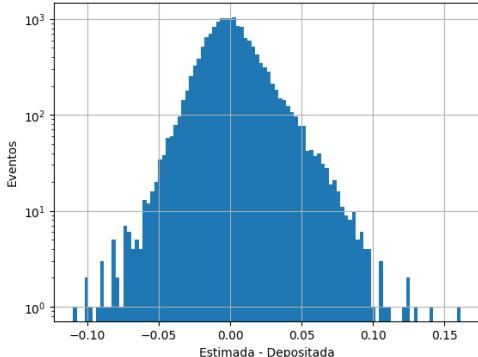


Fig. 4. Histograma do erro de estimação da rede MLP para o banco de dados com ocupação de 10% e 40%.

#### E. Análise da CNN

A CNN mostrou características semelhantes a rede MLP, mas o processo de treinamento é bem mais custoso computacionalmente e requer cuidados maiores do que a rede MLP. Para comparação, podemos usar o banco de dados com ocupação de 10% e 40%, onde o desvio padrão do erro de estimação da rede CNN foi de 1,7 contagens de ADC para uma janela de 7 amostras. A Figura 5 mostra o histograma do erro de estimação da rede CNN com a escala de energia normalizada (multiplicar por 80 para converter para contagens de ADC).

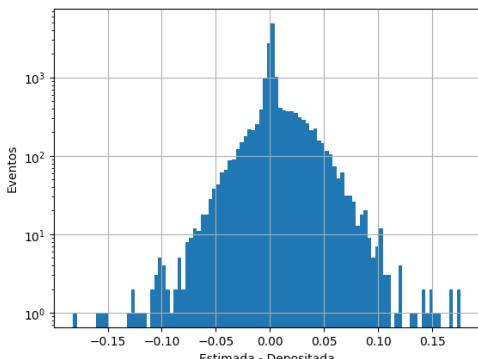


Fig. 5. Histograma do erro de estimação da rede CNN para o banco de dados com ocupação de 10% e 40%.

#### F. Comparação entre os métodos

A Tabela I resume os resultados obtidos pelo métodos avaliados através do desvio padrão do erro de estimação. Estão em negrito os melhores resultados para cada banco de dados analisado. Todos os métodos avaliados utilizaram uma janela de 7 amostras do sinal de entrada, exceto o OF que utilizou 25 amostras.

#### V. CONCLUSÕES

Os resultados obtidos indicaram que o método OF, ativamente utilizado no Tilecal, tem seu desempenho reduzido

TABELA I  
DESVIO PADRÃO DO ERRO DE ESTIMAÇÃO EM CONTAGENS DE ADC.

Ocupação	OF (25)	Wiener (7)	MLP (7)	CNN (7)
10%	2,9	<b>1,3</b>	1,4	1,6
40%	5,1	<b>1,6</b>	2,0	<b>1,6</b>
80%	5,6	<b>1,9</b>	2,2	2,2
10%-40%	6,2	4,4	<b>1,7</b>	<b>1,7</b>
30%-35%-40%	5,0	2,1	<b>1,8</b>	1,9

na presença de empilhamento de sinais, resultando numa subestimação da energia depositada nas células do calorímetro.

Em contrapartida, o Filtro de Wiener demonstrou os melhores resultados em cenários com pouca variação na ocupação das células do calorímetro, mesmo em situações de alta ocupação. Este é um resultado significativo, pois o Filtro de Wiener é uma técnica linear de baixa complexidade computacional, o que viabiliza sua aplicação tanto em *online* quanto em análises *offline*.

Analizando as técnicas de Inteligência Computacional (IC) utilizadas, a rede MLP e a CNN mostraram bons resultados e vantagens em relação ao Filtro de Wiener em cenários nos quais a ocupação pode variar dentro de uma faixa específica. No entanto, tanto a rede MLP quanto a CNN requerem o ajuste de milhares de parâmetros, o que limita sua aplicação a análises *offline*.

Por fim, é importante destacar que as três técnicas consideradas para o cenário do HL-LHC necessitam de treinamento supervisionado, o que implica que devem ser desenvolvidas com dados de simulação antes de serem empregadas no experimento, representando um desafio e uma restrição em termos de utilização.

#### AGRADECIMENTOS

Os autores agradecem ao CNPq, CAPES, FAPEMIG, FAPERJ e ao INCT CERN-Brasil pelo apoio.

#### REFERÊNCIAS

- [1] M. Carminati e G. Scandurra, "Advances in measurements and instrumentation leveraging embedded systems". *Review of Scientific Instruments*. v. 92, n. 12, pp. 121601, 2021.
- [2] K. Hanagaki, J. Tanaka, M. Tomoto, Y. Yamazaki, *Experimental Techniques in Modern High-Energy Physics: A Beginner's Guide*, Springer, 2023.
- [3] I. Alonso et al. *High-Luminosity Large Hadron Collider (HL-LHC): Technical design report*, 2023.
- [4] G. Aad et al, "A detailed map of Higgs boson interactions by the ATLAS experiment ten years after the discovery". *Nature*, v. 607, pp. 52-59, 2022
- [5] Z. Citron [ATLAS], "The ATLAS Upgrade Program," *Acta Phys. Polon. Supp.* v. 16, n.1, 1-A14, 2023
- [6] R. Wigmans, *Calorimetry: Energy Measurement in Particle Physics*. Oxford Science Publication, 2017
- [7] E. Fullana et al. "Digital signal reconstruction in the atlas hadronic tile calorimeter". *IEEE Transactions on Nuclear Science*, v. 53, n. 4, pp. 2139–2143, 2006.
- [8] G. Gonçalves. *Estimação de energia para calorímetros finamente segmentados operando em condições severas de empilhamento de sinais*, Dissertação de mestrado, UERJ, 2020.
- [9] S. Haykin, *Neural Networks and Learning Machines*. Pearson, 2008.
- [10] C. Bishop e H. Bishop, *Deep Learning: Foundations and Concepts*, Springer, 2024.
- [11] T. Davidek [ATLAS], "Performance and Calibration of the ATLAS Tile Calorimeter", *Instruments*, v. 6, n. 3, 2022.