



ESTIMAÇÃO DE ENERGIA PARA CALORIMETRIA EM FÍSICA DE ALTAS ENERGIAS BASEADA EM REPRESENTAÇÃO ESPARSA

Davis Pereira Barbosa

Tese de Doutorado apresentada ao Programa de Pós-graduação em Engenharia Elétrica, PPEE, da Universidade Federal de Juiz de Fora, como parte dos requisitos necessários à obtenção do título de Doutor em Engenharia Elétrica.

Orientadores: Augusto Santiago Cerqueira
Luciano Manhães de Andrade
Filho

Juiz de Fora
Março de 2017

ESTIMAÇÃO DE ENERGIA PARA CALORIMETRIA EM FÍSICA DE ALTAS
ENERGIAS BASEADA EM REPRESENTAÇÃO ESPARSA

Davis Pereira Barbosa

TESE SUBMETIDA AO CORPO DOCENTE DO PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA (PPEE) DA UNIVERSIDADE FEDERAL DE JUIZ DE FORA COMO PARTE DOS REQUISITOS NECESSÁRIOS PARA A OBTENÇÃO DO GRAU DE DOUTOR EM ENGENHARIA ELÉTRICA.

Examinada por:

Prof. Augusto Santiago Cerqueira, D.Sc.

Prof. Luciano Manhães de Andrade Filho, D.Sc.

Prof. Marco Aurelio Lisboa Leite, D.Sc.

Prof. Marcello Luiz Rodrigues de Campos, Ph.D.

Prof. Rafael Antunes Nobrega, D.Sc.

Prof. Moíses Vidal Ribeiro, D.Sc.

JUIZ DE FORA, MG – BRASIL
MARÇO DE 2017

Pereira Barbosa, Davis

ESTIMAÇÃO DE ENERGIA PARA CALORIMETRIA
EM FÍSICA DE ALTAS ENERGIAS BASEADA EM
REPRESENTAÇÃO ESPARSA/Davis Pereira Barbosa. –
Juiz de Fora: UFRJ/COPPE, 2017.

XVII, 86 p.: il.; 29, 7cm.

Orientadores: Augusto Santiago Cerqueira

Luciano Manhães de Andrade Filho

Tese (doutorado) – UFRJ/COPPE/Programa de
Engenharia Elétrica, 2017.

Referências Bibliográficas: p. 79 – 84.

1. Estimação de Energia.
 2. Filtragem Ótima.
 3. Física de Alta Energia.
 4. Empilhamento de Sinais.
 5. Representação Esparsa.
- I. Santiago Cerqueira, Augusto
et al. II. Universidade Federal de Juiz de Fora, COPPE,
Programa de Engenharia Elétrica. III. Título.

“O conhecimento nos faz responsáveis”. (Che Guevara)

Agradecimentos

Aos meus orientadores prof. Augusto Santiago Cerqueira e prof. Luciano Manhães de Andrade Filho pela formação de alto nível, dedicação e comprometimento com a educação. Apesar dos inúmeros compromissos pessoais e profissionais, sempre se mostraram disponíveis para discussões e ensinamentos. Além de excelentes orientadores e profissionais, são grandes amigos.

Aos meus pais e irmãs pelo incentivo e apoio em todas minhas escolhas. Além da educação e ensinamentos para que eu chegassem até este momento.

A minha querida esposa Natália, pelo amor, paciência e incentivo irrestritos, acompanhando minha trajetória para que alcançasse a essa realização.

Aos colegas e amigos do Laptel e do CERN, pelos momentos de descontração, companheirismo e troca de informações. Em especial aos amigos Bernardo Sotto-Maior e Denis Damazio e suas famílias, pelo compartilhamento de idéias e acolhimento fraternal.

À colaboração ATLAS no CERN, em especial ao TileCal e a saudosa Irene Vichou por usufluir de sua confiança e de seus conhecimentos.

À Coordenadoria de Aperfeiçoamento de Pessoal de Nível Superior (CAPES), pelo apoio financeiro dado a este trabalho.

Ao Povo Brasileiro que, diretamente ou indiretamente, financiou meus estudos que resultou no presente trabalho.

Resumo da Tese apresentada ao PPEE/UFJF como parte dos requisitos necessários para a obtenção do grau de Doutor em (D.Sc.)

ESTIMAÇÃO DE ENERGIA PARA CALORIMETRIA EM FÍSICA DE ALTAS ENERGIAS BASEADA EM REPRESENTAÇÃO ESPARSA

Davis Pereira Barbosa

Março/2017

Orientadores: Augusto Santiago Cerqueira
Luciano Manhães de Andrade Filho

Programa: Engenharia Elétrica

Esta tese propõe uma nova abordagem baseada em representação esparsa para o problema de estimativação de energia em calorimetria de altas energias em cenários com empilhamento de sinais. Inserida dentro do programa de atualização do experimento ATLAS, no LHC, ela teve como principal motivação o aumento progressivo da luminosidade no colisionador e suas consequências relativas ao problema da estimativação da energia nos canais do calorímetro eletromagnético do ATLAS, o LArg. Dois métodos de estimativação foram propostos e denominados de SPARSE e SPARSE-COF, ambos utilizando programação linear na busca pela esparsidade. Esses métodos tiveram os seus desempenhos avaliados em diversas simulações e foram comparados com o método clássico utilizado nos calorímetros do ATLAS, denominado OF, e com o DM-COF, método recentemente desenvolvido para o calorímetro hadrônico do ATLAS que trata o problema de empilhamento de sinais em sua formulação. Nas diversas simulações realizadas, os métodos SPARSE e SPARSE-COF apresentaram desempenho superior aos demais, principalmente quando a janela de observação utilizada para a estimativação da energia não contém todas as amostras do pulso típico do calorímetro, operando em cenários de empilhamento de sinais. Adicionalmente, através dados de simulações Monte Carlo do LArg, os métodos baseados em representação esparsa foram avaliados utilizando programação linear e também métodos esparsos de menor complexidade computacional, como o IRLS, o OMP e o LS-OMP. Os resultados mostraram que o método LS-OMP apresentou desempenho equivalente aos métodos SPARSE e SPARSE-COF, qualificando-o como candidato a ser utilizado para estimativação *on-line* de energia no LArg.

Palavras-chave: Detecção e Estimação de Sinais, Representação Esparsa, Empilhamento de Sinais, Física de Altas Energias.

Abstract of Thesis presented to PPEE/UFJF as a partial fulfillment of the requirements for the degree of Doctor of (D.Sc.)

ENERGY ESTIMATION FOR HIGH-ENERGY PHYSICS CALORIMETRY
BASED ON SPARSE REPRESENTATION

Davis Pereira Barbosa

March/2017

Advisors: Augusto Santiago Cerqueira
Luciano Manhães de Andrade Filho

Department: Electrical Engineering

This thesis proposes a new approach based on sparse representation for the energy estimation problem in high energy calorimetry operating in pile-up scenarios. This work was mainly motivated by the progressive increase of the LHC luminosity and its consequences on the energy estimation problem for channels of the electromagnetic calorimeter of ATLAS (LArg), in the context of the ATLAS experiment upgrade program at the LHC. Two estimation methods were proposed and named SPARSE and SPARSE-COF, both using linear programming in the search for sparsity. These methods were evaluated in several simulations and compared with the classical method used in ATLAS calorimeters, called OF, and with DM-COF, a recently developed method for the ATLAS hadronic calorimeter that addresses pile-up problem in its formulation. In the various simulations performed, SPARSE and SPARSE-COF methods performed better than others, especially when the observation window used for energy estimation does not contain all samples of the typical calorimeter pulse, operating in pile-up scenarios. In addition, through LArg Monte Carlo simulations, the methods based on sparse representation were evaluated using linear programming and also sparse methods with less computational complexity, such as IRLS, OMP and LS-OMP. The results showed that the LS-OMP method presented performance equivalent to the SPARSE and SPARSE-COF methods, qualifying it as a candidate to be used for online energy estimation in LArg.

Keywords: Signal Detection and Estimation, Matched Filter, Signal Pile-up, High Energy Physics.

Sumário

Lista de Figuras	x
Lista de Tabelas	xiii
1 Introdução	1
1.1 Objetivo	2
1.2 Contribuições	3
1.3 Organização do texto	3
2 O Ambiente de Física Experimental de Partículas	4
2.1 CERN e o LHC	4
2.2 O ATLAS	6
2.2.1 O Sistema de Seleção de Eventos Online e Aquisição de Dados do ATLAS	8
2.2.2 O Sistema de Calorimetria do ATLAS	10
2.3 Programa de Atualização do ATLAS	14
3 Estimação de Energia em Calorímetros para Física de Altas Ener- gias	16
3.1 O Problema da Estimação de Energia em Calorimetria	16
3.2 Estimação de Parâmetros	19
3.3 BLUE - <i>Best Linear Unbiased Estimator</i>	21
3.4 Estimador de Máxima Verossimilhança (MLE)	24
3.5 Estimação de Energia nos Calorímetros do ATLAS	25
3.5.1 Filtro Ótimo	26
3.6 Estimação de Energia em Outros Experimentos	28
3.7 Métodos de Estimação de Energia para Cenários de Empilhamento de Eventos	29
3.7.1 Método ManyAmps	29
3.7.2 COF - <i>Constrained Optimal Filter</i>	30

4 Estimação de Energia para Calorimetria Baseada em Representação Esparsa	33
4.1 Representação Esparsa para Estimação de Energia	33
4.1.1 Representação Esparsa sem Ruído	35
4.1.2 Representação Esparsa com Ruído	37
4.2 Propostas para Estimação de Energia para Calorimetria Baseado em Representação Esparsa (SPARSE e SPARSE-COF)	39
4.3 Outros Métodos Esparsos	39
4.3.1 Algorítimos de <i>Greedy</i> ou <i>Pursuit</i>	40
4.3.2 IRLS	41
4.4 Esparsidade e Unicidade	41
5 Avaliação da Estimação de Energia Baseada em Representação Esparsa	44
5.1 Simulação	44
5.2 Resultados e Análises	47
5.2.1 Considerações Sobre o Projeto dos Métodos SPARSE	47
5.2.2 Estimação da Amplitude do Sinal de Interesse	47
5.2.3 Estimação da Amplitude do Sinal de Interesse × Nível de Empilhamento	50
5.3 Conclusões	52
6 Avaliação da Estimação de Energia Baseada em Representação Esparsa na Calorimetria do ATLAS	53
6.1 Simulações do Sinal do LArg e do TileCal	54
6.1.1 Simulações	54
6.1.2 Resultados e Análises	57
6.1.3 Conclusões	68
6.2 Simulação Monte Carlo do LArg	68
6.2.1 Métodos Avaliados	70
6.2.2 Resultados e Análises	70
6.2.3 Conclusões	73
7 Conclusões	75
7.1 Trabalhos Futuros	77
Referências Bibliográficas	79
A Sistema de Coordenadas do ATLAS	85

Listas de Figuras

2.1	Visão geral do LHC e seus Detectores [1]	5
2.2	Alcance das partículas nos subdetectores do ATLAS [2]	6
2.3	Detector ATLAS e seus Sub-Detectores [3]	7
2.4	Visão simplificada do Sistema de Trigger/DAQ [4]	9
2.5	Calorímetro Hadronico e Calorímetro Eletromagnético [3]	10
2.6	Esboço da estrutura de acordeão do Calorímetro Eletromagnético e sua segmentação [5]	11
2.7	Diagrama Esquemático do Circuito do Pré-Amplificador e do <i>Shaper</i> [5].	12
2.8	Forma triangular do sinal produzido pelo detector (Linha) e Sinal após <i>Shaper</i> (Curva com Pontos) [5]	13
2.9	Linha do tempo base para atualizações no LHC do período de 2013 à 2030 [6]	14
3.1	Resposta típica de um calorímetro de altas energias (TileCal), em que as amostras digitais estão destacadas para (a) o sinal puro (sem a presença de ruído) e (b) sob condições de baixa SNR (com a presença de ruído)	18
3.2	Pulso de Referência do TileCal [7]. Neste calorímetro, a janela de observação tem comprimento $N = 7$, contendo todo o pulso	27
3.3	Resposta do calorímetro eletromagnético do ATLAS. As amostras digitais estão destacadas sobre a curva	28
3.4	Forma do pulso utilizado no ZEUS. [8, 9]	29
3.5	Exemplo de <i>fit</i> para amplitude múltipla com o método ManyAmps. As amostras e a forma total da forma são mostradas juntamente com as amplitudes individuais usadas para a reconstrução. [10]	30
4.1	Exemplo de <i>pile-up</i> de dois sinais em dois <i>bunch-crossing</i> diferentes .	36
4.2	Componentes recuperadas utilizando LS e SR	37
4.3	Diagrama em blocos exemplificando o processo de estimativa de energia pelo algoritmo SPARSE	39

4.4	Diagrama em blocos exemplificando o processo de estimativa de energia pelo algoritmo SPARSE-COF	40
5.1	Forma dos pulsos de referência nos sinais utilizados na simulação. As amostras centrais do sinal ($W = 5$ e $W = 12$ para o bipolar e unipolar, respectivamente) estão em destaque	46
5.2	Erro Relativo para simulação com 20% de ocupância e $SPR = 2$	49
5.3	Valores RMS da distribuição do erro relativo em função da ocupância para $SPR = 2$	51
5.4	Valores RMS da distribuição do erro relativo em função do SPR para uma ocupância de 10% (Sinal bipolar).	52
6.1	População de BC com 10% de ocupância. BC com valor 1 significa que ocorreu deposição de energia no canal	54
6.2	Passos para simulação do <i>pile-up</i> para o Sinal do LArg e do TileCal .	55
6.3	Sinal de referência do LArg com um pequeno desvio de fase, fazendo com que a amostra de valor máximo não corresponda ao pico do sinal	55
6.4	Adição de desvio de fase aos sinais	56
6.5	Adição de ruído branco gaussiano na simulação	56
6.6	Exemplos do conjunto de ruído na simulação	56
6.7	Exemplo de sinais simulados. (a) ruído (WGN + <i>pile-up</i>) e (b) sinal a ser estimado	57
6.8	Exemplo das 5 amostras do sinal resultante (vetor \mathbf{x}) no LArg (Simulação)	57
6.9	Comparação dos histogramas do erro relativo para 10% de ocupância e $SPR = 2$	58
6.10	Erro relativo SPARSE-COFxTRUTH para faixa dinâmica entre 0 a 100 contagens. Para 10% de ocupância e $SPR = 2$	59
6.11	Erro relativo OFxTRUTH para faixa dinâmica entre 0 a 100 contagens. Para 10% de ocupância e $SPR = 2$	59
6.12	Valores RMS para diferentes níveis de ocupância no LArg (simulação com $SPR = 2$)	60
6.13	Valores RMS para diferentes níveis de ocupância para estimativa de energia no TileCal (simulação com $SPR = 2$)	61
6.14	Valor do limiar obtido para detecção de <i>pile-up</i> nos métodos baseados no COF (simulação com $SPR = 2$)	62
6.15	Reconstrução dos jatos localizados no BC central sofrendo influência de empilhamento de dois jatos vindo BC vizinhos.(Sinal do LArg) . .	64
6.16	Projeção em $ \eta $ da reconstrução do jato do BC central (Sinal do LArg)	65

6.17	Reconstrução dos jatos OOT utilizando o método SPARSE-COF (Sinal do LArg)	67
6.18	Histogramas dos erros relativos para $\mu = 40$ (Monte Carlo LArg)	70
6.19	Histogramas dos erros relativos de estimativa para luminosidade de $\mu = 80$ (Monte Carlo LArg)	71
6.20	Histogramas dos erros relativos de estimativa para luminosidade de $\mu = 120$ (Monte Carlo LArg)	72
6.21	Porcentagem dos resultados em que pode-se atestar a unicidade e esparsidade ao ser aplicados ao algoritmo de estimativa esparso (Monte Carlo LArg)	73
A.1	O sistema de coordenadas do ATLAS.	86

Lista de Tabelas

5.1	Valores RMS e Média dos histogramas do erro relativo para reconstrução do pulso Bipolar e Unipolar	50
6.1	Parâmetros do <i>fit</i> para os três jatos reconstruídos utilizando os métodos OF e SPARSE-COF, em unidades de largura de célula (Sinal do LArg)	68
6.2	Tabela de RMS dos histogramas dos erros relativos de estimação - valores expressos em GeV (Monte Carlo LArg)	72

Lista de Abreviaturas e Siglas

ATLAS *A Toroidal LHC ApparatuS*

LHC *Large Hadron Collider*

ALICE *A Large Ion Collider Experiment*

LHCb *Large Hadron Collider beauty*

CMS *Compact Muon Solenoid*

TRT *Transition Radiation Tracker*

SCT *Semi-Conductor Tracker*

ROC *Receiver Operating Curve*

SNR *Signal-to-Noise Ratio*

MF *Matched Filter*

OF *Optimal Filter*

RMS *Root Mean Square*

ROD *Read Out Driver*

FIR *Finite Impulse Response*

ADC *Analog-to-Digital Converter*

DSP *Digital Signal Processor)*

ML *Maximum Likelihood*

PCA *Principal Component Analysis*

CERN *Conseil Européen pour la Recherche Nucléaire*

TDAQ *Trigger and Data Acquisition*

LAR *Liquid Argonic*

LArg *Liquid Argonic Calorimeter*

EM *Electromagnetic Calorimeter*

TileCal *Tile Calorimeter*

CTP *Central Trigger Processor*

LVL1 Primeiro Nível de Seleção de Eventos

LVL2 Segundo Nível de Seleção de Eventos

RoI *Region of Interest*

EF *Event Filter*

HLT *High Level Trigger*

PMT *Photo Multiplier Tube*

CIS *Charge Injection System*

TT *Trigger Tower*

PU *Processing Unit*

CP carga-paridade

DAQ Sistema de Aquisição de Dados

LS1 *First Long Shutdown*

LS2 *Second Long Shutdown*

PMT fotomultiplicadora

TT Trigger Towers

ROB Read Out Buffers

pile-up Empilhamento de Eventos

LS *Least Square*

IID Independente e Identicamente Distribuídas

MLP *Multilayer Perceptron* ou Perceptron Multicamadas

LP *Linear Programming*

DS *Dantzig-Selector Algorithm*

PDF Função Densidade de Probabilidade

BLUE *Best Linear Unbiased Estimator*

IP Ponto Interior primal-dual

LHCf *The Large Hadron Collider forward*

TOTEM *TOTAL Elastic and diffractive cross section Measurement*

FEBs *front-end boards*

COF *Constrained Optimal Filter*

DM *Deconvolution Matrix*

BC *Bunch-Crossing*

SR *Sparse Representation*

HEC *Hadronic End Cap*

MVU *Minimal Variance Unbiased Estimator*

OOT *out-of-time*

OMP *Orthogonal-Matching-Pursuit*

LS-OMP *Least-Square Orthogonal-Matching-Pursuit*

HL-LHC *High Luminosity LHC*

WGN *White Gaussian Noise*

Capítulo 1

Introdução

As engenharias avançaram significativamente ao longo de todo o século XX e início do século XXI, destacando-se a engenharia elétrica, transformando completamente o desenvolvimento científico e tecnológico e consequentemente nossa sociedade. As áreas de instrumentação eletrônica e processamento digital de sinais, têm tido certo protagonismo neste processo, passando por diversas modificações, trazendo grandes desafios para os pesquisadores e permitindo grandes avanços tecnológicos.

Atualmente, um dos grandes desafios da instrumentação eletrônica é a necessidade de processamento dos sinais de um crescente número de sensores em intervalos de tempo cada vez menores. Um exemplo de ambiente onde tais requisitos estão presentes são os colisionadores de partículas subatômicas que trabalham com altas taxas de colisões, gerando uma grande quantidade de subprodutos que deve ser em parte absorvida, detectada e amostrada por complexos experimentos posicionados ao redor dos pontos de colisão. Adicionalmente, como os eventos de interesse são raros, o ruído de fundo é de grande volume, exigindo o desenvolvimento de sistemas de validação de eventos *on-line*, visando a redução da taxa de eventos salva para posterior análise.

O *Large Hadron Collider* (LHC) é, hoje, o maior colisionador de partículas do mundo. Nele, feixes de prótons são acelerados até velocidades próximas à da luz, fazendo com que os prótons atinjam altas energias cinéticas para, então, serem colididas umas com as outras, a uma taxa de 40 MHz (uma colisão a cada 25 ns). O LHC forneceu aos seus experimentos quantidades colossais de dados em seus períodos de funcionamento, compreendendo 2010 até 2012 e 2015-2016.

O *A Toroidal LHC ApparatuS* (ATLAS) é o maior experimento do LHC, sendo um detector de propósito geral, projetado e construído para analisar a maior quantidade possível de fenômenos físicos passíveis de serem gerados em colisões prótons-prótons no LHC. vale ressaltar que este trabalho foi desenvolvido no contexto do experimento ATLAS. No ano de 2012, a colaboração ATLAS alcançou um dos seus

objetivos principais, que era a busca pelo Bóson de Higgs, uma partícula elementar prevista pelo Modelo Padrão, o que resultou no Prêmio Nobel de Física em 2013, partilhado pelos físicos teóricos, François Englert, da Universidade Livre de Bruxelas (Bélgica), e Peter Higgs, da Universidade de Edimburgo (Reino Unido).

Experimentos modernos em física de altas energias, como o ATLAS, apoiam-se fortemente nos seus sistemas de calorimetria. Com o objetivo de determinar a energia e identificação das partículas, os calorímetros são segmentados em células (normalmente a soma dos sinais dos diversos sensores em uma região) que fornecem resolução espacial ao detector. Quando partículas são absorvidas pelo material pesado do calorímetro, suas propriedades podem ser reconstruídas a partir dos sinais produzidos por todas as células que foram envolvidas no processo de deposição de energia no calorímetro. A energia depositada em cada célula é medida individualmente através de sua eletrônica de leitura dedicada. Do ponto de vista do sistema de aquisição de dados, cada célula corresponde a um canal de leitura individual. Os calorímetros atuais podem possuir milhares de células e necessitam que estes canais de leitura sejam processados paralelamente.

Todavia, no ATLAS, a estimativa de energia em seus calorímetros vem sofrendo com o empilhamento (*pile-up*) de sinais de diferentes colisões. Este fenômeno ocorre devido à alta taxa de colisões, combinada ao grande número de eventos por colisão e a resposta ao impulso dos sensores que é mais lenta do que a taxa de eventos do LHC. Este problema interfere na estimativa da deposição de energia no calorímetro, atrapalhando o sistema de filtragem online do ATLAS e até mesmo a reconstrução final de um evento. Esta tese trata especificamente do problema de empilhamento de sinais no contexto de experimentos de física de altas energias.

O LHC, até 2026, passará por várias atualizações em seus sistemas, onde está previsto um aumento considerável no número de interações por colisão. Parte destas atualizações já ocorreram e atualmente o LHC funciona com um número de interações por colisão de 40 (valor médio), o que é bem maior do que em seus primeiros anos de funcionamento. Com isso, o efeito de empilhamento de sinais aumentou (e ainda aumentará consideravelmente até 2025), impactando diretamente os sistemas de calorimetria e seus algoritmos de estimativa.

1.1 Objetivo

O presente trabalho propõe um novo método de estimativa de energia para calorimetria que supera as limitações das técnicas comumente utilizadas na área em cenários de empilhamentos de eventos, baseado em representação esparsa dos dados. Ao invés de modelar o empilhamento de sinais como ruído, como é o caso dos algoritmos comumente utilizados na área, o método proposto modela o empilhamento

como um possível sinal, desta forma, torna-se necessário deconvoluir a resposta ao impulso do calorímetro para que a estimativa possa ser realizada. Isso equivale a gerar uma representação mais esparsa dos dados de origem. Com isso, busca-se utilizar técnicas modernas de representação esparsa no ambiente de calorimetria operando em alta taxa de eventos.

1.2 Contribuições

As principais contribuições desta tese estão resumidas a seguir:

- desenvolvimento métodos de estimativa de energia para calorimetria de altas energias baseado na representação esparsa de dados;
- identificação dos cenários em que tais métodos tornam-se úteis no contexto da calorimetria de altas energias, através de comparação com outros métodos;
- análises do desempenho das técnicas esparsas e comparação com outros métodos no calorímetro eletromagnético do ATLAS;
- identificação de uma técnica esparsa que poderia ser implementada para estimativa de energia *on-line* no calorímetro eletromagnético do ATLAS.

1.3 Organização do texto

No Capítulo 2, será apresentado o ambiente no qual esta tese foi desenvolvida, destacando-se o experimento ATLAS e seu sistema de calorimetria. O Capítulo 3 apresenta uma revisão bibliográfica sobre métodos de estimativa para calorimetria de altas energias. No Capítulo 4, são apresentados os métodos para estimativa de energia em calorímetros baseados em representação esparsa. O Capítulo 5 apresenta os resultados de simulações, visando identificar em quais condições indica-se a utilização da representação esparsa para estimativa de energia em calorimetria. No Capítulo 6, os métodos baseado em representação esparsa são avaliados em simulações dos principais calorímetros do ATLAS e também com dados de simulações Monte Carlo do calorímetro eletromagnético do ATLAS. Finalmente, no Capítulo 7, serão apresentadas as conclusões sobre o trabalho realizado e seus possíveis desdobramentos.

Capítulo 2

O Ambiente de Física Experimental de Partículas

Este capítulo descreve o ambiente no qual este trabalho se insere, sendo importante para o melhor entendimento do problema da estimativa de energia para calorimetria de altas energias e das motivações da tese.

2.1 CERN e o LHC

O *Conseil Européen pour la Recherche Nucléaire* (CERN) é um dos maiores e mais respeitados centros de pesquisa científica do mundo, localizando-se na fronteira da França com a Suíça, próximo à cidade de Genebra. O CERN formado por um grupo de 22 países membros e conta ainda com a colaboração de outros países, como é o caso do Brasil. Seus estudos focam na busca do entendimento da estrutura fundamental do universo [1], utilizando para isso os maiores e mais complexos instrumentos científicos, como os colisionadores de partículas. Desta forma, no CERN, está localizado o maior acelerador de partículas do mundo, o LHC, que tem sua visão geral ilustrada na Figura 2.1. Como mostrado na figura, o LHC localiza-se dentro de um túnel circular com 27 km de comprimento, 175 m abaixo da superfície e foi projetado para realizar colisões próton-próton com uma energia de 14 TeV no centro de massa a cada 25 ns [11, 12].

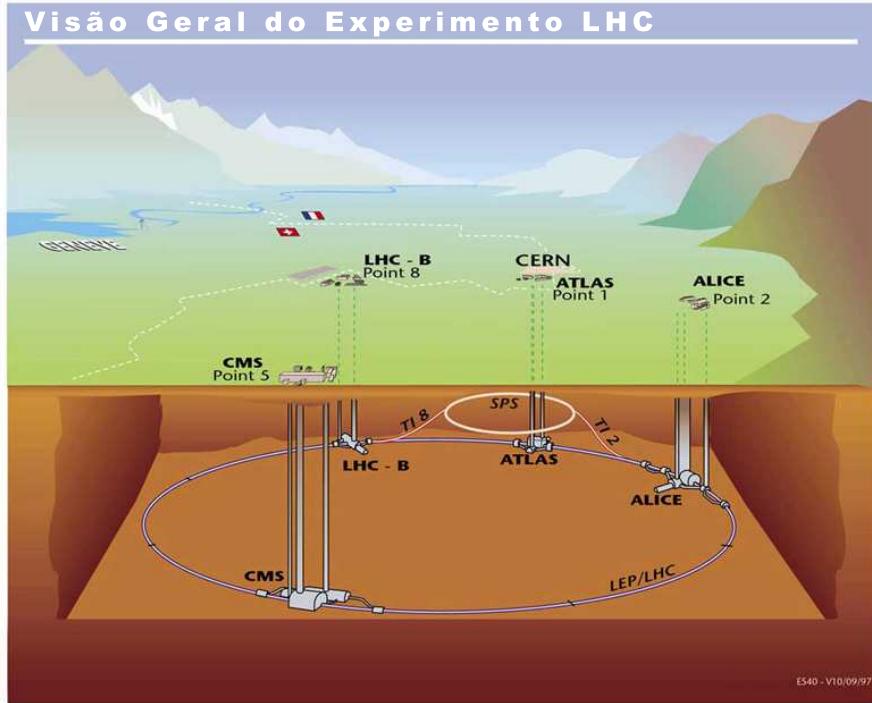


Figura 2.1: Visão geral do LHC e seus Detectores [1].

Colisionadores de partículas (ou aceleradores de partículas) são dispositivos que aceleram feixes de partículas a velocidades próximas à da luz, fazendo com que estas atinjam altas energias cinéticas para posteriormente colidirem umas com as outras. Através dessas colisões, partículas fundamentais são geradas, possibilitando aos pesquisadores estudarem a estrutura fundamental da matéria, explorando a física do Modelo Padrão e além [11]. Para estes estudos, utilizam-se de instrumentos científicos específicos, tais como os detectores de partículas. Esses detectores são baseados em um modelo de camadas, onde cada uma delas é responsável por estimar as propriedades específicas de diferentes tipos de partículas. As partículas eletromagnéticas incluem elétrons, pósitrons e fótons, já as partículas hadrônicas compreendem todas as partículas que interagem através de força forte (prótons e nêutrons). A Figura 2.2 mostra quais partículas interagem com quais subdetectores em um dos principais experimentos do LHC, o ATLAS. Essa informação é bastante útil para a discriminação das partículas detectadas.

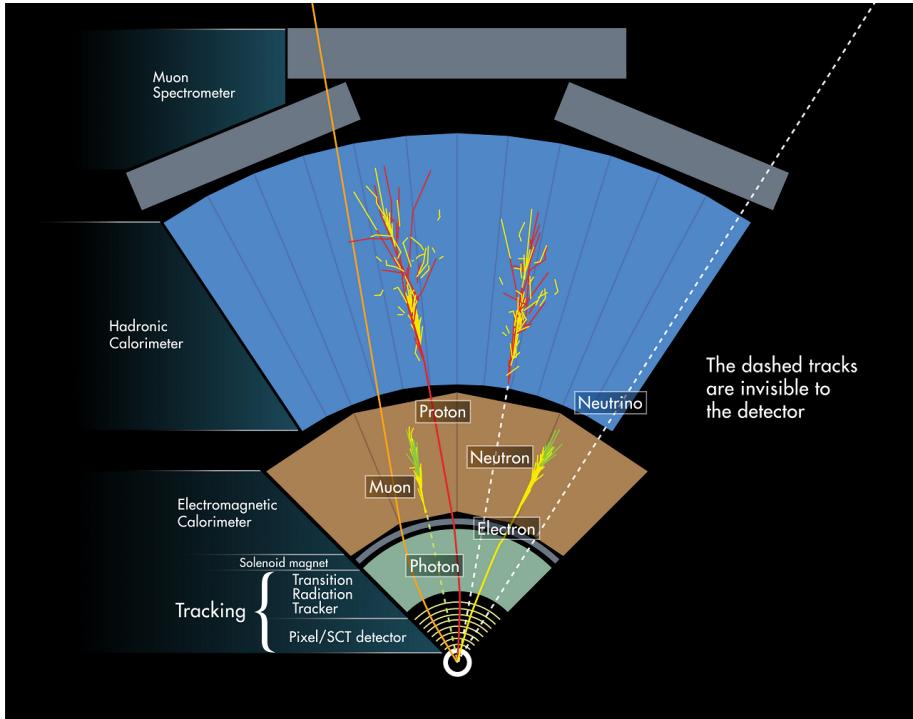


Figura 2.2: Alcance das partículas nos subdetectores do ATLAS [2].

Seis detectores estão colocados nos diversos pontos de colisão ao longo da circunferência do LHC, possibilitando a reconstrução das colisões ocorridas. São eles o ATLAS, *Compact Muon Solenoid* (CMS), *A Large Ion Collider Experiment* (ALICE), *Large Hadron Collider beauty* (LHCb), *TOTal Elastic and diffractive cross section Measurement* (TOTEM) e *The Large Hadron Collider forward* (LHCf).

Os dois maiores experimentos do LHC são o ATLAS e o CMS que são detectores de propósito geral, construídos para analisar uma grande gama de fenômenos físicos produzidos pelas colisões próton-próton no acelerador [2, 3, 13–15]. No ano de 2012, estes detectores alcançaram um dos seus principais objetivos, que era a busca pelo Bóson de Higgs [16], uma partícula elementar prevista pelo Modelo Padrão de partículas.

O ALICE e o LHCb são experimentos de médio porte e possuem objetivos mais específicos. O ALICE [17] se dedica à física de colisões nucleares enquanto o LHCb é dedicado ao estudo de violação carga-paridade (CP) [18].

O TOTEM e o LHCf são experimentos de pequeno porte dedicados à física projetiva (*forward*) de prótons e íons pesados [19, 20].

2.2 O ATLAS

O ATLAS é um experimento de propósito geral para detecção de colisões próton-próton no LHC. A colaboração ATLAS envolve 38 países, 174 institutos e conta com mais de 3000 cientistas. O projeto do detector foi pensado para estudar a maior

quantidade possível de fenômenos físicos passíveis de serem gerados em colisões no LHC[11, 12], desde a busca pelo boson de Higgs até dimensões extras e partículas que possam constituir a matéria escura.

O detector tem formato cilíndrico e foi projetado para cobrir um ângulo sólido próximo a 4π , ao redor da região de colisão das partículas. Além dos Magnetos para geração de intensos campos magnéticos que auxiliam na medida de momento das partículas carregadas, três sub-detectores básicos compõem o ATLAS (em ordem do mais interno para o mais externo): o detector de trajetórias, os calorímetros eletromagnético e hadrônico e o detector de múon, como ilustra a Figura 2.3. O ATLAS possui 44 m de comprimento, 25 m de altura e pesa aproximadamente 7000 T [2, 3, 13, 14, 21].

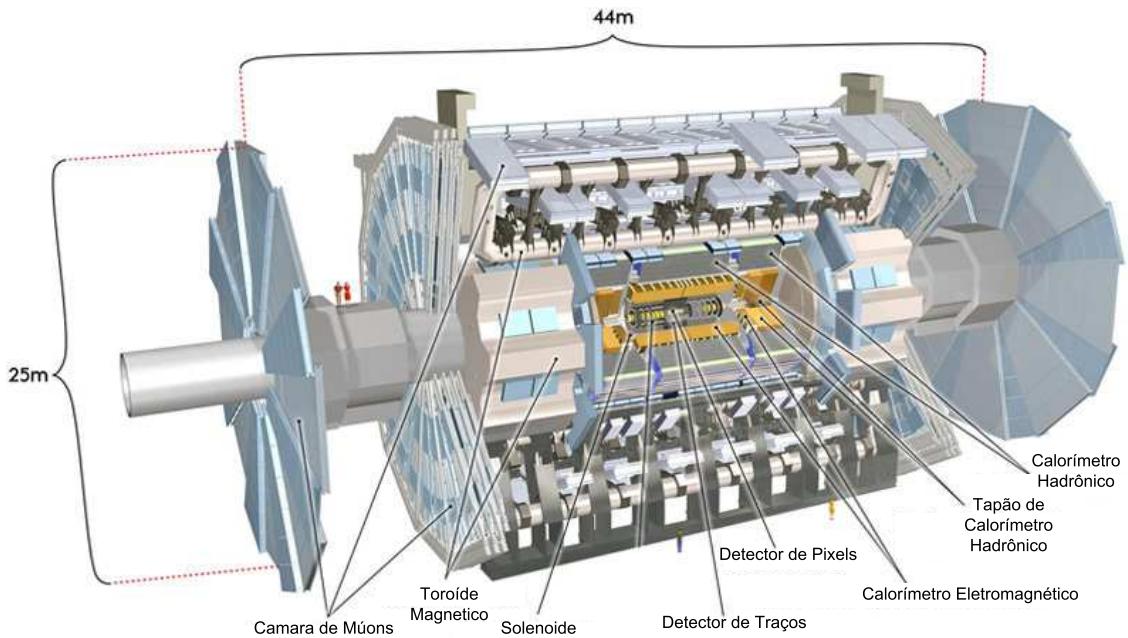


Figura 2.3: Detector ATLAS e seus Sub-Detectores [3].

O detector de trajetórias é o primeiro subsistema a interagir com as partículas provenientes da colisão e tem como objetivo a medida do momento e posição do vértice das partículas. Uma grande densidade de traços é medida neste detector devido ao considerável número de partículas produzidas nas colisões do LHC. O Detector de trajetórias é composto pelo Detector de Pixels (Pixel Detector), o *Semi-Conductor Tracker* (SCT) e o *Transition Radiation Tracker* (TRT), possuindo uma grande granularidade e estando imerso em um campo magnético de 2 Tesla gerado pelo Solenoide Central [22, 23].

Os calorímetros são os próximos detectores a interagirem com as partículas e têm como propósito absorver e medir a energia destas. Um calorímetro é um bloco de matéria que interage com as partículas, fazendo-as decair em outras menos ener-

géticas. Ao decair, essas partículas liberam energia, amostrada parcialmente pelo calorímetro [24]. Logo após o detector de traços, está localizado o calorímetro eletromagnético do ATLAS, chamado de Calorímetro de Argônio Líquido, do Inglês *Liquid Argonic Calorimeter* (LArg). O LArg tem sua estrutura composta chumbo e cobre imersos em argônio líquido, de modo que, quando uma partícula (Fóton ou Elétron) atravessa o detector, por ionização do argônio líquido, libera elétrons que são captados por eletrodos conectados às placas de cobre e transformados em corrente elétrica. Já o calorímetro hadrônico, que envolve o eletromagnético, é constituído por duas tecnologias, o Calorímetro de Telhas, do inglês *Tile Calorimeter* (TileCal) e a Tampa Hadrônica, do inglês *Hadronic End Cap* (HEC). O TileCal é formado por sanduíches placas de aço e de material cintilante (em forma de telhas, por isso seu nome) que ao interagir com as partículas (Prótons e Nêutrons) emitem fôtons (sinal luminoso) que são captados por fotomultiplicadoras e transformadas em corrente elétrica. O HEC é envolvido pelo barril externo do TileCal e está mais próximo do feixe e distante do ponto de colisão.

Numa camada mais externa, encontram-se as Câmaras de Múons [25, 26] que identificam uma determinada partícula denominada mûon. Os mûons de alta energia não são absorvidos pelo experimento, depositando apenas uma pequena parte da sua energia nos calorímetros.

2.2.1 O Sistema de Seleção de Eventos Online e Aquisição de Dados do ATLAS

Sistemas de seleção de eventos (filtragem) *online* são fundamentais em ambientes que trabalham com altas taxas e aonde se deseja separar o sinal de interesse dos demais sinais gerados pelo experimento (ruído de fundo). Geralmente, existem restrições no tempo para este tipo de processamento, pois os sistemas de filtragem operam, frequentemente, em ambientes que geram altas taxas de eventos. Em alguns casos, como nos colisionadores de partículas, os eventos gerados podem requerer uma quantidade de memória elevada, exigindo uma discriminação *online* de alta velocidade e tornando todo o processo de filtragem ainda mais complexo.

O sistema de seleção de eventos e aquisição de dados do ATLAS, do inglês *Trigger and Data Acquisition* (TDAQ), se baseia em três níveis que operam *online* [4, 27–29], onde cada um destes, refina as decisões tomadas no nível anterior e, quando necessário, aplica critérios de seleção adicionais. A partir de uma taxa de *Bunch-Crossing* (BC) (momento em que as partículas colidem) inicial de 40 MHz, a taxa de eventos selecionados deve ser reduzida para ≈ 100 Hz visando o armazenamento para posterior análise [4, 27–29].

O Primeiro Nível de Seleção de Eventos (LVL1) faz uma seleção inicial com

base em informações com granularidade reduzida de todos os calorímetros do ATLAS(eletromagnético e hadrônico) e das Câmaras de Múons. O primeiro nível é basicamente implementado em *hardware* de baixa programabilidade, reduzindo a taxa de eventos de entrada de 40 MHz para 100 kHz.

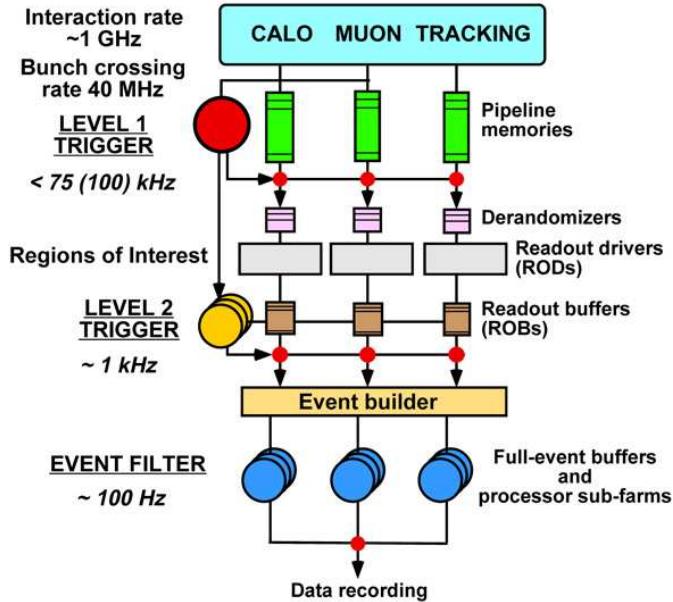


Figura 2.4: Visão simplificada do Sistema de Trigger/DAQ [4].

O Segundo Nível de Seleção de Eventos (LVL2), utilizando informações fornecidas pelo LVL1, as *Region of Interest* (RoI), deve reduzir a taxa de eventos de 100 kHz para não mais que 1 kHz [4, 27–29]. Para isso, conta com uma rede de computadores que processa os algoritmos de busca especializados nos diversos sub-detectores do ATLAS utilizando granulosidade total dos calorímetros nas RoI. Esta busca visa encontrar elementos que representem possíveis decaimentos referentes à física de interesse [21]. O terceiro nível é implementado por processadores interligados por redes rápidas, devendo reduzir ainda mais a taxa de eventos para até 100 Hz. Diferentemente do LVL2, que olha para partes específicas dos detectores, o terceiro nível utiliza toda a informação disponível.

O sistema de calorimetria do ATLAS tem um papel fundamental no sistema de filtragem *online* e na reconstrução *offline* dos eventos. Estes sistemas utilizam as informações básicas do calorímetro para estimar a energia depositada em suas células que constitui o tema central do presente trabalho.

Para uma melhor compreensão do processo de reconstrução de eventos no sistema de calorimetria do ATLAS, a próxima seção apresenta uma descrição detalhada deste sistema.

2.2.2 O Sistema de Calorimetria do ATLAS

O sistema de calorimetria do ATLAS é ilustrado em maiores detalhes na Figura 2.5, abrangendo uma ampla pseudo-rapidez $|\eta| < 5$ com cobertura total de azimute (Apêndice A).

O Calorímetro Eletromagnético, do inglês *Electromagnetic Calorimeter* (EM), de Argônio Líquido (LArg) é composto pelo barril e por duas tampas (ENDCAP). O calorímetro EM absorve energia de partículas que interagem de forma eletromagnética (elétrons e fótons) permitindo, por seus 190 mil canais de leitura, medidas de alta precisão tanto em energia quanto em posição.

O calorímetro hadrônico é posicionado envolvendo o calorímetro EM, tendo a espessura necessária para conter grande parte dos jatos de alta energia que serão produzidos no LHC [14]. O calorímetro hadrônico absorve a energia de partículas que interagem através da interação forte (principalmente hádrons e neutros), energia esta captada por mais de 10 mil canais presentes neste detector. A parte central e mais externa do calorímetro hadrônico é coberta pelo TileCal enquanto η maiores são cobertos pelo HEC.

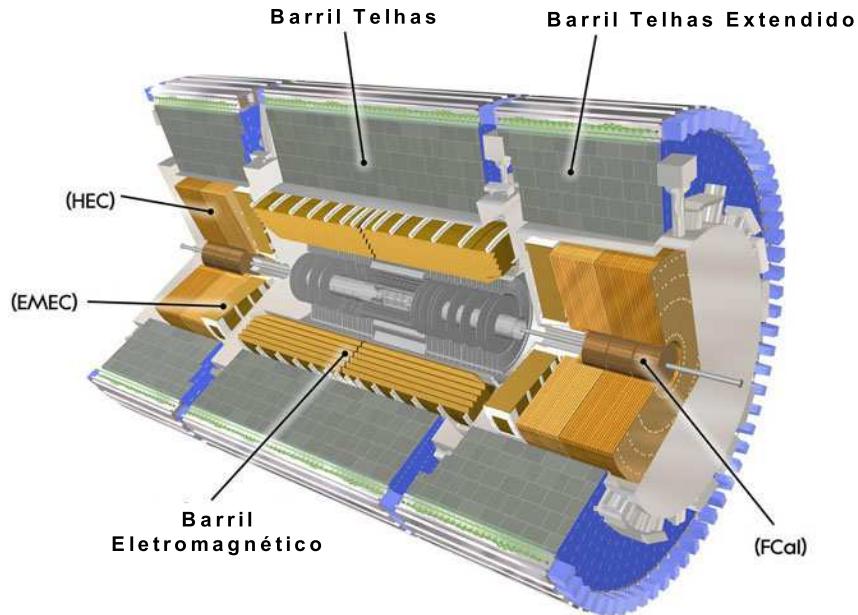


Figura 2.5: Calorímetro Hadronico e Calorímetro Eletromagnético [3].

Como o desenvolvimento desta tese tem como principal foco o problema de estimação de energia no LArg, este calorímetro e seu sinal serão descritos em mais detalhes a seguir.

2.2.2.1 O Calorímetro Eletromagnético de Argônio Líquido

O Calorímetro de Argônio Líquido (LArg), utiliza eletrodos em forma de "acordeão" (Figura 2.6), que se estendem por todo calorímetro eletromagnético, cobrindo o intervalo de pseudo-rapidez $|\eta| < 3.2$. Esta técnica é também utilizada para calorimetria hadrônica a partir de $|\eta| = 1.4$ até o limite de aceitação $|\eta| = 4.8$ (HEC) [5, 30]. O material absorvedor é chumbo. Uma alta tensão aplicada entre os eletrodos coleta as cargas geradas no processo de ionização, produzindo um sinal elétrico. Este calorímetro necessita de um sistema de resfriamento para a redução do ruído de fundo induzido pelos campos magnéticos e pela eletrônica de *front-end* [5, 30].

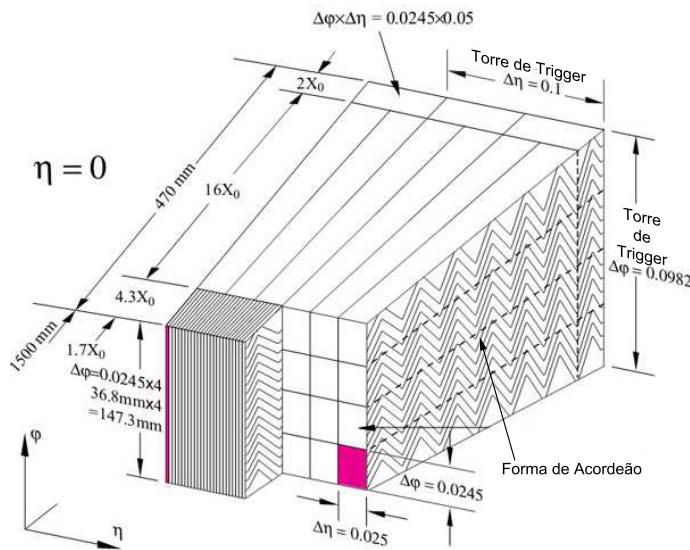


Figura 2.6: Esboço da estrutura de acordeão do Calorímetro Eletromagnético e sua segmentação [5].

Em relação à segmentação, este calorímetro é dividido em três camadas, das quais a segunda é a mais profunda. Cada camada possui granularidade específica, que ajuda a determinar alguns aspectos dos objetos que interagem com este detector. O calorímetro EM do ATLAS possui uma granularidade constante com relação à rotação (eixo ϕ), mas variável com relação a η . Esta diversificação da granularidade ao longo do plano $\eta \times \phi$, pode ser observada na Figura 2.6. O calorímetro EM também possui uma camada extra chamada de pré-amostrador (não mostrada na figura), utilizada para corrigir a energia perdida por elétrons e fótons antes destes atingirem o calorímetro.

2.2.2.2 Características do Sinal do LArg

Os sinais no LArg são produzidos quando uma partícula carregada ou fóton passa pelo detector e, por um processo de ionização, libera elétrons que são coletados pelos

eletrodos gerando uma corrente elétrica. O sinal de corrente possui forma aproximadamente triangular com o tempo de subida de poucos nanosegundos, seguido por um decaimento decaimento linear mais longo. O pico da corrente é proporcional a deposição de energia.

A eletrônica de *front-end* do LArg, que pode ser vista na Figura 2.7, tem como primeiro estágio um pré-amplificador. A função do pré-amplificador é gerar uma voltagem de saída proporcional à corrente de entrada. Em seguida, encontra-se o circuito conformador de sinal, do inglês *Shaper*, que é utilizado para dar forma fixa ao sinal, mais adequada para a digitalização do mesmo, e torná-lo bipolar o que contribui para estabilidade da linha de base do sinal. Adicionalmente, o *Shaper* garante que amplitude do pulso resultante seja proporcional a carga coletada (Energia). O circuito de *front-end* fornece ainda três sinais de saída com diferentes ganhos o que é necessário para cobrir a faixa dinâmica necessária em cada canal do calorímetro.

[5]

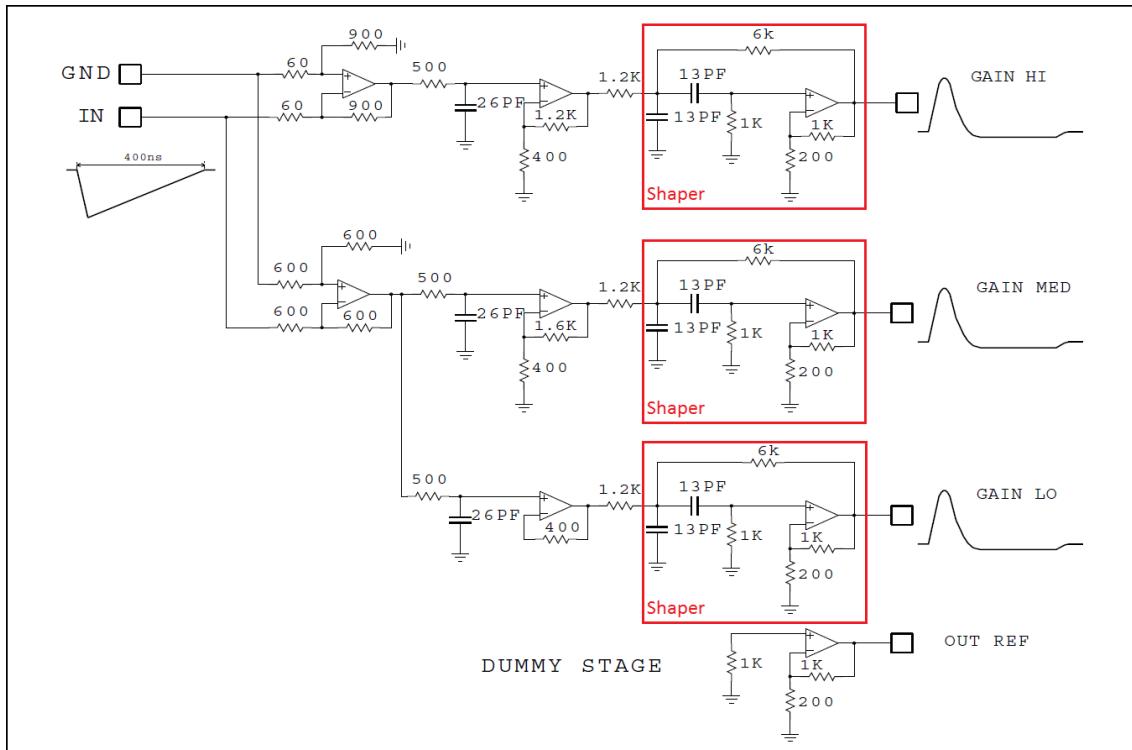


Figura 2.7: Diagrama Esquemático do Circuito do Pré-Amplificador e do *Shaper* [5].

Os três sinais com diferentes ganhos são enviados pela eletrônica de *front-end* para serem digitalizados com uma frequência de amostragem de 40 MHz no módulo digitalizador de sinais do LArg.

Existem dois caminhos para o sinal, um que segue para o primeiro nível de validação de eventos do ATLAS e outro que segue para o sistema de aquisição de dados. O sinal que segue para o LVL1 é analógico e resultante da soma de diversos

canais (sinal compactado). Uma vez que o LVL1 considera válido um determinado evento, um sinal contendo a informação do BC é enviado de volta ao detector para que então as amostras digitalizadas do evento de interesse sejam enviadas a *Read Out Driver* (ROD) (do inglês *Read-out Driver*) e tenha sua energia estimada a uma taxa de até 100 kHz e seja transmitida para o LVL2. Caso o evento seja aceito pelos segundo e terceiro níveis de validação, a energia estimada pela ROD para os todos os canais do calorímetro são, então, armazenadas pelo sistema de aquisição de dados do ATLAS.

A energia depositada em um determinado canal do calorímetro é estimada, na ROD, com base em uma janela de observação que contém apenas cinco amostras do sinal em torno do pico. A Figura 2.8 destaca as cinco amostras que são utilizadas no processo de reconstrução do pulso. Na figura, também pode ser vista uma representação do sinal de corrente gerado nos eletrodos do calorímetro para comparação com o sinal após a eletrônica de *front-end*.

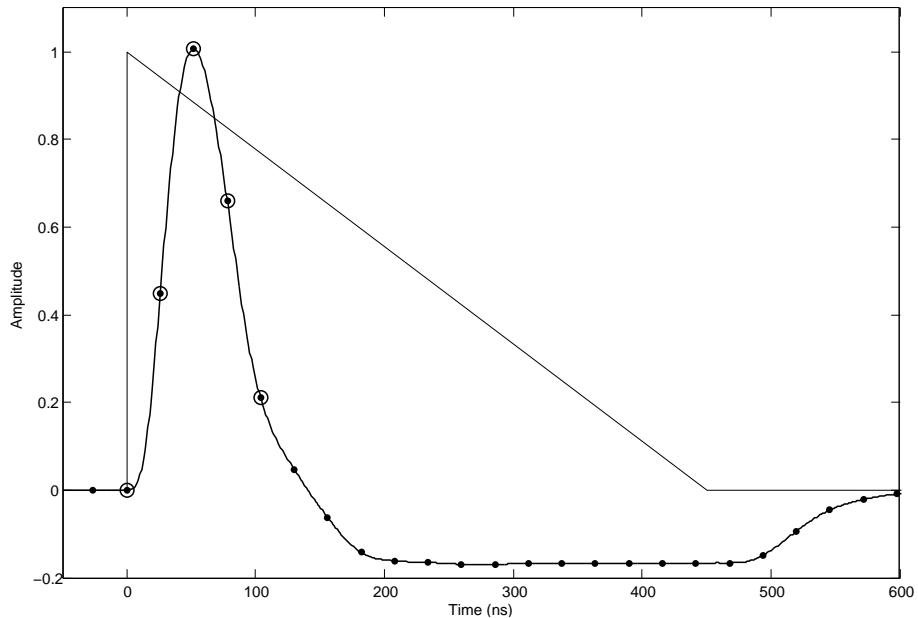


Figura 2.8: Forma triangular do sinal produzido pelo detector (Linha) e Sinal após *Shaper* (Curva com Pontos) [5].

Deve-se ressaltar que uma estimativa de energia incorreta nas ROD não somente afeta a reconstrução final de um determinado evento no ATLAS, mas também afeta o desempenho do sistema de validação de eventos que utiliza a informação da energia estimada nos seus segundo e terceiro níveis.

2.3 Programa de Atualização do ATLAS

A colaboração ATLAS estabeleceu um programa de atualização do experimento devido ao aumento progressivo da luminosidade do LHC, visando sua progressiva adequação para o *High Luminosity LHC* (HL-LHC) que deve iniciar sua operação em 2026.

Luminosidade é uma quantidade que mede a habilidade de um acelerador de partículas produzir um número determinado de interações, sendo que quanto mais interações produzidas em uma colisão maior a chance de observar eventos raros. Desta forma, a luminosidade é definida como um fator proporcional entre o número de eventos por segundo e a área da seção do feixe de partículas, tendo unidade de $\text{cm}^{-2}\text{s}^{-1}$ [31].

O LHC entrou em operação em 2009 aumentando gradativamente a energia no centro de massa e sua luminosidade. Em 2012, o LHC chegou a trabalhar com picos de luminosidade de $3 \times 10^{33} \text{ cm}^{-2}\text{s}^{-1}$ e com energia no centro de massa de 8 TeV, finalizando o primeiro período de operação do LHC, denominado de *Run 1*.

Durante os anos de 2013 e 2014 (Figura 2.9), o acelerador permaneceu desligado para manutenção e atualização de alguns de seus componentes e detectores (*First Long Shutdown* (LS1)). Este período de parada do ATLAS serviu para sua atualização tendo sido denominado de Fase 0 de atualização.

Na segunda metade de 2015, o acelerador voltou a operação, marcando o início do *Run 2* do LHC que está planejado para se estender até o final de 2018. Em 2016, o LHC atingiu picos de luminosidade de $1,4 \times 10^{34} \text{ cm}^{-2}\text{s}^{-1}$ com uma luminosidade integrada de 40 fb^{-1} no ATLAS.

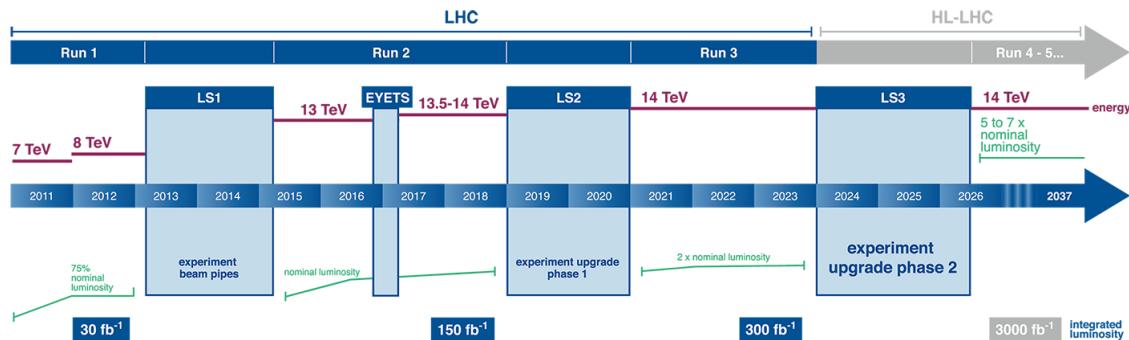


Figura 2.9: Linha do tempo base para atualizações no LHC do período de 2013 à 2030 [6].

A Fase I de atualização do detector está prevista para 2019-2020 (Figura 2.9), quando o LHC entra em sua segunda longa parada (*Second Long Shutdown* (LS2)). Nesta fase, será necessária a atualização do sistema de pré-aceleração e de injeção de partículas do LHC visando alcançar uma luminosidade $2 \times 10^{34} \text{ cm}^{-2}\text{s}^{-1}$. Adicionalmente, diversos sistemas e detectores do ATLAS deverão passar por atualizações.

No ano de 2021, que inicia o *Run 3*, o LHC voltará a realizar colisões com a expectativa da ocorrência de 50 à 80 interações por colisão, em média, a cada 25 ns, o que é muito além dos objetivos iniciais do projeto do LHC. Nesta fase, espera-se acumular 300 fb^{-1} de dados, ampliando o alcance para a descoberta de novas físicas e a capacidade de estudar novos fenômenos.

Finalmente, durante os anos de 2024, 2025 e 2026 (Fase II de atualização), deverá ocorrer uma nova longa parada do acelerador visando diversas atualizações de seus componentes e detectores onde a luminosidade instantânea deverá atingir $5 \times 10^{34} \text{ cm}^{-2} \text{s}^{-1}$, para uma luminosidade integrada total de 3.000 fb^{-1} no HL-LHC.

Um dos maiores desafios para colaboração ATLAS é que com o aumento da luminosidade aumenta também um efeito chamado de *Empilhamento de Eventos (pile-up)*, o que deteriora o desempenho dos algoritmos de estimação de energia em seus calorímetros e da reconstrução dos eventos, refletindo diretamente na performance do sistema de calorimetria [32–35]. Deve-se ressaltar que neste trabalho, o *pile-up* refere-se a sobreposição (empilhamento) de sinais em um mesmo canal do calorímetro, devido ao grande número de interações por colisões e o consequente aumento na ocupação dos canais do calorímetro.

Desta forma, o aumento progressivo da luminosidade do LHC se configura como principal razão para o desenvolvimento desta tese, trazendo um grande desafio para o desenvolvimento de algoritmos de estimação de energia em calorímetros que possam operar bem em condições de empilhamento de sinais. Como este problema é mais severo para o LArg do que para o TileCal, devido à maior proximidade do LArg em relação ao feixe, o foco para o desenvolvimento e aplicação do método proposto será o LArg.

Capítulo 3

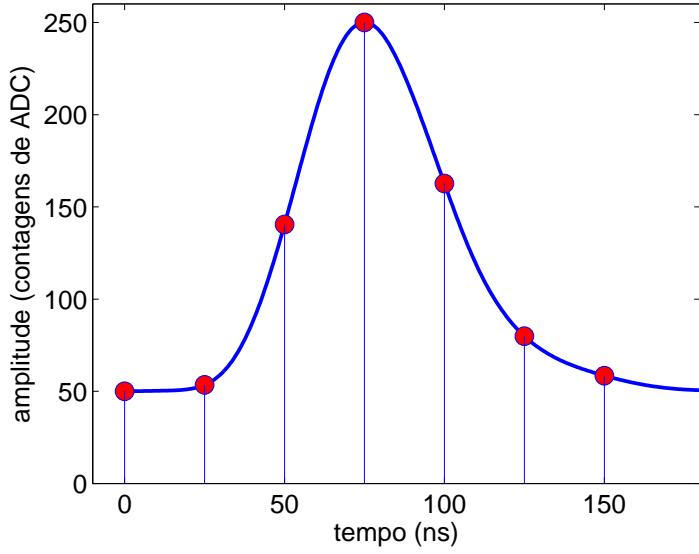
Estimação de Energia em Calorímetros para Física de Altas Energias

A estimação da energia em calorímetros é comumente abordada como um problema de estimação de parâmetros de um sinal recebido. Neste capítulo, inicialmente é apresentado de forma sucinta o problema da estimação de energia em calorimetria; em seguida, são apresentadas algumas técnicas de estimação de parâmetros de sinais; são descritos alguns métodos comumente utilizados em calorímetros modernos; e, concluindo o capítulo, são apresentados algoritmos alternativos (propostos mais recentemente) que lidam mais especificamente com o problema do empilhamento de sinais.

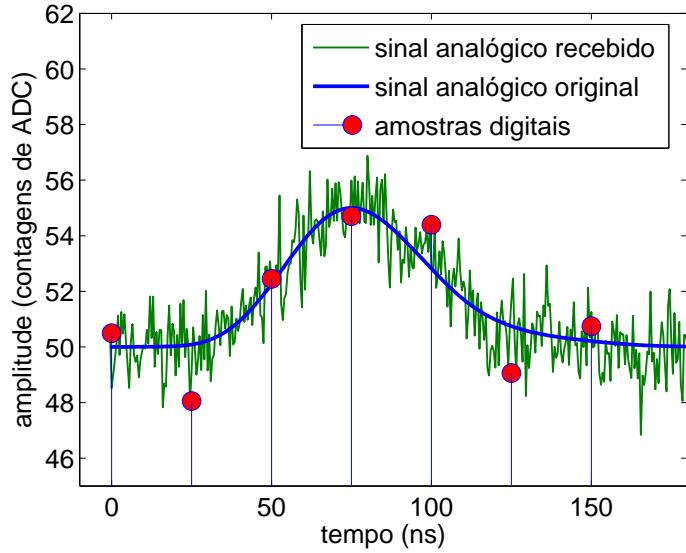
3.1 O Problema da Estimação de Energia em Calorimetria

Normalmente, o processo de estimativa da energia de calorímetros em experimentos de física de partículas envolve o pulso de interesse, gerado pela deposição de energia das partículas no detector, e o ruído de fundo, que é principalmente proveniente da cadeia eletrônica de condicionamento do sinal (eletrônica de *front-end*). Este tipo de ruído é normalmente originado por contribuições de diversas fontes independentes e, segundo o teorema do limite central [36], pode ser aproximado por uma distribuição gaussiana. O uso do modelo gaussiano na descrição do ruído de fundo simplifica o projeto e análise de estimadores, uma vez que a covariância pode ser usada para descrever todo o processo aleatório. Adicionalmente, se as variáveis da densidade de probabilidade conjunta de um processo aleatório são gaussianas e descorrelacionadas, existe independência estatística entre as mesmas [36].

Os circuitos de condicionamento e conformação de sinais de calorímetros modernos fornecem um pulso com formato aproximadamente fixo, ou seja, parâmetros como largura a meia altura, tempo de subida e tempo de descida fixos, mas com a amplitude dependente da energia depositada pela partícula em uma determinada região do detector. Tipicamente, os pulsos utilizados em calorimetria são unipolares [8, 17, 37, 38], cuja duração pode cobrir diversos períodos de colisão. A Figura 3.1(a) ilustra uma resposta típica encontrada em calorímetros modernos (TileCal como exemplo), onde as amostras digitais que são utilizadas no processamento digital são destacadas. Desta forma, o problema da estimativa de energia se resume em obter a amplitude deste sinal digital recebido. A Figura 3.1(b) ilustra um sinal imerso em ruído e suas amostras digitais, explicitando a dificuldade de estimativa da amplitude em casos de baixa relação sinal ruído (SNR).



(a)



(b)

Figura 3.1: Resposta típica de um calorímetro de altas energias (TileCal), em que as amostras digitais estão destacadas para (a) o sinal puro (sem a presença de ruído) e (b) sob condições de baixa SNR (com a presença de ruído).

A maioria dos calorímetros de altas energias utiliza um algoritmo de estimativa da amplitude (reconstrução da energia) baseado na soma ponderada (ou um filtro *Finite Impulse Response* (FIR)) das amostras digitais recebidas dentro de uma janela de leitura de N amostras, considerando ainda o ruído como sendo gaussiano [39] [40, 41]. Este tipo de abordagem é conveniente para sistemas que necessitam de uma resposta rápida do algoritmo de estimativa, como é o caso de experimentos de alta taxa de eventos, unindo simplicidade e desempenho. A decisão de qual

canal contém informação relevante é baseada no valor da amplitude estimada. Ou seja, somente os sinais acima de um determinado limiar de amplitude são utilizados durante as análises *offline* para reconstrução do evento.

Em condições de alta luminosidade, onde o feixe de partículas é mais denso e consequentemente o número de eventos por colisão é alto, o sinal de interesse ainda pode sofrer a sobreposição de sinais provenientes de colisões subsequentes. Este efeito distorce a forma do pulso de interesse, comprometendo assim a estimativa da amplitude. Os métodos tradicionais de reconstrução da amplitude em calorimetria consideram o empilhamento de sinais como uma fonte adicional de ruído, a qual é tratada utilizando a informação da estatística de segunda ordem do ruído, já que em suas formulações o ruído é considerado gaussiano. Desta forma, os estimadores utilizam a matriz de covariância do ruído [42]. Assim, tais estimadores permanecem ótimos para condições em que o ruído pode ser modelado por uma distribuição gaussiana, entretanto, o empilhamento de sinais modifica as características estatísticas do processo, levando estes métodos a condições de operação sub-ótimas.

3.2 Estimação de Parâmetros

A Teoria de Estimação é aplicada em diversos sistemas eletrônicos. Exemplos desses sistemas são: Radar, Sonar, Voz, Imagem, Biomedicina, Comunicações, Controle, Sismologia. Tais sistemas compartilham um problema em comum: a necessidade de estimar um parâmetro ou um conjunto de parâmetros de um sinal frequentemente corrompido por ruído, tipicamente aditivo.

Para possibilitar a formulação matemática do problema, considere um sinal $x(t)$, resultante de um determinado sistema linear que é a combinação do sinal $s(t; \boldsymbol{\theta})$, onde $\boldsymbol{\theta}$ é um vetor de parâmetros a ser estimado, e um ruído aditivo $w(t)$, podendo ser escrito como:

$$x(t) = s(t; \boldsymbol{\theta}) + w(t). \quad (3.1)$$

Atualmente, o sinal $x(t)$ será normalmente processado digitalmente; portanto, torna-se necessário representá-lo no domínio discreto

$$x[n] = s[n; \boldsymbol{\theta}] + w[n]. \quad (3.2)$$

Matematicamente, pode-se representar um vetor $\mathbf{x} = [x[0] \ \cdots \ x[N - 1]]^T$ com N -elementos dependentes dos parâmetros desconhecidos $\boldsymbol{\theta}$. Para determinar $\boldsymbol{\theta}$, baseado no vetor \mathbf{x} , define-se então um estimador através da função $g(\cdot)$, tal que:

$$\hat{\boldsymbol{\theta}} = g(\mathbf{x}). \quad (3.3)$$

Face ao caráter aleatório dos dados, para se determinar bons estimadores, o primeiro passo é ter um bom modelo matemático dos dados. Desta forma, descreve-se o conjunto de dados por sua Função Densidade de Probabilidade (PDF). Esta função é parametrizada por $\boldsymbol{\theta}$, ou seja, temos uma classe de funções onde uma é diferente da outra devido à um valor diferente de $\boldsymbol{\theta}$.

O desempenho obtido pelo estimador será totalmente dependente dos pressupostos escolhidos para a PDF. Esse tipo de estimação, que se baseia na PDF, é denominada de Estimação Clássica, na qual os parâmetros de interesse assumem-se deterministicos mas desconhecidos [43].

Se, *a priori*, é conhecida alguma característica a respeito do parâmetro a ser estimado, como por exemplo o intervalo de valores ao qual o parâmetro pertence, pode-se incorporar este conhecimento na solução do problema. Para atribuir este conhecimento na resolução do problema, assume-se que $\boldsymbol{\theta}$ não é mais determinístico, mas sim uma variável aleatória e pode-se lhe ser atribuída uma PDF, dentro do intervalo conhecido. Sendo assim, todo estimador produzirá valores dentro deste intervalo. Desta forma, o parâmetro que se deseja estimar será visto como uma realização da variável $\boldsymbol{\theta}$. Tal abordagem é conhecida como Estimação Bayesiana e é descrita pela PDF conjunta

$$p(x; \boldsymbol{\theta}) = p(x|\boldsymbol{\theta})p(\boldsymbol{\theta}), \quad (3.4)$$

onde $p(\boldsymbol{\theta})$ é a PDF *a priori*, representando o conhecimento prévio das características de $\boldsymbol{\theta}$ antes de qualquer observação, e $p(x|\boldsymbol{\theta})$ é a PDF condicional, que descreve o conhecimento dos dados x condicionado ao conhecimento de $\boldsymbol{\theta}$ [43, 44].

Contudo, estimadores baseados em PDF frequentemente resultam em funções $g(\cdot)$ não-lineares, o que torna sua implementação complexa e dependente dos dados. Portanto, em algumas situações práticas, é interessante forçar o projeto de estimadores lineares devido a simplicidade de implementação e ao comportamento independente da faixa dinâmica dos dados de entrada; todavia, tais estimadores são, geralmente, não-ótimos.

Desta forma, no contexto da calorimetria de altas energia, técnicas lineares têm sido amplamente utilizadas para estimação de energia, cabendo a eletrônica de condicionamento garantir que tais algoritmos operem em condições próximas à ótima. Algumas técnicas de estimação lineares muito utilizadas em calorimetria, que têm projetos independentes da PDF do processo, serão apresentadas a seguir.

3.3 BLUE - *Best Linear Unbiased Estimator*

Partindo-se de um caso particular, onde se deseja estimar um único parâmetro θ , o *Best Linear Unbiased Estimator* (BLUE) restringe o algoritmo de estimação a uma operação linear, ou seja, a uma soma ponderada das entradas, conforme a Equação (3.5)

$$\hat{\theta} = \sum_{k=0}^{N-1} g_k x[k], \quad (3.5)$$

onde g_k são os pesos a serem determinados. Pode-se gerar um grande número de diferentes estimadores de θ , pois este depende diretamente dos valores escolhidos para g_k . No caso dos estimadores BLUE, o projeto (determinação dos pesos g_k) visa a não tendenciosidade e a minimização da variância do mesmo.

A condição de não tendenciosidade, resulta em

$$E[\hat{\theta}] = \sum_{k=0}^{N-1} g_k E[x[k]]. \quad (3.6)$$

Já a variância de $\hat{\theta}$, pode ser escrita como

$$\text{var}[\hat{\theta}] = E \left[\left(\sum_{k=0}^{N-1} g_k x[k] - E \left[\sum_{k=0}^{N-1} g_k x[k] \right] \right)^2 \right]. \quad (3.7)$$

Visando uma representação matricial da Equação (3.7), pode-se definir os vetores $\mathbf{g} = [g_0 \ g_1 \ \dots \ g_{N-1}]^T$ e $\mathbf{x} = [s[0]+w[0] \ s[1]+w[1] \ \dots \ s[N-1]+w[N-1]]^T$, resultando em

$$\begin{aligned} \text{var}[\hat{\theta}] &= E[(\mathbf{g}^T \mathbf{x} - \mathbf{g}^T E[\mathbf{x}])^2] \\ &= E[(\mathbf{g}^T (\mathbf{x} - E[\mathbf{x}]))^2] \\ &= E[\mathbf{g}^T (\mathbf{x} - E[\mathbf{x}]) (\mathbf{x} - E[\mathbf{x}])^T \mathbf{g}] \\ &= \mathbf{g}^T \mathbf{C} \mathbf{g}, \end{aligned} \quad (3.8)$$

onde \mathbf{C} é a matriz de covariância do ruído $w[n]$.

O vetor de pesos \mathbf{g} é encontrado pela minimização da Equação (3.8) sujeita à restrição imposta pela Equação (3.6). Para o caso particular em que $s[n] = Ah[n]$, onde $h[n]$ representa as amostras de um sinal determinístico e A a sua amplitude

$$x[n] = Ah[n] + w[n]. \quad (3.9)$$

Se a média do ruído $w[n]$ for igual a zero, a restrição de não tendenciosidade resulta

em

$$\begin{aligned}\sum_{k=0}^{N-1} g_k E[x[k]] &= A \\ \sum_{k=0}^{N-1} g_k h[k]A &= A \\ \sum_{k=0}^{N-1} g_k h[k] &= 1\end{aligned}$$

ou

$$\mathbf{g}^T \mathbf{h} = 1 \quad (3.10)$$

onde $\mathbf{h} = [h[0] \ h[1] \ \dots \ h[N-1]]^T$ é conhecido.

A variância (3.8) do estimador pode, então, ser minimizada através da utilização de multiplicadores de Lagrange [43]. Como apenas uma restrição (Equação (3.10)) é aplicada, apenas um multiplicador é utilizado no método, como mostra a Equação (3.11),

$$J = \mathbf{g}^T \mathbf{C} \mathbf{g} + \lambda(\mathbf{g}^T \mathbf{h} - 1), \quad (3.11)$$

onde J é a função custo a ser minimizada e λ é o multiplicador de Lagrange.

A minimização da função custo em (3.11) pode ser feita derivando-a em relação ao vetor \mathbf{g} , resultando em

$$\mathbf{g}_{BLUE} = \frac{\mathbf{h}^T \mathbf{C}^{-1}}{\mathbf{h}^T \mathbf{C}^{-1} \mathbf{h}}.$$

Desta forma, a estimativa BLUE para este caso particular resulta em

$$\hat{A} = \frac{\mathbf{h}^T \mathbf{C}^{-1} \mathbf{x}}{\mathbf{h}^T \mathbf{C}^{-1} \mathbf{h}}. \quad (3.12)$$

Caso $w[n]$ seja um ruído gaussiano, o estimador BLUE resulta na menor variância possível, ou seja, é um estimador *Minimal Variance Unbiased Estimator* (MVU) [45, 46].

Se a informação a ser estimada for um vetor de parâmetros de dimensão $p \times 1$, então, para o estimador ser linear ao conjunto de dados

$$\hat{\theta}_i = \sum_{k=0}^{N-1} g_{ik} x[k] \quad i = 1, 2, \dots, p, \quad (3.13)$$

onde g_{ik} são os pesos, o índice i refere-se ao parâmetro a ser estimado e o índice k refere-se ao elemento do vetor \mathbf{x} . Na forma matricial, tem-se

$$\hat{\boldsymbol{\theta}} = \mathbf{G}^T \mathbf{x}$$

onde \mathbf{G} é uma matriz $N \times p$ a ser determinada. Para que $\hat{\boldsymbol{\theta}}$ seja não tendencioso

$$E[\hat{\theta}_i] = \sum_{k=0}^{N-1} g_{ik} E[x[k]] = \theta_i \quad i = 1, 2, \dots, p, \quad (3.14)$$

ou na forma matricial

$$E[\hat{\boldsymbol{\theta}}] = \mathbf{G}^T E[\mathbf{x}] = \boldsymbol{\theta}. \quad (3.15)$$

Dada a Equação (3.15) e considerando

$$E[\mathbf{x}] = \mathbf{H}\boldsymbol{\theta} \quad (3.16)$$

para uma matriz conhecida \mathbf{H} ($N \times p$), dada por

$$\mathbf{H} = \begin{bmatrix} h_1[0] & h_2[0] & \cdots & h_p[0] \\ h_1[1] & h_2[1] & \cdots & h_p[1] \\ \vdots & \vdots & \ddots & \vdots \\ h_1[N-1] & h_2[N-1] & \cdots & h_p[N-1] \end{bmatrix},$$

substituindo a Equação (3.16) na Equação (3.15), a restrição de não tendenciosidade do estimador resulta em

$$\mathbf{G}^T \mathbf{H} = \mathbf{I}_{p \times p}. \quad (3.17)$$

Definindo-se $\mathbf{g}_i = [g_{i0} \ g_{i1} \ \dots \ g_{i(N-1)}]^T$, a variância resulta em

$$\text{var}[\hat{\theta}_i] = \mathbf{g}_i^T \mathbf{C} \mathbf{g}_i, \quad (3.18)$$

que é semelhante ao resultado para o caso escalar (Equação (3.8)). O BLUE para um vetor de parâmetros é encontrado pela minimização da Equação (3.18) sujeita às restrições de (3.17), repetindo a minimização para cada parâmetro θ_i . A função custo neste caso resulta em

$$J_i = \mathbf{g}_i^T \mathbf{C} \mathbf{g}_i + \lambda_0(\mathbf{g}_i^T \mathbf{h}_i - 1) + \sum_{k=1}^p \lambda_k \mathbf{g}_k^T \mathbf{h}_i, \quad \text{para } k \neq i, \quad (3.19)$$

onde pode ser observado que são necessários p multiplicadores de Lagrange. A condição de não tendenciosidade é multiplicada por λ_0 e os demais multiplicadores são restrições adicionais para forçar a ortogonalidade entre os estimadores, conforme indicado na Equação (3.17) de restrições.

O resultado final do processo de minimização de cada função J_i pode ser agrupado em uma única equação matricial [43]

$$\mathbf{G}_{BLUE} = \mathbf{C}^1 \mathbf{H} \left(\mathbf{H}^T \mathbf{C}^{-1} \mathbf{H} \right)^{-1}. \quad (3.20)$$

A estimativa do método resulta em

$$\hat{\boldsymbol{\theta}} = (\mathbf{H}^T \mathbf{C}^{-1} \mathbf{H})^{-1} \mathbf{H}^T \mathbf{C}^{-1} \mathbf{x}. \quad (3.21)$$

O BLUE vetorial restringe-se a problemas onde $p \leq N$, pois a matriz $\mathbf{H}^T \mathbf{C}^{-1} \mathbf{H}$ não pode ser invertida para $p > N$.

3.4 Estimador de Máxima Verossimilhança (MLE)

O problema de estimação de parâmetros pode ser abordado através da maximização da probabilidade $P(\boldsymbol{\theta}|\mathbf{x})$, ou seja, deseja-se obter o valor de $\hat{\boldsymbol{\theta}}$ que fornece a maior probabilidade condicional $P(\boldsymbol{\theta}|\mathbf{x})$. Como esta probabilidade normalmente não é conhecida, pode-se reescrevê-la em função da densidade de probabilidade condicional do vetor observado dado o vetor de parâmetros, utilizando a regra de Bayes

$$P(\boldsymbol{\theta}|\mathbf{x}) = p(\mathbf{x}|\boldsymbol{\theta})P(\boldsymbol{\theta}), \quad (3.22)$$

onde $p(\mathbf{x}|\boldsymbol{\theta})$ é a função densidade de probabilidade condicional do processo observado dado o vetor de parâmetros e $P(\boldsymbol{\theta})$ é a probabilidade *a priori* do vetor de parâmetros.

Observando a Equação (3.22), é possível notar que a maximização da probabilidade $P(\boldsymbol{\theta}|\mathbf{x})$ pode ser obtida através da maximização da densidade condicional $p(\mathbf{x}|\boldsymbol{\theta})$, chamada neste caso de função de verossimilhança. Considerando que o processo observado $\mathbf{X} = \{X_1, X_2, X_3, \dots, X_N\}$ corresponde a variáveis aleatórias independentes e igualmente distribuídas (i.i.d., do inglês *independent and identically distributed*) com densidades de probabilidade $p(x_k|\boldsymbol{\theta})$, a função de verossimilhança resulta em

$$p(\mathbf{x}|\boldsymbol{\theta}) = \prod_{k=1}^N p(x_k|\boldsymbol{\theta}). \quad (3.23)$$

Com isso, o primeiro passo para obtenção do MLE é conhecer a função densidade de probabilidade das variáveis aleatórias, $p(x_k|\boldsymbol{\theta})$, dado que este possui um determinado parâmetro a ser estimado $\boldsymbol{\theta}$. Em seguida, se as variáveis forem i.i.d., extrai-se a função de verossimilhança através da Equação (3.23). A melhor estimativa de $\boldsymbol{\theta}$ é o valor que maximiza $p(\mathbf{x}|\boldsymbol{\theta})$. Desta forma, a estimativa pode ser encontrada resolvendo a seguinte equação para a variável $\boldsymbol{\theta}$

$$\frac{\partial p(\mathbf{x}|\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = 0. \quad (3.24)$$

Como pode ser observado, para o desenvolvimento do MLE, é necessário o co-

nhecimento *a priori* sobre o processo aleatório que envolve o parâmetro de interesse. Em muitos casos práticos, o problema não apresenta solução analítica ou se torna um procedimento complicado, que resulta em estimadores complexos. Desta forma, muitos projetistas utilizam aproximações para simplificar o projeto de estimadores.

No problema de estimação formulado na seção anterior, aonde o sinal $x[k]$ é modelado através da Equação (3.9), supondo o caso particular em que as variáveis podem ser modeladas por uma distribuição gaussiana e o processo multivariável possui matriz de covariância \mathbf{C} , a função densidade de probabilidade conjunta é dada por

$$p(\mathbf{x}|\theta) = \frac{1}{\sqrt{2\pi \det(\mathbf{C})}} \exp\left(\frac{-(\mathbf{x} - A\mathbf{h})^T \mathbf{C}^{-1} (\mathbf{x} - A\mathbf{h})}{2}\right), \quad (3.25)$$

onde $\det(\cdot)$ representa o determinante da matriz.

A solução pode ser obtida aplicando-se o logaritmo, derivando e igualando a zero

$$\frac{\partial p(\mathbf{x}|\theta)}{\partial \theta} = \frac{-1}{\sqrt{2\pi \det(\mathbf{C})}} \frac{(\mathbf{x} - A\mathbf{h})^T \mathbf{C}^{-1} (\mathbf{x} - A\mathbf{h})}{2} = 0. \quad (3.26)$$

A estimativa $\hat{\theta}_{MLE}$ é apresentada na Equação (3.27). Assim como o método BLUE, este estimador MLE pode ser implementado em processadores digitais através de um filtro FIR (do inglês, *Finite Impulse Response*) de ordem $N-1$ e coeficientes \mathbf{w} .

$$\hat{\theta}_{MLE} = \frac{\mathbf{x}^T \mathbf{C}^{-1} \mathbf{h}}{\mathbf{h}^T \mathbf{C}^{-1} \mathbf{h}} = \sum_{k=0}^{N-1} x[k] w[k] \quad (3.27)$$

Pode ser observado que, neste caso particular, $\hat{\theta}_{MLE} = \hat{\theta}_{BLUE}$ e os estimadores MLE e BLUE apresentam os mesmos conjuntos de pesos.

3.5 Estimação de Energia nos Calorímetros do ATLAS

Esta sessão apresenta as técnicas utilizadas atualmente pela colaboração ATLAS para estimação de energia em seus calorímetros. De forma geral, tanto o calorímetro eletromagnético quanto o hadrônico utilizam técnicas baseadas no BLUE, sendo denominadas no contexto da colaboração de Filtro Ótimo (*Optimal Filter* (OF)). Desta forma, inicialmente apresenta-se a formulação do OF para em seguida apresentar as especificidades de sua aplicação no LArg a no TileCal.

3.5.1 Filtro Ótimo

O algoritmo chamado de OF pode ser considerado como o método clássico utilizado nos sistemas de calorimetria do ATLAS para estimação de energia [47]. É uma técnica de minimização de variância que utiliza o conhecimento da forma do pulso (saída do circuito de conformação de sinal) para estimar a amplitude e fase do sinal e, em consequência, a energia depositada na célula do calorímetro [39].

A Equação (3.28) apresenta o modelo do problema de estimação utilizado pelo método OF

$$x[n] = Ah[n - \tau] + w[n], \quad (3.28)$$

onde $x[n]$ representa a amostra do sinal observado, $h[n]$ representa a amostra do pulso de referência do calorímetro, A é a amplitude do sinal que é proporcional a energia depositada, τ representa um desvio de fase para o sinal e referência e $w[n]$ o ruído aditivo. Esse desvio fase pode aparecer em alguns experimentos devido aos diferentes tempos de voo (*time of flight*) das partículas, fazendo com que o pico do sinal de referência não coincida com a amostra central da janela de observação.

Utilizando a expansão da série de Taylor de primeira ordem [47], pode-se obter uma aproximação linear para a fase do pulso, resultando em

$$x[n] = Ah[n] - A\tau h'[n] + w[n], \quad (3.29)$$

onde $h'[n]$ representa a amostra da derivada do sinal de referência em relação ao tempo. Em notação vetorial

$$\mathbf{x} = \mathbf{H}\boldsymbol{\theta} + \mathbf{w}, \quad (3.30)$$

onde

$$\boldsymbol{\theta} = \begin{bmatrix} \theta_1 \\ \theta_2 \end{bmatrix} = \begin{bmatrix} A \\ -A\tau \end{bmatrix} \quad (3.31)$$

e

$$\mathbf{H} = \begin{bmatrix} h[1] & h'[1] \\ \vdots & \vdots \\ h[N] & h'[N] \end{bmatrix}. \quad (3.32)$$

Dado o exposto, este problema recai em uma otimização BLUE Vetorial, que tem como solução [?]

$$\hat{\boldsymbol{\theta}} = (\mathbf{H}^T \mathbf{C}^{-1} \mathbf{H})^{-1} \mathbf{H}^T \mathbf{C}^{-1} \mathbf{x}, \quad (3.33)$$

onde \mathbf{C} é a matriz de covariância do ruído $w[n]$.

A amplitude estimada será dada por $\hat{A} = \theta_1$ e a fase pode ser estimada fazendo $\hat{\tau} = -\frac{\theta_2}{\theta_1}$, de acordo com a Equação (3.31) .

3.5.1.1 Estimação de energia no TileCal

Para implementação do OF no TileCal, o modelo para o sinal recebido é dado por

$$x[n] = Ah[n] - A\tau h'[n] + w[n] + ped \quad n = 1, 2, \dots, N, \quad (3.34)$$

onde $x[n]$ representa a amostra digital recebida no instante n e N corresponde ao número de amostras da janela de observação ($N = 7$ no caso do TileCal). A amplitude A é o parâmetro a ser estimado enquanto $w[n]$ representa o ruído aditivo de fundo; $h[n]$ e $h'[n]$ correspondem, respectivamente, às amostras do pulso de referência do TileCal e sua derivada, enquanto o parâmetro τ é o desvio de fase do sinal. A diferença em relação ao modelo de sinal apresentado em (3.29) é a inclusão do parâmetro ped , que representa a linha de base (pedestal) do sinal de referência.

Portanto, o vetor de parâmetros θ a ser estimado resulta em

$$\theta = \begin{bmatrix} \theta_1 \\ \theta_2 \\ \theta_3 \end{bmatrix} = \begin{bmatrix} A \\ -A\tau \\ ped \end{bmatrix} \quad (3.35)$$

e a matriz \mathbf{H} em

$$\mathbf{H} = \begin{bmatrix} h[1] & h'[1] & 1 \\ \vdots & \vdots & \vdots \\ h[N] & h'[N] & 1 \end{bmatrix}. \quad (3.36)$$

A Figura 3.2 ilustra o pulso de referência do TileCal amostrado a uma taxa de 40 MHz. Pode-se observar que o pulso fica contido em uma janela com $N = 7$ amostras que são utilizadas para estimação de energia.

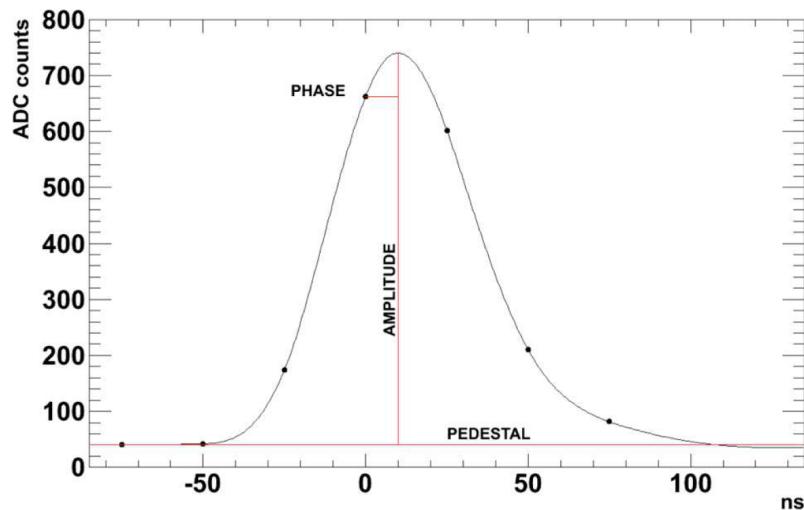


Figura 3.2: Pulso de Referência do TileCal [7]. Neste calorímetro, a janela de observação tem comprimento $N = 7$, contendo todo o pulso.

3.5.1.2 Estimação de energia LArg

Neste calorímetro, o método OF também é utilizado para estimativa de energia, utilizando o modelo de sinal descrito na Equação (3.29). A forma do pulso de resposta do LAr é mostrada na Figura 3.3, onde 32 amostras são necessárias para representar todo o pulso. Para a estimativa da energia, somente cinco amostras ($N = 5$), localizadas ao redor do pico, são utilizadas.

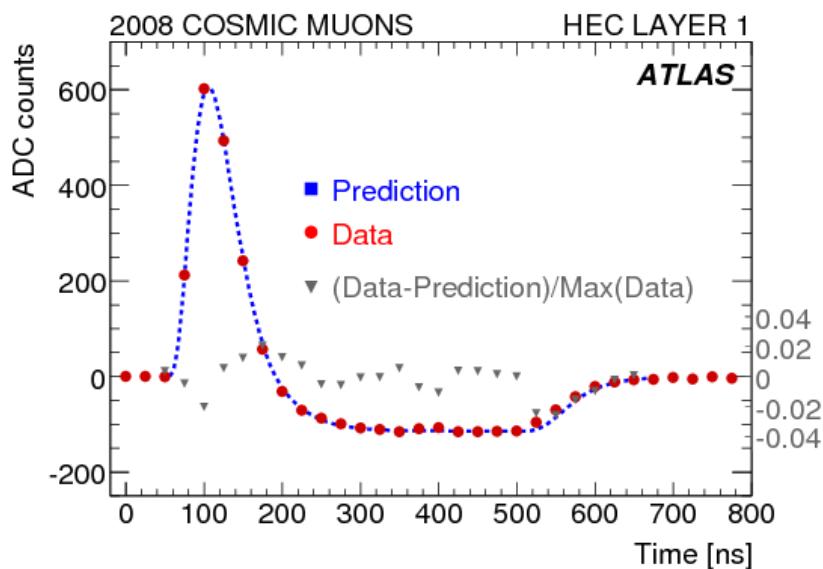


Figura 3.3: Resposta do calorímetro eletromagnético do ATLAS. As amostras digitais estão destacadas sobre a curva (extraído de [48]).

3.6 Estimação de Energia em Outros Experimentos

Existem outros experimentos em Física de Altas Energias que também utilizam algoritmos de estimativa de energia baseados na forma do pulso provenientes de seu sistema de calorimetria. O ZEUS, um exemplo disto, foi um detector de partículas que operou no acelerador de partículas HERA (Hadron Elektron Ring Anlage) em DESY, Hamburgo. Começou a funcionar junto com HERA em 1992 e concluiu sua operação em junho 2007.

Assim, como o experimento ATLAS no CERN, o ZEUS possui vários subdetectores, incluindo um calorímetro cintilador, que por sua vez, também possui um

algoritmo de reconstrução e estimação de energia baseado na forma do sinal entregue pela eletrônica de leitura do sistema de calorimetria [8].

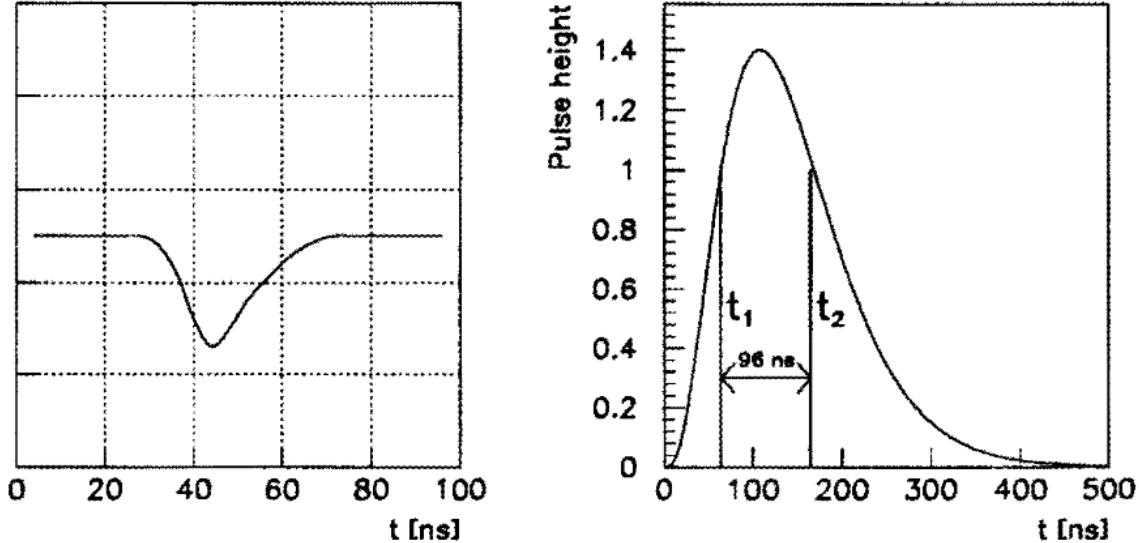


Figura 3.4: Forma do pulso utilizado no ZEUS. [8, 9]

No calorimetro do ZEUS, eram utilizadas três amostras h_i do sinal de referência. Uma das amostras, chamada de h_0 está situada na linha base do sinal e as outras duas amostras estão situadas em h_1 amostrada no tempo t_1 e h_2 amostrada no tempo t_2 , como mostrado a direita na Figura 3.4.

O método de reconstrução de energia tenta reconstruir a carga depositada no calorímetro através de uma aproximação de um pulso triangular em um curto intervalo de tempo. A carga estimada pode, então, ser estimada por

$$Q = (h_1 - h_0) + C_r(h_2 - h_0) = H_1 + C_rH_2, \quad (3.37)$$

onde C_r é definido como

$$C_r = \frac{\frac{dh}{dt}|_{t=t1}}{-\frac{dh}{dt}|_{t=t2}}. \quad (3.38)$$

3.7 Métodos de Estimação de Energia para Cenários de Empilhamento de Eventos

3.7.1 Método ManyAmps

Este método é baseado em um *fit* de amplitude múltipla e destina-se a lidar com sinais afetados pelo empilhamento. Ele realiza um *fit* para uma amplitude central na faixa de tempo central e várias amplitudes auxiliares em $t = \pm 25, \pm 50, \pm 75, \dots$ ns (para sinais provenientes dos *bunch-crossing* adjacentes). Estes *fittings* são rea-

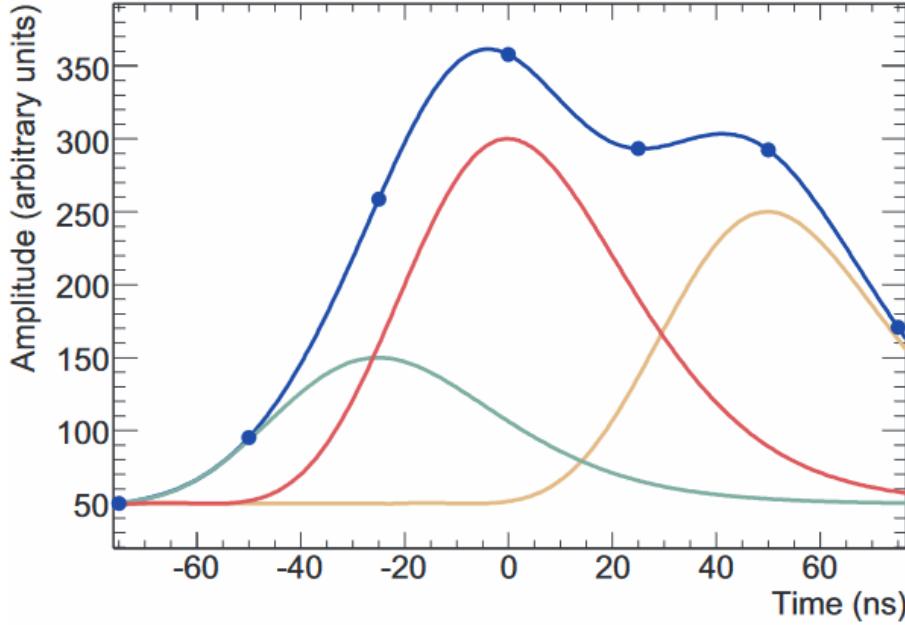


Figura 3.5: Exemplo de *fit* para amplitude múltipla com o método ManyAmps. As amostras e a forma total da forma são mostradas juntamente com as amplitudes individuais usadas para a reconstrução. [10]

lizados para várias amplitudes e um pedestal comum, com todos os tempos fixos, como mostrado na Figura 3.5, com um exemplo.

O procedimento começa pelo *fit* para a amplitude central e se o χ^2 resultante não for satisfatório, as amplitudes adicionais são adicionadas sucessivamente nos *bunch-crossing* com os resíduos mais altos até que um bom χ^2 seja alcançado. O resultado final da reconstrução inclui apenas a amplitude central e, ignorando todas as amplitudes adicionais utilizadas no procedimento [10].

3.7.2 COF - *Constrained Optimal Filter*

Para o caso de estimação de amplitude de sinais de calorímetros em colisionadores, pode-se considerar a deposição de energia em uma determinada região (célula) do detector como um impulso em um determinado BC. Portanto, o sinal resultante $x[n]$ pode ser modelado como

$$x[n] = Ah[n] + w[n], \quad (3.39)$$

onde $h[n]$ (pulso de referência) é a resposta ao impulso do sistema linear que representa um determinado canal do calorímetro, A é a amplitude do sinal a ser estimada e $w[n]$ é o ruído gaussiano proveniente da eletrônica de *front-end*. Neste modelo, não foram considerados desvios de fase do sinal e o pedestal é conhecido a priori.

Para incluir no problema de estimação os sinais adjacentes provenientes do empilhamento de sinais, pode-se formular o problema matricial

$$\hat{\mathbf{a}}_p = \mathbf{G}_p^T \mathbf{x}, \quad (3.40)$$

onde p é o número de sinais sobrepostos, $\hat{\mathbf{a}}_p$ é o vetor de amplitudes estimadas, \mathbf{x} são as amostras do sinal para uma célula do calorímetro e \mathbf{G}_p é a matriz de estimativa. Nesta formulação, o objetivo é estimar não somente a amplitude do sinal de interesse (a energia depositada em um determinado BC), mas também as amplitudes dos sinais de colisões adjacentes. Como os sinais empilhados, na formulação proposta, não são absorvidos pelo ruído, pode-se considerar a hipótese de ruído branco proveniente da eletrônica de condicionamento do calorímetro.

A matriz de estimativa \mathbf{G}_p pode ser derivada diretamente do método BLUE conforme apresentado na Equação (3.20).

$$\mathbf{G}_p = \mathbf{H}_p (\mathbf{H}_p^T \mathbf{H}_p)^{-1} \quad (3.41)$$

onde \mathbf{H}_p tem suas colunas formadas por pulsos de referência dos p sinais sobrepostos (sinal de referência deslocado), possuindo dimensão $N \times p$, com N representando tamanho da janela de observação utilizada para estimativa. A matriz de covariância do ruído não aparece em (3.41), pois o ruído eletrônico foi considerado branco. Esta equação é a base do *Constrained Optimal Filter* (COF) [49], onde \mathbf{G}_p é a pseudo-inversa de \mathbf{H}_p^T .

O matriz de estimativa apresentada em (3.41) requer o conhecimento de em quais BC encontram-se os sinais sobrepostos, informação que não é conhecida a priori. Adicionalmente, deve-se ressaltar que a matriz \mathbf{G}_p deve ter dimensão finita para que o problema tenha solução, sendo normalmente limitada pelo tamanho da janela de observação (comprimento N) utilizada para estimativa; portanto, a solução apresenta simplificações. Este problema é agravado para alto nível de empilhamento de sinais e quando a duração da resposta do calorímetro é lenta, já que o efeito dos sinais empilhados fora da janela de observação do sinal é mais acentuado do que em casos aonde o sinal é mais rápido e contido na janela.

Supondo um calorímetro cuja resposta ao impulso possa ser aproximada por um sinal com $W = N$ amostras, onde a janela de observação disponível para estimativa possui comprimento N e o período de amostragem é igual ao intervalo entre colisões, pode-se fazer $p = N$ para estimar a deposição de energia dos N BC. Desta forma, \mathbf{H}_p resulta em uma matriz quadrada \mathbf{H}_s de tamanho $N \times N$ que simplifica a Equação (3.41)

$$\mathbf{G}_s = \mathbf{H}_s^{T^{-1}}. \quad (3.42)$$

A matriz $\mathbf{H}_s^{T^{-1}}$ é nomeada como Matriz de Deconvolução, do inglês

Deconvolution Matrix (DM). Um patamar é aplicado ao vetor resultante da operação $\mathbf{G}_s \mathbf{x}$, a fim de detectar em quais BCs existe deposição relevante de energia. Após este pré-processamento, a matriz H_p do COF é devidamente determinada.

O COF com processamento por DM tem um desempenho satisfatório e superior ao OF no TileCal [49]. Devido a este aumento considerável de desempenho, está sendo avaliado durante o *Run 2* do LHC.

Capítulo 4

Estimação de Energia para Calorimetria Baseada em Representação Esparsa

Como já discutido nos capítulos anteriores, com o aumento da luminosidade do LHC, a estimação de energia para os calorímetros do ATLAS deve lidar com o problema do empilhamento de sinais. Este capítulo, apresenta novos algoritmos de estimação de energia para calorimetria baseado em representação esparsa.

4.1 Representação Esparsa para Estimação de Energia

Sem perda de generalização, podemos usar o problema da estimação de energia do LArg como base para o desenvolvimento do método proposto. Assim, pode-se definir um vetor \mathbf{h} que contém as $W = 32$ amostras do sinal de referência do LArg

$$\mathbf{h} = [h_{-2} \ h_{-1} \ h_0 \ h_1 \ \dots \ h_{29}]^T \quad (4.1)$$

onde h_0 corresponde à posição do pico do sinal (ver Figura 2.8) e ao *bunch crossing* de interesse. Pode-se definir a matriz \mathbf{H} , chamada de matriz de convolução, cujas colunas são versões deslocadas do sinal de referência \mathbf{h} , limitadas a janela de observação de N amostras. No caso do LArg, $N = 5$ e por esta razão \mathbf{H} terá 5 linhas e $32 + 5 - 1 = 36$ colunas.

$$\mathbf{H} = \begin{pmatrix} \mathbf{0} & h_{-2} & \dots & h_{25} & \dots & h_{29} \\ \ddots & \vdots & & \vdots & \ddots & \\ h_{-2} & \dots & h_2 & \dots & h_{29} & \mathbf{0} \end{pmatrix}. \quad (4.2)$$

Deve-se ressaltar que a matriz \mathbf{H}_p na Equação (3.41) é uma versão truncada da matriz de convolução \mathbf{H} . Para o caso do LArg, caso exista deposição de energia nos cinco BC contidos na janela de observação ($N = 5$), $\mathbf{H}_p = \mathbf{H}_5$ terá dimensão 5×5 .

Considerando um caso ideal em que o sinal recebido não tem ruído, uma representação linear do sinal recebido \mathbf{x} é dada por

$$\mathbf{x} = \mathbf{Ha}, \quad (4.3)$$

onde \mathbf{x} possui $N = 5$ amostras e \mathbf{a} representa o vetor a ser estimada, contendo as amplitudes dos 36 sinais ($p = N + W - 1$). Ou seja, neste problema, pretende-se estimar a amplitude de 36 sinais utilizando apenas as 5 amostras da janela de observação do sinal. A Equação (4.3) é um sistema indeterminado e apresenta infinitas soluções possíveis para o vetor estimado $\hat{\mathbf{a}}$. Assim, deve-se determinar uma função objetiva a fim de definir um critério para a escolha da solução mais adequada. Uma abordagem comum em processamento de sinais é a seleção do vetor \mathbf{a} com a menor norma euclidiana $\|\mathbf{a}\|_2^2$, definida como norma- l_2 . Esta regra estabelece o seguinte problema de otimização

$$\begin{array}{ll} \text{minimizar} & \|\mathbf{a}\|_2^2 \\ \text{sujeito a} & \mathbf{x} = \mathbf{Ha} \end{array} \quad (4.4)$$

conduzindo a um problema estritamente convexo com uma solução única, conhecida como a solução de Mínimos Quadrados, do Inglês *Least Square* (LS) [43]

$$\hat{\mathbf{a}} = \mathbf{H}^T (\mathbf{HH}^T)^{-1} \mathbf{x}. \quad (4.5)$$

O método LS é muito usado em processamento de sinais aleatórios devido à sua simplicidade de projeto e sua forte correlação com o Filtro de Wiener [50]. Entretanto, esta abordagem tende a espalhar a energia entre os componentes resultantes, polarizando negativamente a solução. Desta forma, ao se utilizar esta solução para identificação de em quais BC ocorreram deposição de energia, pode ocorrer um falso alarme em BC próximos aos BC com sinal. Portanto, em vez de minimizar uma função de custo quadrática, é proposto nesta tese a busca da configuração de sinais mais esparsa possível para a reconstrução do sinal adquirido. Desta forma, esta abordagem considera sinais mais distantes do BC central.

Esta proposta conduz à Representação Esparsa, do inglês *Sparse Representation* (SR), de sistemas indeterminados de equações. SR tem sido motor central de muitos projetos de processamento de sinais, como compressão de dados e separação de fontes independentes, que recentemente tem sido explorado em profundidade.

Atualmente o SR tornou-se um campo de pesquisa próprio [51] e vários algoritmos competitivos estão sendo propostos na literatura. Um dos algoritmos que apresenta melhor desempenho para SR baseia-se na teoria de programação linear (*Linear Programming* (LP)) [52], a qual será utilizada nesta tese como algoritmo básico. Entretanto, serão também avaliados outros métodos que buscam esparsidade, mais eficientes computacionalmente do que a técnica baseada em LP, visando a estimativa *on-line* de energia no LArg.

4.1.1 Representação Esparsa sem Ruído

Modificando a norma- l_2 da Equação (4.4) para um problema genérico de norma- l_q

$$\begin{array}{ll} \text{minimizar}_{\mathbf{a}} & \|\mathbf{a}\|_q^q \\ \text{sujeito a} & \mathbf{x} = \mathbf{H}\mathbf{a} \end{array} \quad (4.6)$$

e lembrando que

$$\|\mathbf{a}\|_q^q = \sum_{i=1}^p |A_i|^q, \quad (4.7)$$

pode-se mostrar que, quanto menor o valor de q , mais esparsa é a solução, ou seja, maior é a quantidade de elementos nulos em \mathbf{a} [51]. Sendo assim, a solução mais esparsa, encontra-se no limite para $q \rightarrow 0$. Contudo, para $q < 1$ o problema da Equação (4.6) não é mais convexo e não é solucionável com teorias de otimização regulares. Portanto, a solução mais esparsa para \mathbf{a} , na Equação (4.3), é aproximada utilizando a norma- l_1 , resultando em

$$\begin{array}{ll} \text{minimizar}_{\mathbf{a}} & \|\mathbf{a}\|_1^1 \\ \text{sujeito a} & \mathbf{x} = \mathbf{H}\mathbf{a}. \end{array} \quad (4.8)$$

Por outro lado, a descontinuidade da norma- l_1 pode ser evitada desmembrando-se o vetor \mathbf{a} em dois vetores, \mathbf{u} e \mathbf{v} , contendo apenas os elementos positivos e negativos de \mathbf{a} respectivamente. Neste passo, o problema da Equação (4.6), para $q = 1$, pode ser modificado como a seguir.

Tomando-se \mathbf{a} como uma combinação de dois vetores ($\mathbf{a} = \mathbf{u} - \mathbf{v}$), onde \mathbf{u} contém os valores positivos de \mathbf{a} e zero para os outros elementos. Da mesma forma, \mathbf{v} contém os valores negativos de \mathbf{a} e zero para os outros elementos. Concatenando o vetores \mathbf{u} e \mathbf{v} em um vetor \mathbf{z} de tamanho duas vezes o tamanho do vetor \mathbf{a} , compreendendo apenas elementos não negativos, o modelo linear da Equação (4.3)

poderá ser redefinido como

$$\mathbf{x} = \mathbf{H}^\dagger \mathbf{z} \quad (4.9)$$

onde $\mathbf{H}^\dagger = [\mathbf{H} \quad -\mathbf{H}]$. A norma- l_1 pode então ser reescrita como

$$\begin{array}{ll} \text{minimizar}_{\mathbf{z}} & \mathbf{1}' \mathbf{z} \\ \text{sujeito a} & \left\{ \begin{array}{l} \mathbf{x} = \mathbf{H}^\dagger \mathbf{z} \\ \mathbf{z} \geq \mathbf{0} \end{array} \right. \end{array} \quad (4.10)$$

onde $\mathbf{1}$ representa um vetor cujos elementos são iguais a um.

Este problema de otimização representa uma função objetiva linear com restrições também lineares, resultando em um problema de LP que pode ser solucionado utilizando várias classes de algoritmos conhecidos [52].

Para ilustrar o uso do algoritmo proposto, a Figura 4.1 mostra a sobreposição de dois sinais do LArg deslocados, representando um *pile-up* de sinais localizado em dois BC diferentes. Ambos os sinais e o sinal obtido da sobreposição são mostrados, junto com as $N = 5$ amostras (vetor \mathbf{x}) observadas para estimativa da energia no LArg.

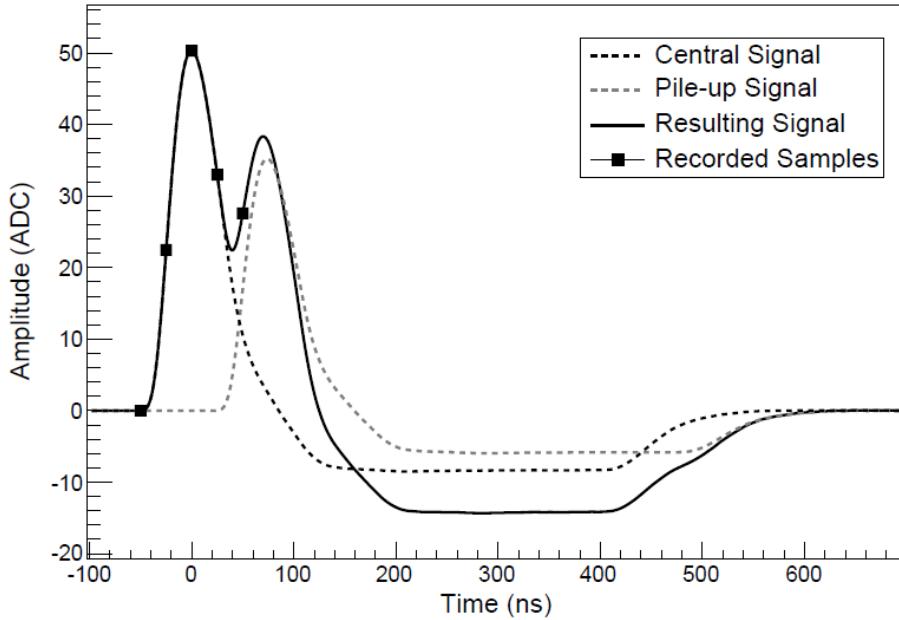


Figura 4.1: Exemplo de *pile-up* de dois sinais em dois *bunch-crossing* diferentes.

Na Figura 4.2, é mostrado o vetor de componentes $\hat{\mathbf{a}}$ recuperado para os métodos LS (Equação (4.5)) e para o SR (Equação (4.10)), quando aplicados as cinco

amostras observadas do sinal ilustrado na Figura 4.1. Como se vê, o LS tende a espalhar a energia sobre as componentes adjacentes levando a um erro na recuperação das componentes. Por outro lado, o método proposto, baseado em representação esparsa recupera corretamente a localização dos sinais sobrepostos, fornecendo uma estimativa mais precisa da amplitude dos componentes não-nulos.

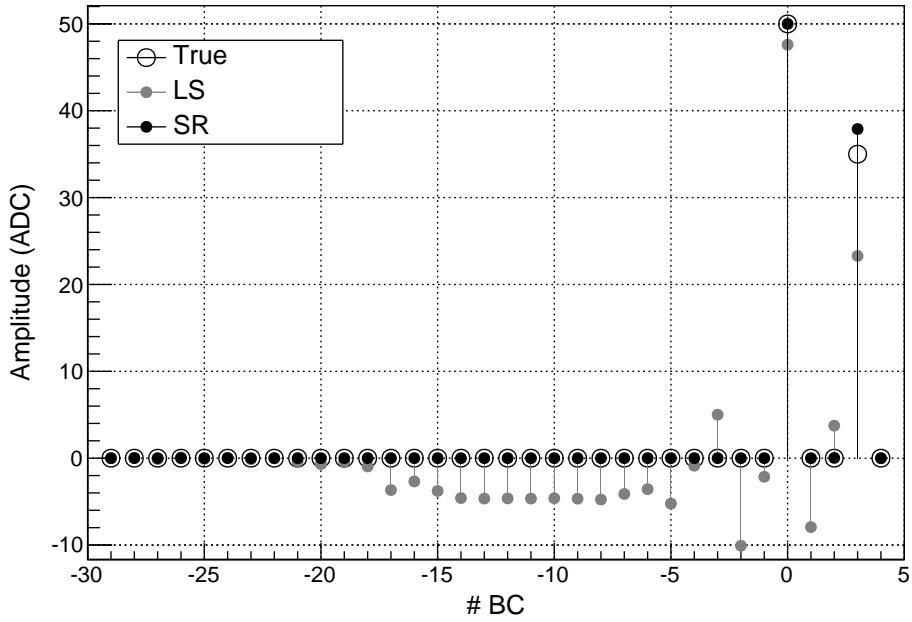


Figura 4.2: Componentes recuperadas utilizando LS e SR

4.1.2 Representação Esparsa com Ruído

Na presença de ruído, a restrição de igualdade na Equação (4.9) pode ser relaxada, admitindo-se um pequeno erro em relação a solução ideal.

$$-\mathbf{e} < \mathbf{H}^\dagger \mathbf{z} - \mathbf{x} < \mathbf{e} \quad (4.11)$$

Desta forma, o problema de otimização deve ser atualizado para trabalhar com a inequação (4.11). A fim de permitir um desvio diferente para cada componente recuperada em $\hat{\mathbf{a}}$, o resíduo $\mathbf{H}^\dagger \mathbf{z} - \mathbf{x}$ pode ser projetado na matriz \mathbf{H} sem perda de generalização.

$$-\mathbf{e} < \mathbf{H}^T (\mathbf{H}^\dagger \mathbf{z} - \mathbf{x}) < \mathbf{e} \quad (4.12)$$

Do exposto, extrai-se que o vetor \mathbf{e} tem comprimento p . Outra interpretação para a Equação (4.12), conforme [53], é que a correlação entre o resíduo e cada componente do sinal da matriz \mathbf{H} deve ser menor do que um determinado limiar \mathbf{e} . Isso garante que o resíduo restante não tenha nenhuma componente dos sinais

de interesse. Essa técnica é conhecida como *Dantzig-Selector Algorithm* (DS), nomeado como homenagem ao criador do método *Simplex* para o LP [54]. O valor de \mathbf{e} pode ser encontrado experimentalmente, sendo dependente das fontes de ruído. No problema em questão, as diversas fontes de ruído como a eletrônica, sinais de empilhamento de baixa amplitude e *cross-talk*, desvio de fase no pulso de referência, saturação e etc, são incorporados ao \mathbf{e} . O problema de otimização LP resultante será então:

$$\begin{array}{ll} \text{minimizar}_{\mathbf{z}} & \mathbf{1}^T \mathbf{z} \\ \text{sujeito a} & \left\{ \begin{array}{l} \mathbf{H}^T \mathbf{H}^\dagger \mathbf{z} < \mathbf{H}^T \mathbf{x} + \mathbf{e} \\ \mathbf{H}^T \mathbf{H}^\dagger \mathbf{z} < \mathbf{H}^T \mathbf{x} - \mathbf{e} \\ \mathbf{z} \geq \mathbf{0} \end{array} \right. \end{array} \quad (4.13)$$

Na aplicação em calorimetria, o vetor \mathbf{a} apresenta apenas valores positivos referentes às amplitudes do sinais sobrepostos que compõem o sinal de entrada \mathbf{x} . Desta forma, é proposta nesta tese, uma modificação no algoritmo *Dantzig-Selector* de modo a dar maior ponderação para reconstrução de amplitudes positivas. Isto pode ser realizado adicionando um multiplicador $k > 1$ para os componentes do vector \mathbf{v} na função objetiva.

Finalmente, implementadas as modificações, o procedimento LP proposto nesta tese resulta em

$$\begin{array}{ll} \text{minimizar}_{\mathbf{z} = [\mathbf{u} \ \mathbf{v}]} & \mathbf{1}^T \mathbf{u} + k \mathbf{1}^T \mathbf{v} \\ \text{sujeito à} & \left\{ \begin{array}{l} \mathbf{H}^T \mathbf{H}^\dagger \mathbf{z} < \mathbf{H}^T \mathbf{x} + \mathbf{e} \\ \mathbf{H}^T \mathbf{H}^\dagger \mathbf{z} < \mathbf{H}^T \mathbf{x} - \mathbf{e} \\ \mathbf{z} \geq \mathbf{0} \\ k > 1 \end{array} \right. \end{array} \quad (4.14)$$

Do exposto, pode-se observar que o algoritmo implementando é baseado em [55], que é uma variante do algoritmo de correlator-preditor proposto em [56], baseado no método de Ponto Interior primal-dual (IP) [57]. Os valores de k e \mathbf{e} devem ser obtidos experimentalmente.

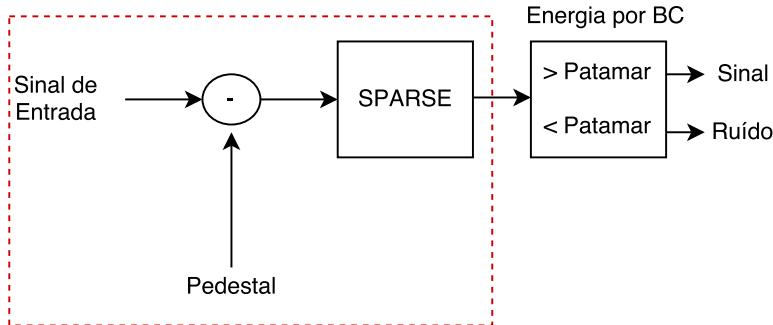


Figura 4.3: Diagrama em blocos exemplificando o processo de estimação de energia pelo algoritmo SPARSE.

4.2 Propostas para Estimação de Energia para Calorimetria Baseado em Representação Esparsa (SPARSE e SPARSE-COF)

A seção anterior apresentou o desenvolvimento teórico do método proposto baseado em representação esparsa. Esta seção apresenta a descrição de duas opções para utilização da representação esparsa que serão avaliadas nesta tese.

Inicialmente, é definido um modelo para o sinal do calorímetro conforme (3.39), salientando novamente que nesse modelo não são considerados desvios na fase do sinal de referência do calorímetro e o pedestal é considerado conhecido.

Em seguida, deve-se resolver (4.14) para chegar as estimativas da amplitude do sinal para os $p = N + W - 1$ bunch crossings, onde N é número de amostras contidas na janela de observação e W é o número de amostras do sinal de referência. Este método é ilustrado em um diagrama em blocos na Figura 4.3, sendo chamado, nesta tese, de SPARSE.

Entretanto, pode-se combinar o SPARSE ao COF visando melhorar a estimativa realizada pelo SPARSE para os BC com energia relevante contidos dentro da janela de observação, em cenários aonde o empilhamento de sinais não é tão elevado. Portanto, o SPARSE pode ser utilizado para identificação de em quais BC ocorreram deposição de energia de forma a possibilitar a utilização do COF através da montagem da matriz \mathbf{H}_p e da obtenção da matriz de estimativa (3.20). A Figura 4.4 ilustra este método, denominado, nesta tese, de SPARSE-COF.

4.3 Outros Métodos Esparsos

Os outros métodos esparsos menos robustos, serão abordados nessa seção. Tais métodos que não utilizam LP serão comparados com aos métodos esparsos que utilizam programação linear, visando opções para implementação *on-line* no LArg.

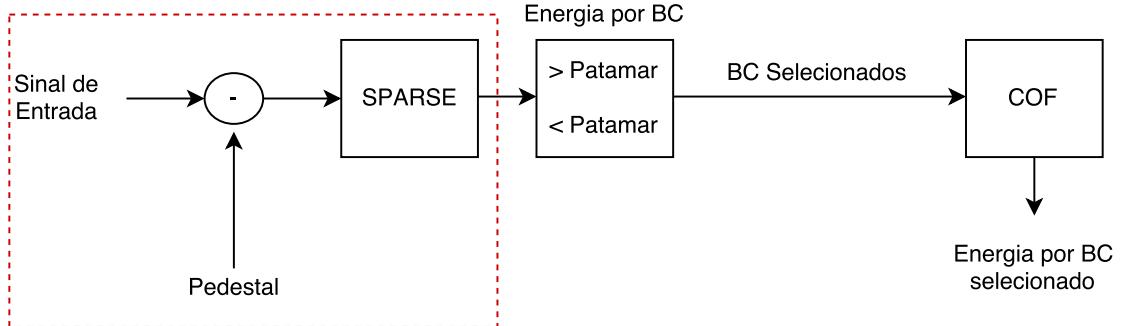


Figura 4.4: Diagrama em blocos exemplificando o processo de estimação de energia pelo algoritmo SPARSE-COF.

Os métodos que não utilizam LP são computacionalmente menos complexos e podem ser bons candidatos implementados em *hardware*.

4.3.1 Algorítimos de *Greedy* ou *Pursuit*

Os algorítimos de ganância (do inglês, *Greedy*), também conhecido como algorítimos de busca (do inglês, *Pursuit*), têm como objetivo encontrar a solução, de modo iterativo, da equação

$$(P_0) : \min_{\mathbf{x}} \|\mathbf{x}\|_0 \quad \text{sujeito à} \quad \mathbf{b} = \mathbf{Sx}.$$

onde \mathbf{S} é uma matriz de suporte com colunas escolhidas de uma dada matriz \mathbf{A} . De modo iterativo, procura-se encontrar a melhor composição de \mathbf{S} com o objetivo de minimizar a energia residual $\|\mathbf{r}\|_2^2 < \epsilon_0$ de uma dada entrada \mathbf{b} , sendo ϵ_0 o patamar de parada para o método iterativo e $\mathbf{r} = \mathbf{b} - \mathbf{Sx}$. Nesta técnica, a cada iteração uma coluna de \mathbf{A} é inserida no Suporte \mathbf{S} . Para isso, é escolhida a coluna de \mathbf{A} que mais reduz a energia do resíduo a cada iteração. Desta forma, a menor quantidade de sinais é inserida, chegando-se a solução mais esparsa possível.

Dentre estes algoritmos, dois deles se destacam, o *Orthogonal-Matching-Pursuit* (OMP) e o *Least-Square Orthogonal-Matching-Pursuit* (LS-OMP) [?]. O que difere uma técnica da outra é o método de varredura (do inglês, *Sweep*) na parte iterativa, visando a melhor escolha das colunas da matriz \mathbf{A} afim de compor o vetor de suporte \mathbf{S} .

O OMP utiliza um casamento direto do resíduo \mathbf{r} com a k -ésima coluna da matriz \mathbf{A} e seleciona a coluna que tem maior correlação com o resíduo

$$\mathbf{S}_k = \max(\mathbf{A}_k^T \mathbf{r}),$$

onde inicialmente $\mathbf{r} = \mathbf{b}$. Nas iterações seguintes, calcula-se o resíduo como demonstrado anterior, aonde k é o índice da coluna e \mathbf{S}_k receberá a coluna que retornar o

maior valor de energia do produto interno entre \mathbf{A}_k e \mathbf{r} .

No método de varredura do LS-OMP, a amplitude de cada componente x_k do suporte é atualizada a cada iteração, resolvendo o sistema $\mathbf{Sx} = \mathbf{b}$ através do método do Least-Square. Isto é equivalente a usar o estimador BLUE da Equação (3.41) com os p sinais já incluídos no suporte. Com esta atualização do vetor \mathbf{x} a cada passo, o resíduo entre os sinais já sobrepostos e o vetor \mathbf{b} tem um cálculo mais preciso, levando a um melhor desempenho. Vale a pena ressaltar a estreita relação entre este método e o COF, posto que a cada iteração, um novo sinal é incluído e a equação do COF é aplicada de forma a re-estimar as amplitudes dos sinais sobrepostos.

4.3.2 IRLS

O algoritmo Iterative-Reweighed-Least-Squares (IRLS) [?] é muito semelhante ao modo como funcionam os algoritmos de ganância abordados na seção anterior. Observa-se que, embora a ideia central seja semelhante, a derivação aqui é um tanto diferente.

Tomando $\mathbf{X} = \text{diag}(|\mathbf{x}|)$, temos que $\|\mathbf{x}\|_1 = \mathbf{x}^T \mathbf{X}^{-1} \mathbf{x}$. Assim, podemos ver a *norma* $-l_1$ como uma versão ponderada e adaptativa da norma quadrada *norma* $-l_2$.

Dada uma solução aproximada \mathbf{x}_{k-1} , onde $\mathbf{X}_{k-1} = \text{diag}(|\mathbf{x}_{k-1}|)$, pode-se tentar minimizar iterativamente a função custo dada por

$$\lambda \mathbf{x}^T \mathbf{X}_{k-1}^{-1} \mathbf{x} + \frac{1}{2} \|\mathbf{b} - \mathbf{Ax}\|_2^2. \quad (4.15)$$

Esta função custo tem dois termos. O primeiro termo é a *norma* $-l_1$ e é responsável por manter a esparsidade da solução. O segundo termo é responsável por manter a restrição primordial $\mathbf{Ax} = \mathbf{b}$ mais próxima possível da ideal. Um peso λ é utilizado para se ponderar entre reforçar a esparcidez ou a restrição primordial no processo de otimização. No método IRLS, este peso deve ser determinado experimentalmente. Trata-se de um problema de otimização quadrático e pode ser solucionado com álgebra linear padrão. Esta pode ser considerada como apenas um das múltiplas iterações que deverão seguir até a obtenção de um resultado satisfatório, que corresponde a não se perceber mais diferença significativa na diagonal das matrizes \mathbf{X}_k e \mathbf{X}_{k-1} .

Portanto, este algoritmo, assim como os algoritmos de ganância, precisa de um regra de parada, onde chega-se em um resultado com o menor erro aceitável.

4.4 Esparsidade e Unicidade

Por todo o exposto para o problema central, o qual é a determinação da solução mais esparsa para um sistema linear indeterminado $\mathbf{Ax} = \mathbf{b}$, podem-se levantar as

seguintes questões: quando a solução esparsa pode ser considerada como única? um candidato pode ser testado de modo a verificar sua otimização?

Para tentar responder a estas questões, inicialmente, considere o caso de um sistema indeterminado homogêneo $\mathbf{Ax} = \mathbf{0}$. A solução mais esparsa é aquela que combina a menor quantidade de colunas linearmente dependentes de \mathbf{A} a fim de se anular o resultado. Como um exemplo simples, suponha que \mathbf{A} tenha duas colunas iguais, mas de sinais contrários. A solução mais esparsa para o sistema homogêneo é aquela com valores igual a unidade nos índices do vetor \mathbf{x} correspondentes à posição das respectivas colunas na matriz \mathbf{A} . Portanto, para o caso homogêneo, a solução mais esparsa deve ter um número de elementos, a saber $\|\mathbf{x}\|_0$, igual ao menor número de colunas linearmente dependentes em \mathbf{A} . A essa característica, dá-se o nome de *Spark* [51].

Portanto, o *Spark*(\mathbf{A}) é um número inteiro não negativo que representa a menor quantidade de colunas linearmente dependentes da matriz \mathbf{A} . Pode-se denominar o *Spark* como sendo o oposto do *Rank* de uma matriz, sendo este último, o maior número de colunas linearmente independentes da mesma.

Segundo agora este raciocínio para o caso mais geral $\mathbf{Ax} = \mathbf{b}$ com esparsidade $\|\mathbf{x}\|_0$, suponha que outra solução $\mathbf{Ay} = \mathbf{b}$ com esparsidade $\|\mathbf{y}\|_0$ seja também possível. Isto implica que $\mathbf{A}(\mathbf{x} - \mathbf{y}) = \mathbf{0}$ é uma solução homogênea para este sistema e, portanto, com o menor número de elementos possível (não superior a *Spark*(\mathbf{A})). Dessa forma,

$$\|\mathbf{x}\|_0 + \|\mathbf{y}\|_0 \geq \text{Spark}(\mathbf{A}), \quad (4.16)$$

sendo ambas as soluções esparsas, o número de elementos deve ser o mesmo, ou seja, $\|\mathbf{x}\|_0 = \|\mathbf{y}\|_0$. Assim, temos $\|\mathbf{x}\|_0 < \text{Spark}(\mathbf{A})/2$. Portanto, se esta condição for atendida, pode-se garantir que encontrou-se a solução mais esparsa possível. Nota-se, porém, que se o número de elementos da solução for igual ou superior a $\text{Spark}(\mathbf{A})/2$, ainda assim a mesma pode ser a mais esparsa. O critério acima apenas determina um limite inferior.

Apesar de o *Spark* de uma matriz ser uma característica intimamente relacionada à esparsidade, sua obtenção, quando possível, é de grande custo computacional. Isto porque a mesma requer uma varredura de todos os possíveis grupos de colunas de \mathbf{A} , procurando por sub-grupos de colunas linearmente dependentes. Isto equivale a uma análise combinatória de complexidade exponencial ao o número de colunas da matriz. Assim, métodos alternativos para garantir esparsidade são de interesse. Dentre eles, o utilizado neste trabalho é o método baseado na Coerência Mútua de \mathbf{A} [?]. Simples de calcular, a Coerência Mútua $\mu(A)$ é o maior índice de correlação

entre diferentes colunas de \mathbf{A}

$$\mu(\mathbf{A}) = \max_{1 \leq i, j \leq m, i \neq j} \frac{|\mathbf{a}_i^T \mathbf{a}_j|}{\|\mathbf{a}_i\|_2 \cdot \|\mathbf{a}_j\|_2}. \quad (4.17)$$

Para compreender esta técnica, é conveniente normalizar-se todas as colunas de \mathbf{A} pela sua norma quadrática de modo que a diagonal de $\mathbf{A}^T \mathbf{A}$ tenha todos os elementos iguais a um. Nota-se que isto não modifica nem o *Rank* nem o *Spark* da matriz. Com esta normalização, é possível utilizar a Coerência Mútua para determinar um limite inferior para o número de colunas linearmente dependentes. O ponto principal nesta técnica, cuja prova é dada pelo *Teorema de Disco de Gershgorin* [51], diz que dado um conjunto com p colunas de \mathbf{A} que são linearmente dependentes, a seguinte inequação $1 > (p-1)\mu(\mathbf{A})$ se apresenta, envolvendo p e a Coerência Mútua $\mu(\mathbf{A})$. Esta inequação mostra que quanto maior o número de elementos linearmente dependentes em \mathbf{A} , menor deve ser o valor da Coerência Mútua.

Tomemos o caso de duas colunas iguais, por exemplo. $\mu(\mathbf{A}) = 1$ neste caso é máximo, e pelo limite imposto por esse teorema, temos que $p = 2$ como esperado. Portanto, $p = 1 + 1/\mu(\mathbf{A})$ pode ser usado como um limite inferior para o número de colunas linearmente dependentes em \mathbf{A} . Em resumo, pode-se garantir que se a esparcidez da solução homogênea encontrada for menor que $1 + 1/\mu(\mathbf{A})$ tal solução é necessariamente a mais esparsa.

Para o caso geral, este valor deve então ser dividido por dois, como no critério usando o *Spark* da matriz. Da mesma forma que o uso do *Spark*, um valor superior aqui não garante a não-esparcidez. Além disso, o critério baseado no *Spark* apresenta um limite superior ao utilizado pela Coerência Mútua, sendo portanto uma melhor solução para rejeitar a hipótese de não-esparcidez. Porém, devido à diferença de complexidade considerável entre as técnicas, o critério baseado em Coerência Mútua é o mais utilizado na prática.

O teste de esparcidez para uma dada solução encontrada nos capítulos subsequentes deste trabalho pode ser enunciado como: se um sistema de equações lineares $\mathbf{Ax} = \mathbf{b}$ tem uma solução \mathbf{x} obedecendo $\|\mathbf{x}\|_0 < \frac{1}{2}(1 + 1/\mu(\mathbf{A}))$, está é necessariamente a mais esparsa possível.

Capítulo 5

Avaliação da Estimação de Energia Baseada em Representação Esparsa

Com o objetivo de realizar testes de desempenho e comparação entre os métodos de estimação descritos nos capítulos anteriores, foi desenvolvido um ambiente de simulação que sintetiza sinais com as características encontradas na eletrônica de leitura dos canais dos sistemas calorimetria utilizados em física de altas energias.

O objetivo central deste capítulo é quantificar o desempenho dos métodos esparsos do ponto de vista da qualidade da estimação da amplitude dos sinais sintéticos em um ambiente com níveis de empilhamento de sinais controlados. O ambiente de simulação, bem como os principais resultados destas análises, são descritos neste capítulo.

Neste capítulo, as técnicas baseadas em representação esparsa (SPARSE e SPARSE-COF) utilizam LP, já que pretende-se avaliar o que a representação esparsa pode trazer de ganho no processo de estimação de energia em calorimetria.

Como base de comparação para os métodos esparsos, serão utilizados os métodos OF, muito utilizado no ATLAS, e DM-COF, que utiliza a matriz de deconvolução para identificar sinais empilhados.

5.1 Simulação

Para avaliar os métodos de estimação de energia baseados em representação esparsa e compará-los com o OF e o DM-COF, foi criada uma simulação de amostras de um sinal proveniente de um calorímetro referente a uma única célula.

Inicialmente, foi criado um vetor com 1.000.000 (um milhão) de elementos, que representam uma sequência com a informação da deposição de energia em cada

colisão (BC) sendo preenchido aleatoriamente com uma dada ocupância. Em um extremo, 0% de ocupação significa que não houve deposição de energia neste canal do calorímetro. No outro extremo, uma ocupação de 100% significa que a cada BC ocorreu uma deposição de energia no canal.

Para o BC não-vazio, uma distribuição exponencial com valor médio $\mu_{pile-up} = 80$ MeV foi utilizada para simular a deposição de energia proveniente de eventos de sinais empilhados. Esses são valores de energia são típicos de presença ruído de empilhamento de sinais em experimentos que sofrem muito com o problema de *pileup*, por exemplo, nos principais experimentos do LHC [58, 59].

Centralizados nestes BCs, os sinais de referência do calorímetro, são sobrepostos, gerando o efeito de ruído acumulado, isto é, o ruído de *pileup*.

Para esta simulação, foram gerados dois sinais de referência provenientes de um circuito conformador RC-CR. Através do ajuste dos valores de R e C, diferentes sinais foram gerados:

- um sinal bipolar, com duração aproximada de 500 ns, simulado com uma amostragem de 40 MHz. Neste caso, a janela de observação considera apenas a parte positiva do pulso;
- um sinal unipolar, com duração aproximada de 200 ns, simulado com uma amostragem de 60 MHz. Neste caso, a janela de observação compreende todo o pulso do calorímetro;

simulando diferentes calorímetros em diferentes colisionadores. Em ambos os casos, a frequência de amostragem é considerada igual a frequência do *bunch-crossing*. A Figura 5.1 ilustra os dois sinais de referência simulados, com as amostras utilizadas para estimação destacadas.

Antes da sobreposição dos sinais ao vetor de BC, uma deformação é aplicada a cada amostra, para isso, os valores de deformação são retirados de uma distribuição normal com $\sigma = 1\%$. Também é adicionado ao sinal um desvio de fase aleatório com distribuição uniforme entre $[-1, +1]$ ns, simulando diferentes tempos de voo das partículas.

Depois deste passo, um ruído *White Gaussian Noise* (WGN) de 20 MeV [58] é adicionado, simulando o ruído da eletrônica de *front-end* dos calorímetros.

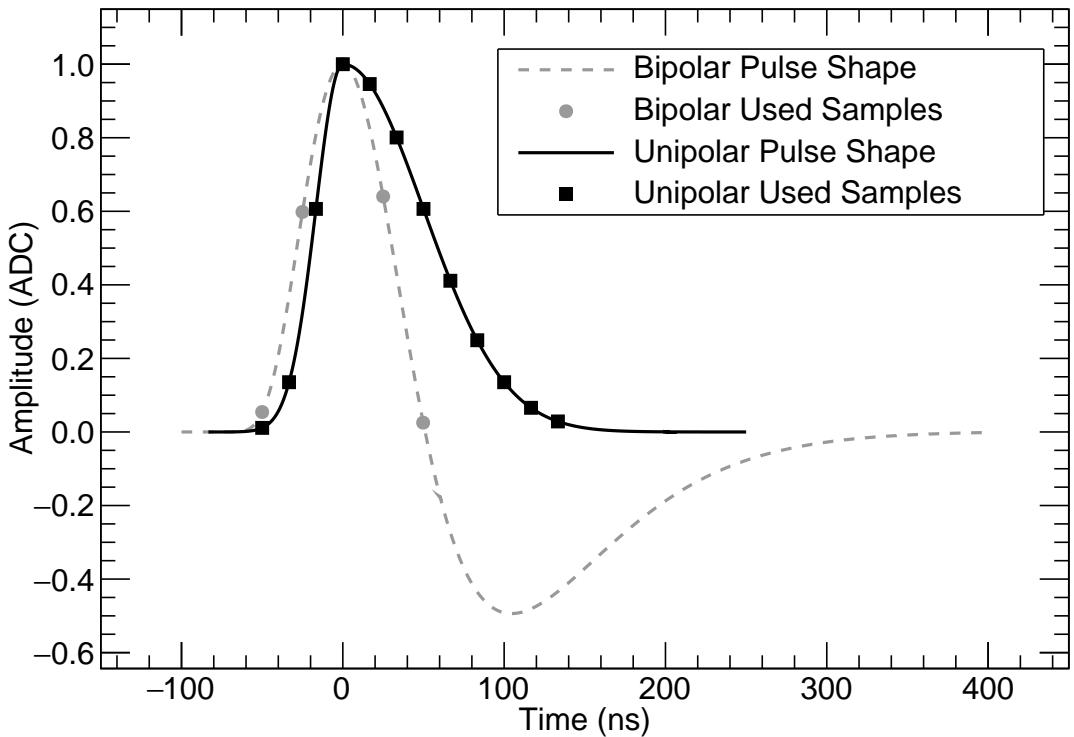


Figura 5.1: Forma dos pulsos de referência nos sinais utilizados na simulação. As amostras centrais do sinal ($W = 5$ e $W = 12$ para o bipolar e unipolar, respectivamente) estão em destaque.

Em seguida, o conjunto de dados é dividido em janelas de W amostras ($W = 5$ para o pulso bipolar e $w = 12$ para o pulso unipolar), referente ao tamanho da janela de observação utilizada para estimativa de energia. As janelas resultantes são divididas em dois conjuntos, metade para formar o **Conjunto de Ruído** e a outra metade para o **Conjunto de Sinal**.

Para gerar o **Conjunto de Sinal**, é adicionado um sinal central com deformação e desvio de fase, seguindo as distribuições indicadas anteriormente, correspondente ao sinal do BC de interesse cuja amplitude deseja-se estimar. Para esses sinais, a amplitude segue uma distribuição exponencial com um dado μ_{sinal} . Desta forma, dependendo do μ_{sinal} , podem-se gerar diferentes bancos de Sinal. Quanto menor o valor do μ_{sinal} em relação ao $\mu_{pile-up}$, mais difícil torna-se a estimativa da amplitude do sinal de interesse. Desta forma, nesta tese, foi criado o conceito da relação Sinal-Pulse-up. Esta relação, denominada de *SPR*, é obtida de acordo com

$$SPR = \frac{\mu_{sinal}}{\mu_{pile-up}}, \quad (5.1)$$

onde μ_{sinal} e $\mu_{pile-up}$ são valores médios da distribuição exponencial das amplitudes do sinal central e dos sinais de *pile-up*, respectivamente.

Adicionalmente, o conjunto de dados foi igualmente dividido em dois: o **Conjunto de Desenvolvimento**, que é usado para o desenvolvimento dos algoritmos de estimação e o **Conjunto de Teste**, a partir do qual é avaliado desempenho dos métodos de estimação.

5.2 Resultados e Análises

Nesta seção, diversos resultados da aplicação dos métodos para as simulações desenvolvidas são apresentados. O objetivo aqui é avaliar o desempenho dos métodos esparsos e apresentar algumas de suas características.

5.2.1 Considerações Sobre o Projeto dos Métodos SPARSE

Para projeto dos métodos SPARSE, é necessária a obtenção dos parâmetros (k, \mathbf{e}) (Capítulo 4) com base no conjunto de dados analisado. Para isto, foi utilizado o **Conjunto de Desenvolvimento**.

Desta forma, diversos conjunto de valores de (k, \mathbf{e}) foram avaliados para ambos os tipos de pulsos considerados nas simulações. O *Root Mean Square* (RMS) do erro relativo entre os valores reais da simulação e os valores estimados da amplitude dos pulsos do sinal de interesse foi utilizado como critério para selecionar o melhor conjunto de parâmetros (k, \mathbf{e}) .

O procedimento consistiu em variar os valores desses dois parâmetros em um determinado intervalo e selecionar os valores que resultam no menor valor RMS do erro relativo. Como esperado, apenas um conjunto de parâmetros foi selecionado para o método proposto, independentemente da *SPR* e dos valores de ocupação utilizados na simulação, resultando em $k = 0,9$ e $k = 0,5$ para os pulsos bipolar e unipolar, respectivamente, e $\mathbf{e} = [0, 12 \ 0, 12 \ \dots \ 0, 12]$ (see Equation (4.14)) para ambos os pulsos.

Deve-se ressaltar que k é calculado somente de acordo com a forma de pulso do calorímetro, enquanto o vetor residual \mathbf{e} é estimado a partir das fontes de ruído do calorímetro. Portanto, ambos os parâmetros k e \mathbf{e} devem ser independentes dos níveis *SPR* e de ocupação. Além disso, como a distribuição do ruído das utilizada na simulação é *WGN*, os elementos de \mathbf{e} são idênticos.

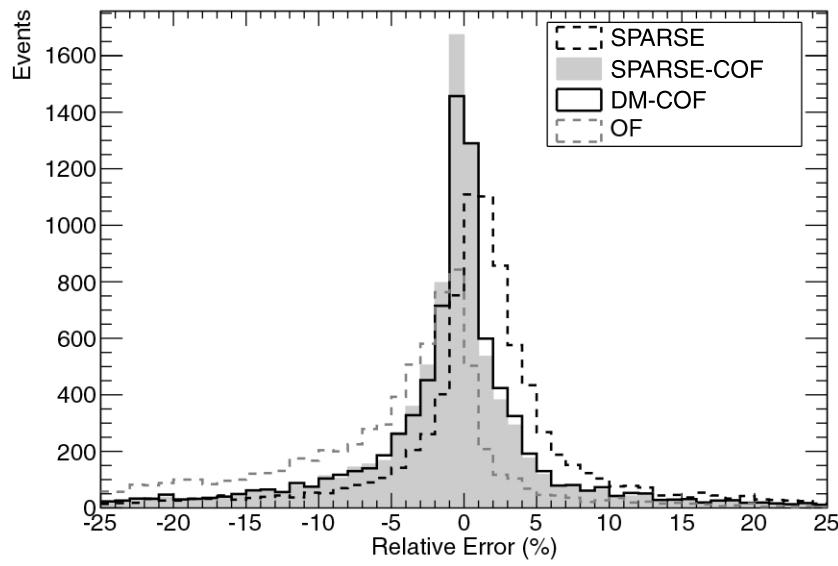
5.2.2 Estimação da Amplitude do Sinal de Interesse

Nesta seção, deseja-se avaliar o desempenho dos algoritmos SPARSE, SPARSE-COF, DM-COF e OF quando aplicados as simulações, visando a estimação da amplitude do BC de interesse da janela de observação.

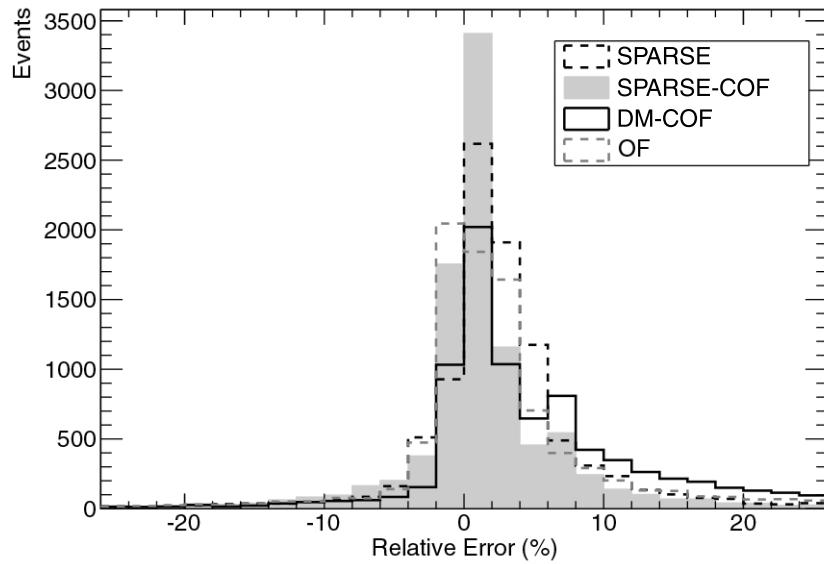
Para avaliar o desempenho dos métodos, serão comparados os histogramas de erro relativo de estimação para os diferentes métodos considerados. Adicionalmente, de forma a quantificar o desempenho, será utilizado o RMS do erro relativo, calculado de forma robusta [60].

As simulações para ambos os pulsos de calorímetros considerados foram realizadas com um nível de ocupação de 20% e um *SPR* de 2, condições ainda não muito severas de empilhamento. A Figura 5.2 apresenta os histogramas de erro relativo de estimação para ambos os pulsos considerados. Começando a análise pelo pulso unipolar (Figura 5.2(a)), pode-se observar que os métodos que apresentaram uma maior concentração de eventos próximos a um erro relativo igual a zero foram SPARSE-COF e o DM-COF, indicando um melhor desempenho para este métodos quando comparados ao SPARSE a ao OF, que obteve o pior desempenho neste caso. Relativamente ao pulso bipolar (Figura 5.2(b)), o melhor desempenho foi do método SPARSE-COF seguido pelo SPARSE. Nesta caso, observa-se um deteriorização do desempenho do método DM-COF, ficando semelhante ao OF. Isto ocorreu devido ao tamanho da janela de observação ser menor do que o tamanho do pulso, conforme esperado e já apontado anteriormente.

O resumo dos valores de RMS do e da média (tendência dos métodos) do erro relativo para ambos os casos de pulsos simulados é mostrado na Tabela 5.1. Esses valores foram extraídos a partir da distribuição do histograma. Como esperado, para o sinal unipolar, o desempenho é semelhante para ambos os métodos de SPARSE-COF e DM-COF, enquanto o desempenho OF é consideravelmente pior. Para o sinal bipolar, observa-se um melhor desempenho para SPARSE-COF, enquanto os desempenhos OF e DM-COF são semelhantes.



(a) Unipolar sinal.



(b) Bipolar sinal.

Figura 5.2: Erro Relativo para simulação com 20% de ocupância e $SPR = 2$.

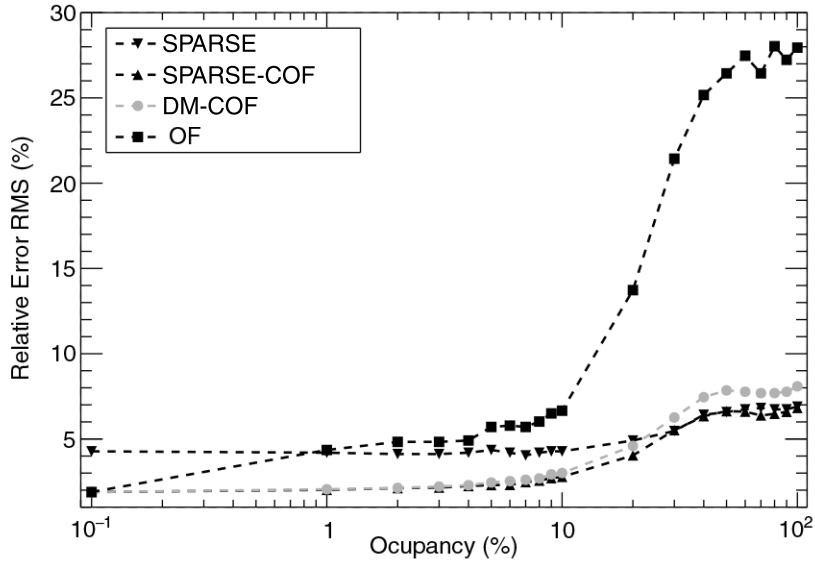
Tabela 5.1: Valores RMS e Média dos histogramas do erro relativo para reconstrução do pulso Bipolar e Unipolar

Tipo do Pulso	Método	Valores RMS (%)	Valores Média(%)
Unipolar	SPARSE	$4,99 \pm 0,04$	$-1,12 \pm 0,06$
	SPARSE-COF	$4,17 \pm 0,03$	$-1,05 \pm 0,05$
	DM-COF	$4,72 \pm 0,04$	$-1,85 \pm 0,05$
	OF	$13,4 \pm 0,1$	$-8,3 \pm 0,1$
Bipolar	SPARSE	$4,21 \pm 0,03$	$2,05 \pm 0,04$
	SPARSE-COF	$2,69 \pm 0,02$	$1,25 \pm 0,03$
	DM-COF	$8,65 \pm 0,06$	$4,46 \pm 0,09$
	OF	$7,35 \pm 0,05$	$2,48 \pm 0,07$

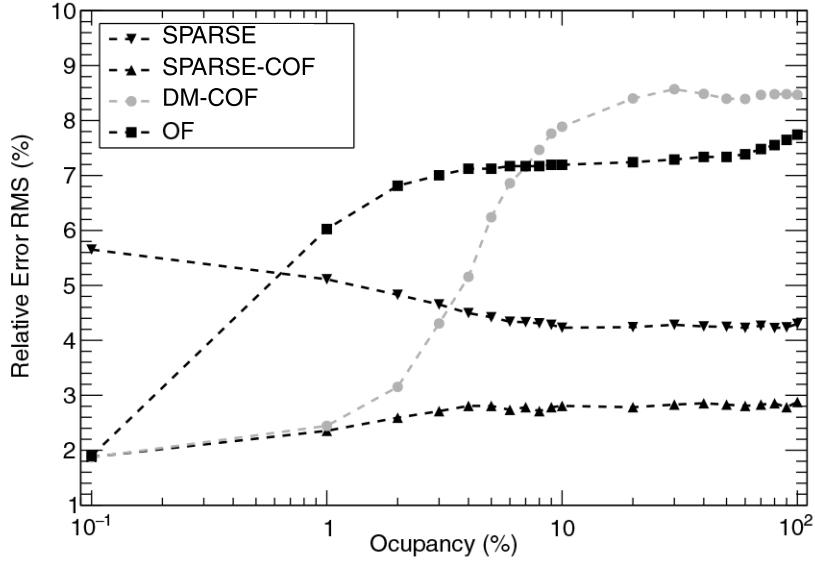
5.2.3 Estimação da Amplitude do Sinal de Interesse × Nível de Empilhamento

Nesta seção, deseja-se avaliar o desempenho dos algoritmos considerados em função do aumento no nível de empilhamento, em termos de ocupação e valores de *SPR*. Desta forma, foram realizadas simulações com *SPR* fixo, variando a ocupância e vice-versa.

A Figura 5.3 mostra o valor RMS do erro relativo de estimação da amplitude do sinal de interesse para um $SPR = 2$. Para o sinal unipolar, ambos os métodos, SPARSE-COF e DM-COF apresentam comportamento semelhante e desempenho superior aos demais para todas os níveis de ocupância avaliados. O desempenho do OF colapsa para níveis de ocupação (acima de 10 %). Para o pulso bipolar, o SPARSE-COF apresenta o melhor desempenho como esperado. A partir do nível de ocupação 1% o erro OF aumenta significativamente. Abaixo de 1% de nível de ocupação, DM-COF e SPARSE-COF apresentam desempenho semelhante, mas acima deste nível de ocupação, a utilização de SPARSE como pré-processamento do COF é indicada, uma vez que o desempenho de DM se deteriora, chegando a ficar pior do que o desempenho do OF. O desempenho do SPARSE-COF estabiliza acima de 10% de ocupação. Com relação ao método SPARSE, observa-se que para baixo nível de ocupação, ele é método que apresenta o pior desempenho devido as suas diversas restrições no problema de otimização. Entretanto, para níveis de ocupação acima de 4% ele já se apresenta como o segundo melhor método avaliado, mantendo desempenho estável até 100% de ocupância.



(a) Sinal unipolar.



(b) Sinal bipolar.

Figura 5.3: Valores RMS da distribuição do erro relativo em função da ocupância para $SPR = 2$.

Considerando agora apenas a simulação do sinal bipolar, aonde os métodos esparsos trazem maior benefício devido ao tamanho limitado da janela de observação, a Figura 5.4 apresenta a evolução do valor RMS do erro de reconstrução como uma função da variação do SPR , quando uma ocupação de 10% é considerada. Como esperado, as técnicas SPARSE e SPARSE-COF apresentam melhor desempenho em regiões de pequena razão SPR , isto é, regiões onde a energia dos sinais de empilhamento é significativa em comparação com a energia do sinal central. Para níveis

elevados de ($SPR > 8$) todos os métodos apresentam desempenho semelhante, já que a amplitude dos sinais empilhados tornam-se pequenas em relação a amplitude do sinal de interesse.

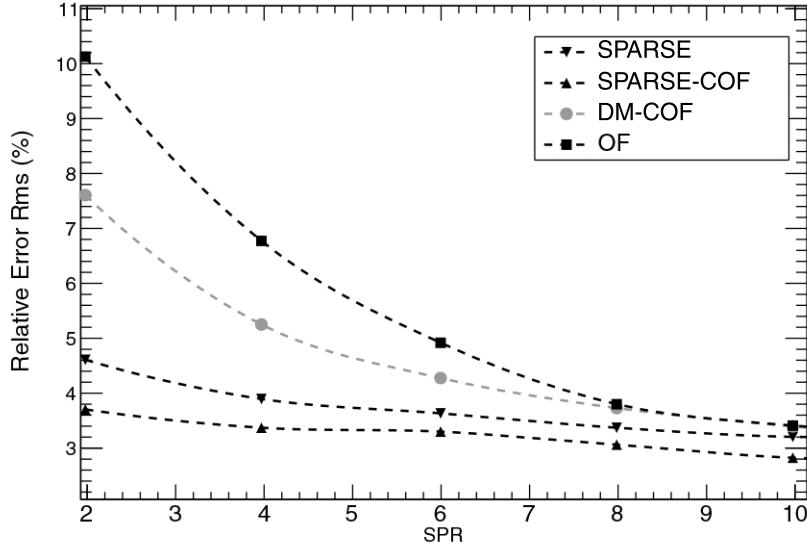


Figura 5.4: Valores RMS da distribuição do erro relativo em função do SPR para uma ocupância de 10% (Sinal bipolar).

5.3 Conclusões

A partir das simulações de pulsos de diferentes calorímetros em diferentes condições de empilhamento, foi observado que os métodos de representação esparsa trazem ganhos significados de desempenho em cenários em que a janela de observação não contém todo o pulso e para níveis relevantes de empilhamento de sinais.

Estes resultados, confirmaram a motivação para o uso de representação esparsa para estimativa de energia de calorímetros em cenários de empilhamento de eventos, já que o método DM-COF só considera o empilhamento de sinais dentro da janela de observação em sua formulação. Já o método OF nem modela o problema de empilhamento, tendo o seu desempenho afetado esperada nesta condições.

Capítulo 6

Avaliação da Estimação de Energia Baseada em Representação Esparsa na Calorimetria do ATLAS

Neste capítulo, os métodos baseados em representação esparsa são aplicados a calorimetria do ATLAS e são comparados ao método que atualmente está sendo utilizado pela colaboração nestes detectores (OF). Também são realizadas comparações com o método DM-COF, proposto para ser aplicado em cenários de empilhamento de eventos e que teve como motivação para o seu desenvolvimento o problema da estimação de energia no TileCal.

Inicialmente, simulações do sinal do TileCal e do LArg foram desenvolvidas, semelhante as apresentadas no capítulo anterior, visando a confirmação dos resultados do capítulo anterior para os sinais dos calorímetros do ATLAS.

Como a proposta de representação esparsa teve como principal motivação o problema de estimação do LArg, devido ao maior nível de empilhamento neste calorímetro e as características do seu sinal de referência que é maior do que a janela de observação, esses métodos foram aplicados ao LArg em dados de simulações Monte Carlo do ATLAS.

Adicionalmente, além da solução da busca de esparsidade utilizando LP, outros métodos de esparsidade com menor complexidade computacional são avaliados em busca de uma solução mais eficiente para ser implementada no LArg.

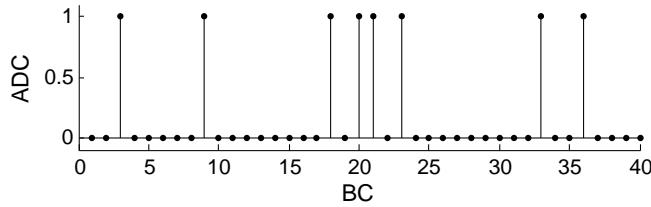


Figura 6.1: População de BC com 10% de ocupância. BC com valor 1 significa que ocorreu deposição de energia no canal.

6.1 Simulações do Sinal do LArg e do TileCal

Com o objetivo de realizar testes de desempenho e comparação entre os métodos de estimação, foi desenvolvido um ambiente de simulação que sintetiza sinais com as características encontradas na eletrônica de leitura dos canais dos sistemas calorimetria do ATLAS. O ambiente de simulação, bem como os principais resultados destas análises, são descritos nesta seção.

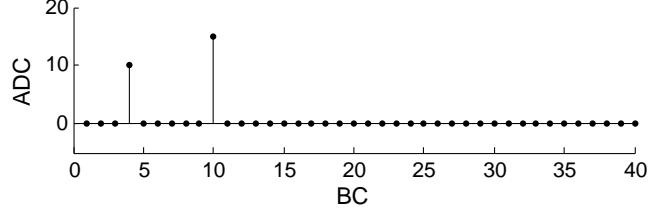
As simulações e análises apresentadas nesta seção são muito semelhantes as apresentadas no Capítulo 5, mas agora serão utilizados pulsos da calorimetria do ATLAS de forma a verificar a validade das análises apresentadas anteriormente para o LArg e para o TileCal.

6.1.1 Simulações

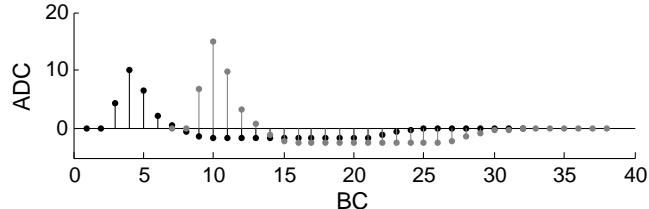
Inicialmente, foram criados sinais de referência baseados no sinal do LArg, como mostra a Figura 3.3, e no sinal do TileCal como mostra a Figura 3.2.

Assim, para simular os sinais de um único canal desses calorímetros, foi criado um vetor com 1.000.000 (um milhão) de elementos, representando uma sequência com a informação da deposição de energia em cada colisão (BC) para um canal do calorímetro preenchido aleatoriamente com um determinado valor de ocupância, conforme a simulação realizada no capítulo anterior. Em um extremo, 0% de ocupância significa que não existe deposição de energia neste canal em nenhuma colisão. No outro extremo, 100% de ocupância significa que em cada BC há uma certa deposição de energia. A Figura 6.1 mostra uma pequena janela deste vetor, para uma ocupância de 10%.

Para um BC não-vazio, uma distribuição exponencial com média de 30 contagens (valor da Conversão Analógico-Digital) foi utilizada para simular a energia depositada dos sinais provenientes de empilhamento. Esta distribuição apresenta uma maior probabilidade de ocorrência de deposição de eventos de menor energia, como ocorre normalmente nos calorímetros do ATLAS. O valor médio de 30 contagens vem de resultados experimentais no LHC [61]. A Figura 6.2(a) mostra um certo número de BC, aonde ocorreu deposição de energia em $BC = 4$ e $BC = 10$ já com



(a) BC com deposição de energia



(b) Sinais sobrepostos aos BC com deposição de energia

Figura 6.2: Passos para simulação do *pile-up* para o Sinal do LArg e do TileCal

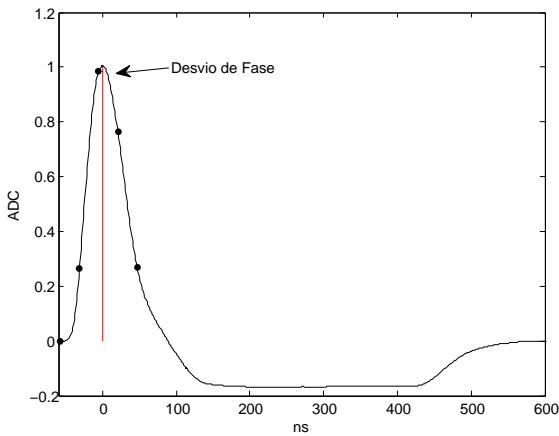


Figura 6.3: Sinal de referência do LArg com um pequeno desvio de fase, fazendo com que a amostra de valor máximo não corresponda ao pico do sinal.

a energia sorteada atribuída.

Para os BC com deposição de energia, o sinal de referência do calorímetro é incluído na simulação. A Figura 6.2(b) ilustra a etapa de inclusão o sinal de referência do calorímetro, considerando o sinal do LArg.

Durante a sobreposição do sinal, um pequeno desvio de fase com distribuição uniforme entre $[-1, +1]$ ns é aplicado a cada sinal. Isso faz com que a amostra referente ao pico do sinal não coincida exatamente com o valor máximo do pulso, deformando o sinal de referência ilustrado na Figura 6.3). Após a sobreposição, temos uma sequência de BC similar à da Figura 6.4.

Em seguida, é adicionado a cada BC um ruído branco gaussiano (WGN) com desvio padrão $\sigma = 1$ contagem para simular o ruído da eletrônica, conforme identificado experimentalmente (Ver Figura 6.5).

Como a janela de observação para estimativa da energia na ROD do LArg é de

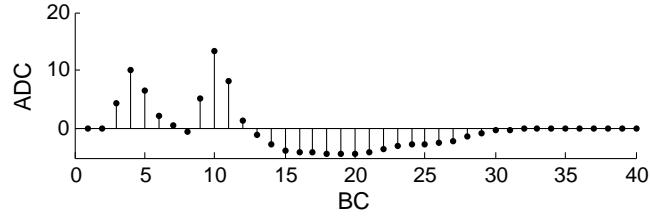


Figura 6.4: Adição de desvio de fase aos sinais.

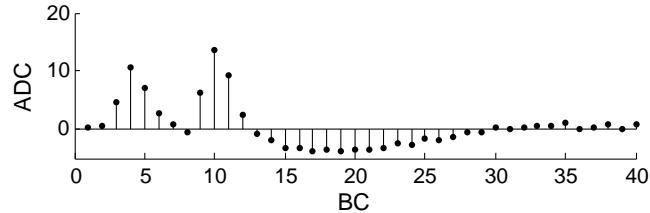


Figura 6.5: Adição de ruído branco gaussiano na simulação.

$N = 5$ amostras, e na ROD do TileCal é de $N = 7$ amostras, torna-se necessária a criação destas janelas de forma a construir um *Conjunto de Ruído* e outro *Conjunto de Sinal*.

O **Conjunto de Ruído**, é criado utilizando-se aproximadamente metade dos elementos do vetor de BC e dividindo este conjunto em janelas, resultando em 100.000 vetores de 5 amostras consecutivas (Ver Figuras 6.6(a) e 6.6(b)) para o LArg e em 70.000 vetores de 7 amostras para o TileCal.

Finalmente, à segunda metade do vetor de BC é adicionado um sinal centrado na terceira amostra (junto a um desvio de fase aleatório) para o LArg e na quarta amostra para o TileCal, que corresponde ao sinal cuja amplitude deve ser estimada, já que esse sinal representa a deposição de energia na colisão de interesse. Para esses sinais, uma distribuição exponencial com média de $\mu_{Sinal} = 60$ contagens é utilizada como amplitude (Ver Figuras 6.7(a) e 6.7(b)). Este conjunto é denominado **Conjunto de Sinal**, e um elemento deste conjunto, para a simulação do LArg é mostrado na Figura 6.8.

Deve-se ressaltar, que para cada simulação, o conjunto de dados foi igualmente

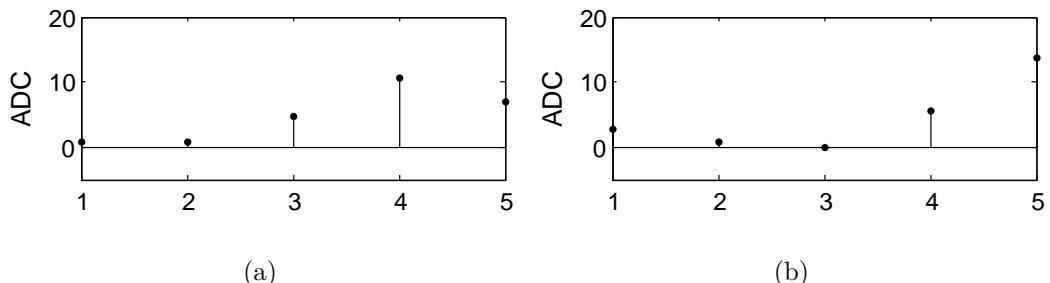


Figura 6.6: Exemplos do conjunto de ruído na simulação.

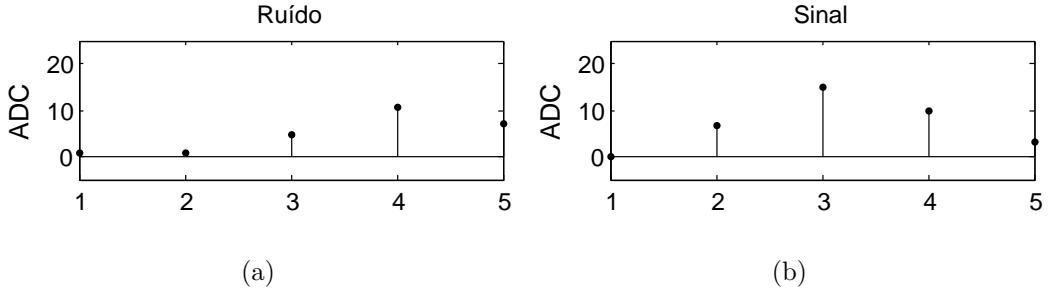


Figura 6.7: Exemplo de sinais simulados. (a) ruído (WGN + *pile-up*) e (b) sinal a ser estimado.

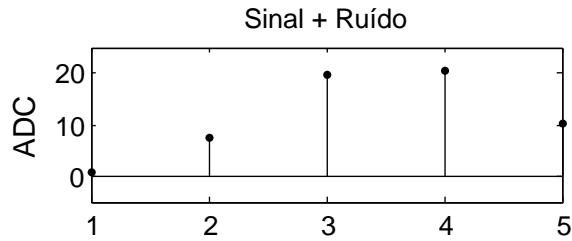


Figura 6.8: Exemplo das 5 amostras do sinal resultante (vetor \mathbf{x}) no LArg (Simulação).

dividido em dois: o **Conjunto de Desenvolvimento**, que é usado para o desenvolvimento dos algoritmos de estimativa e o **Conjunto de Teste**, a partir do qual é avaliado desempenho dos métodos de estimativa.

6.1.2 Resultados e Análises

Nesta seção, os métodos SPARSE, SPARSE-COF, DM-COF e OF têm o seu desempenho avaliados para as simulações contendo o pulso de LArg e do TileCal.

6.1.2.1 Considerações Sobre o Projeto dos Métodos SPARSE

Os parâmetros (k, \mathbf{e}) foram obtidos de forma semelhante ao explicado na Seção 5.2.1, ou seja, a partir o valor RMS do erro relativo entre o valor simulado e o valor estimado da amplitude em diversas simulações, utilizando o **Conjunto de Desenvolvimento**. O menor erro relativo ocorreu com $k = 9$ e $\mathbf{e} = [1, 2, 1, 2, \dots, 1, 2]$ para o sinal do LArg e não variam significativamente para outros níveis de *pile-up*. Para o TileCal $k = 6$ e o \mathbf{e} foi o mesmo já que o ruído é o mesmo nas simulações realizadas. Portanto, estes valores são utilizados em todas as análises a seguir.

Os diferentes valores obtidos para os parâmetros (k, \mathbf{e}) em relação a Seção 5.2.1 são devido aos valores de amplitude utilizados nas diferentes simulações. Nessa simulação, a amplitude dos sinais está em contagens de ADC, enquanto a simulação realizada no Capítulo 5 está em MeV.

6.1.2.2 Estimação da Amplitude do Sinal de Interesse Para o Sinal do LArg

Nesta seção, deseja-se avaliar o desempenho dos algoritmos SPARSE, SPARSE-COF, DM-COF e OF quando aplicados as simulações do sinal do LArg, visando a estimação da amplitude do BC de interesse da janela de observação.

Igualmente à Seção 5.2.2, serão analisados o histograma do erro relativo de estimação e o seu valor RMS, que é calculado de forma robusta [60].

A Figura 6.9 mostra os histogramas do erro relativo para os diferentes métodos de estimação considerados, para uma ocupância de 10% e um $\mu_{Sinal} = 60$. Pode-se observar, pela forma da distribuição do erro relativo, que o melhor desempenho é obtido pelo método SPARSE-COF seguido pelo SPARSE. Observa-se ainda, que tanto OF e DM-COF têm um desempenho bem inferior, como já era esperado.

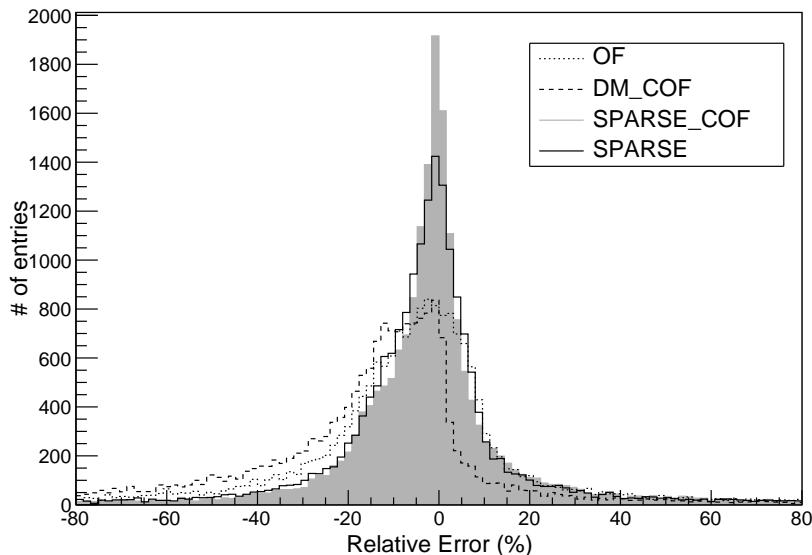


Figura 6.9: Comparação dos histogramas do erro relativo para 10% de ocupância e $SPR = 2$.

Para verificar o desempenho do SPARSE-COF em relação a faixa dinâmica do sinal de interesse, a Figura 6.10 apresenta o erro relativo da estimação em função do valor da amplitude simulada. Para comparação, a mesma análise é feita para o método OF (ver Figura 6.11). Comparando as duas figuras, observa-se que o SPARSE-COF apresenta muito mais eventos em torno de 0% de erro. Adicionalmente, pode-se observar o comportamento linear de ambos estimadores.

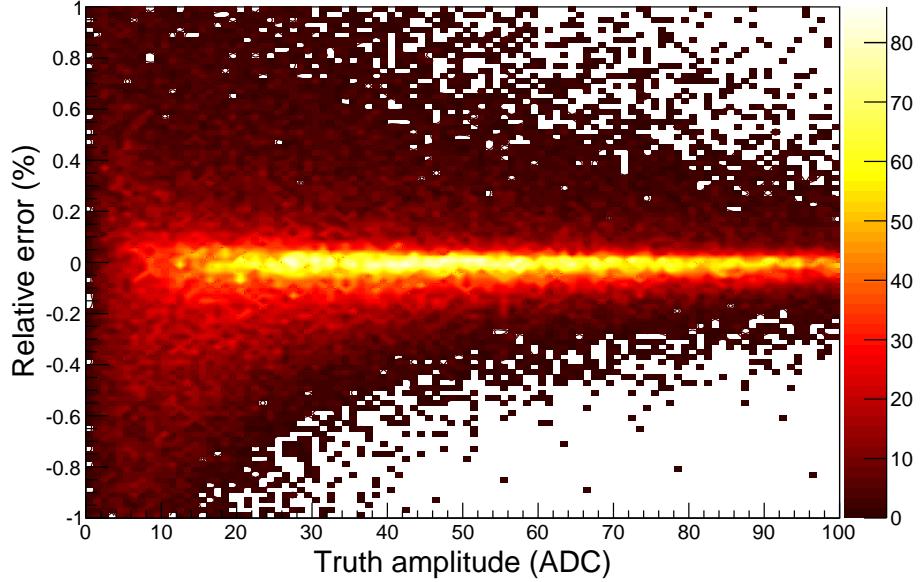


Figura 6.10: Erro relativo SPARSE-COFxTRUTH para faixa dinâmica entre 0 a 100 contagens. Para 10% de ocupância e $SPR = 2$.

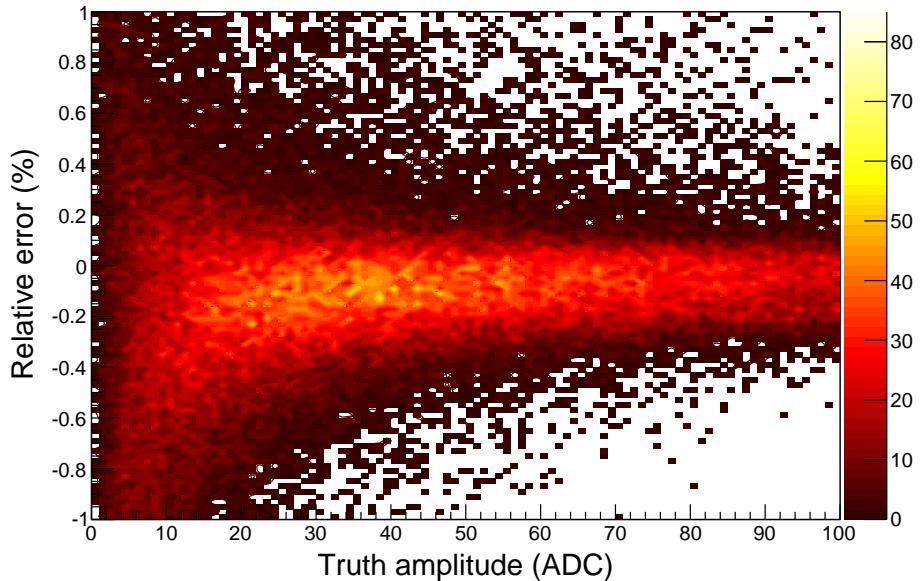


Figura 6.11: Erro relativo OFxTRUTH para faixa dinâmica entre 0 a 100 contagens. Para 10% de ocupância e $SPR = 2$.

Os resultados da simulação do TileCal são omitidos aqui pois não acrescentam muito em relação ao já observado no Capítulo 5.

6.1.2.3 Estimação da Amplitude do Sinal de Interesse × Nível de Empilhamento (LArg)

Para quantificar o desempenho dos algoritmos para diferentes níveis de empilhamento, foi utilizado o RMS calculado através da abordagem alternativa [60], conforme já realizado no capítulo anterior.

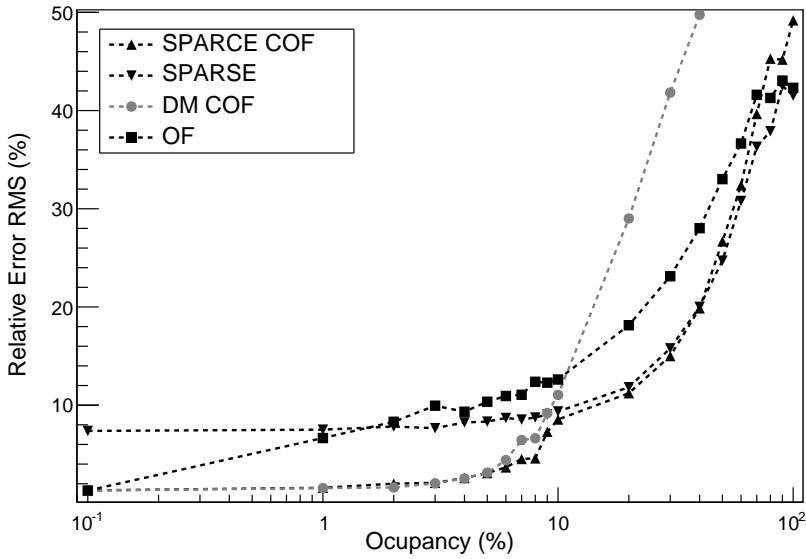


Figura 6.12: Valores RMS para diferentes níveis de ocupância no LArg (simulação com $SPR = 2$).

A Figura 6.12 mostra os valores RMS para diversos níveis de ocupância utilizados em diferentes simulações do sinal do LArg para um mesmo valor de $SPR = 2$. O método SPARSE-COF obteve os menores erros para quase todo o intervalo simulado. Para o nível de ocupância próximo a zero, os métodos OF e DM-COF apresentam eficiências similares. Entretanto, para níveis superiores a 1%, o OF apresenta aumento significativo no erro, enquanto os métodos baseados no COF operam próximo ao erro mínimo até a 4% de ocupância. Para valores de ocupância abaixo de 10%, o método DM-COF pode ser utilizado. Para níveis de ocupância superiores, o uso de representação esparsa trás ganhos significativos. É importante observar que o método SPARSE, torna-se superior ao SPARSE-COF para níveis de ocupância acima de 50

Relativamente à comparação entre o OF e o SPARSE-COF, a redução no valor RMS pode refletir uma melhora importante na resolução de energia para a análise física. Na simulação do LArg, o OF apresenta RMS superior a 10% para ocupância pouco superior a 3%, enquanto que para o SPARSE-COF este valor é alcançado apenas para níveis de ocupância superiores a 20%.

Outra observação importante a ser feita é que acima de 10% de ocupância, o DM-COF deteriora o seu desempenho significativamente, conforme já havia sido observado na Seção 5.2.3. Essa discrepância de desempenho dos pré-processamentos utilizados no COF, pode ser explicada, em parte, pelo fato do número de amostras da janela de observação ser menor que o número total das amostras do sinal de referência, o que trás problemas ao DM-COF para níveis de ocupância mais altos.

Finalmente, é importante ressaltar que para 40% de ocupância, o método

SPARSE possui desempenho semelhante ou pouco superior ao SPARSE-COF.

6.1.2.4 Estimação da Amplitude do Sinal de Interesse × Nível de Empilhamento (TileCal)

Os resultados apresentados para a simulação do sinal do LArg demonstraram o bom desempenho dos métodos esparsos em cenários de empilhamentos de sinais, entretanto, a análise da simulação do sinal de TileCal, complementa a análise, já que o seu sinal de referência está contido na janela de observação.

Desta forma, na Figura 6.13, pode-se observar que para o TileCal, o processamento por DM funciona satisfatoriamente para o COF até uma ocupância de 20%, quando o método colapsa. No caso do TileCal, o método SPARSE-COF apresentou o melhor desempenho entre os métodos avaliados para quase toda a faixa de ocupância analisada.

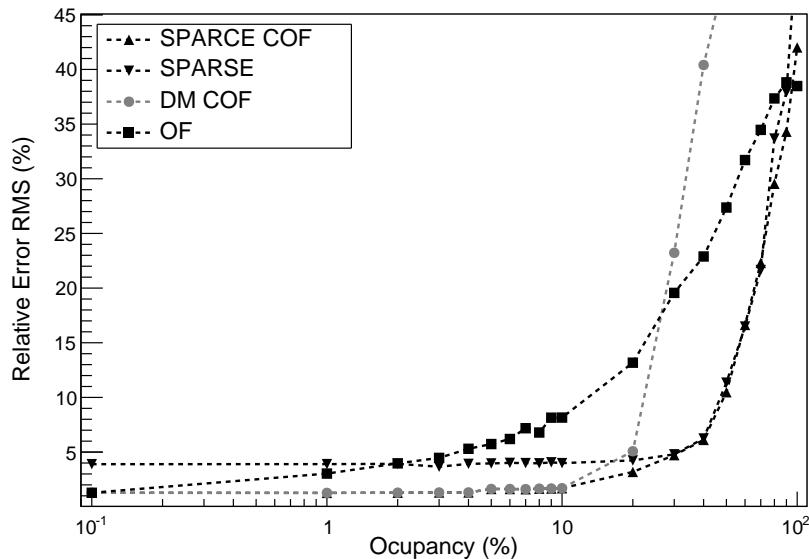


Figura 6.13: Valores RMS para diferentes níveis de ocupância para estimação de energia no TileCal (simulação com $SPR = 2$).

6.1.2.5 Análise do Limiar de Detecção de Empilhamento (COF)

O valor do limiar utilizado para identificação de sinais de empilhamento nos métodos baseados no COF também foi investigado para ambos os sinais simulados. Este parâmetro foi ajustado com base nas simulações para cada nível de ocupância, a fim da obtenção do melhor desempenho do COF para o *Conjunto de Desenvolvimento*. Nesta simulação, $SPR = 2$ e a ocupância foi variada de 1

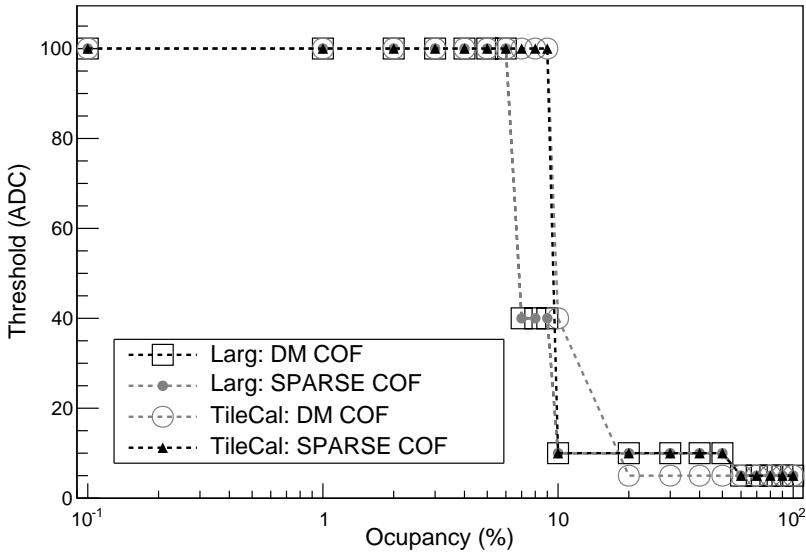


Figura 6.14: Valor do limiar obtido para detecção de *pile-up* nos métodos baseados no COF (simulação com $SPR = 2$).

O valor máximo testado para o limiar foi 100 contagens, visto que, acima deste valor não foram obtidas melhorias significativas. De acordo com a Figura 6.14, abaixo de 10% de ocupância o patamar deve ser alto, já que nenhum sinal empilhado será selecionado, e a Equação (3.41) do COF se resume ao vetor

$$\frac{\mathbf{h}}{|\mathbf{h}|^2},$$

que é equivalente ao resultado do método OF sem a adição de restrições. Do exposto, conclui-se que abaixo de 10% de ocupância, pode-se considerar o ruído ainda aproximadamente WGN.

Por outro lado, acima de 60% de ocupância, o patamar é muito baixo (por volta de 5 contagens), significando que a maioria dos sinais detectados pelo pré-processamento é considerada na segunda interação do COF. Isto nos conduz a desempenhos semelhantes ao próprio método SPARSE, mostrando que a segunda interação para o COF pode ser ignorada nestes casos.

Portanto, a análise do gráfico da Figura 6.14 permite chegar as seguintes considerações sobre os métodos baseados no COF:

- para canais com níveis de ocupância menores (abaixo de 10%), a utilização do OF sem restrições é indicado;
- para ocupâncias entre 10% e 60%, o patamar utilizado para o segundo passo do COF deve ser entre 10-40 ADC;
- acima de 60% de ocupância, o método SPARSE é o mais indicado para estimar

a amplitude do sinal central, incluindo o TileCal que possui o sinal de referência contido na janela de observação.

Vale ressaltar que o OF necessita de informações adicionais sobre o pedestal e matriz de covariância, que dependem do nível atual de *pile-up*. A partir do **Conjunto de Desenvolvimento** de ruído, esta informação foi estimada nas diversas simulações. Entretanto, nos experimentos estas informações não são tão simples de serem estimadas, já que variam de célula para célula e de acordo com a luminosidade.

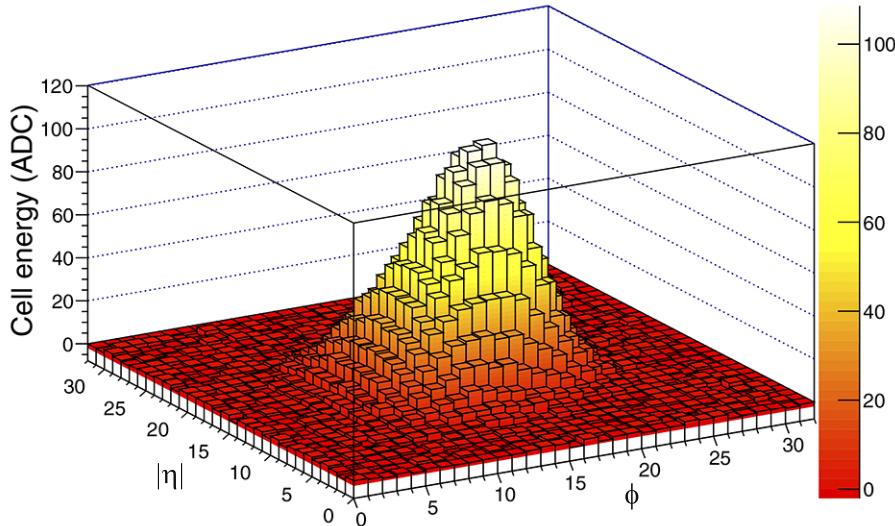
6.1.2.6 Estimação da Amplitude dos Sinais Empilhados com SPARSE-COF

Como o método SPARSE-COF obteve melhor desempenho para os diversos cenários considerados nas diferentes simulações, nesta seção, será avaliada a sua capacidade para estimar as amplitudes para os sinais empilhados (*Out-of-Time*(OOT)) no LArg.

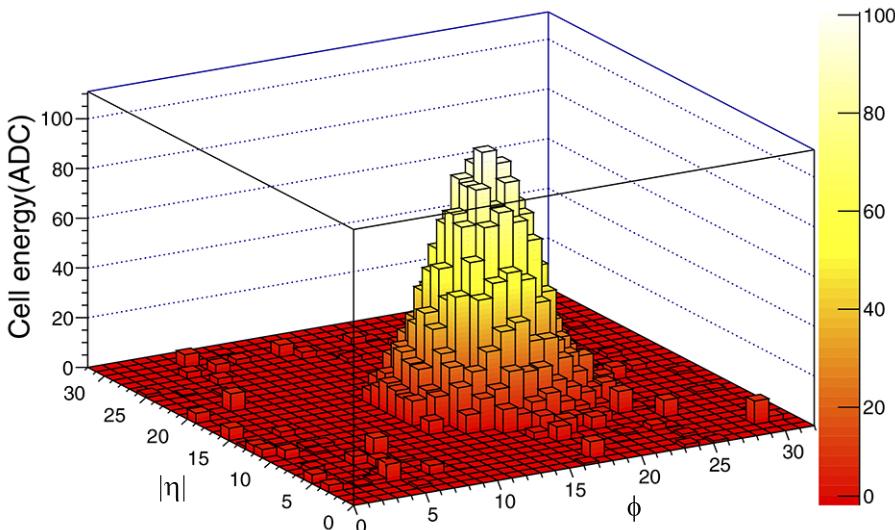
De forma a ilustrar qualitativamente a estimação da amplitude dos sinais empilhados, ela será utilizada para separação de jatos sobrepostos de colisões subsequentes. Quando um jato de partículas atinge uma determinada camada de calorímetro, o padrão de deposição de energia bidimensional (tipicamente chamado $\eta \times \phi$) pode ser modelado como uma distribuição espacial semelhante a um cone [62]. O η é a coordenada que descreve o ângulo de uma partícula em relação ao eixo do feixe, enquanto ϕ corresponde ao ângulo polar da direção da partícula. O objetivo é reconstruir a forma dos jatos de BC vizinhos, quando se sobrepõem uns aos outros.

Neste exemplo, considera-se que três jatos atingem a mesma região do detector. Quanto às distâncias temporais, elas estão localizadas no BCID-2, BCID+0 e BCID+2, onde BCID significa o índice BC para a colisão, onde BCID+0 é o evento selecionado pelo sistema de trigger.

Utilizando um padrão espacial 2 – D gaussiano de deposição de energia, os sinais do pulso de referência do LArg foram sobrepostos para simular o *pileup* em células atingidas pelos três jatos. Adicionalmente, um ruído gaussiano branco com $\sigma = 1$ contagem de ADC foi adicionado a cada sinal. Por uma questão de simplicidade, os três jatos têm a mesma energia de 100 contagens de ADC na sua célula mais quente.



(a) OF.

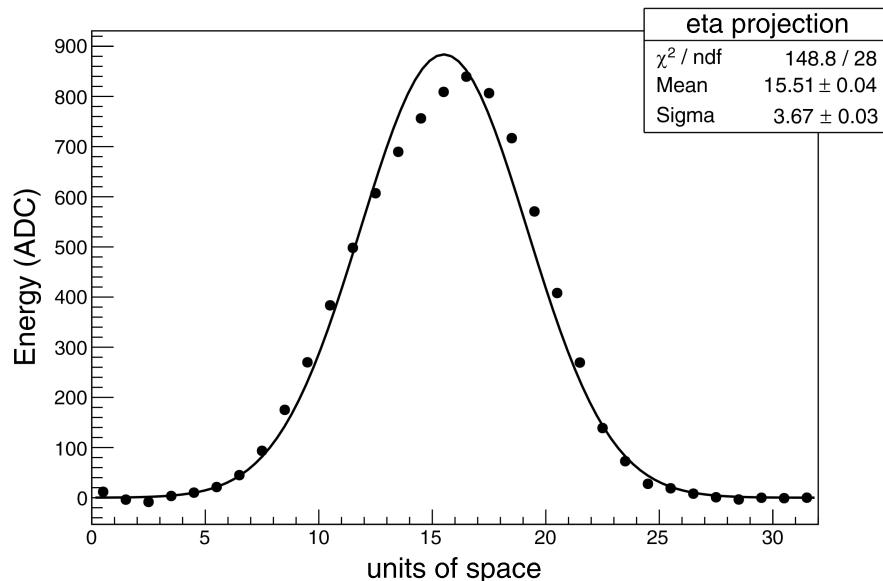


(b) SPARSE-COF.

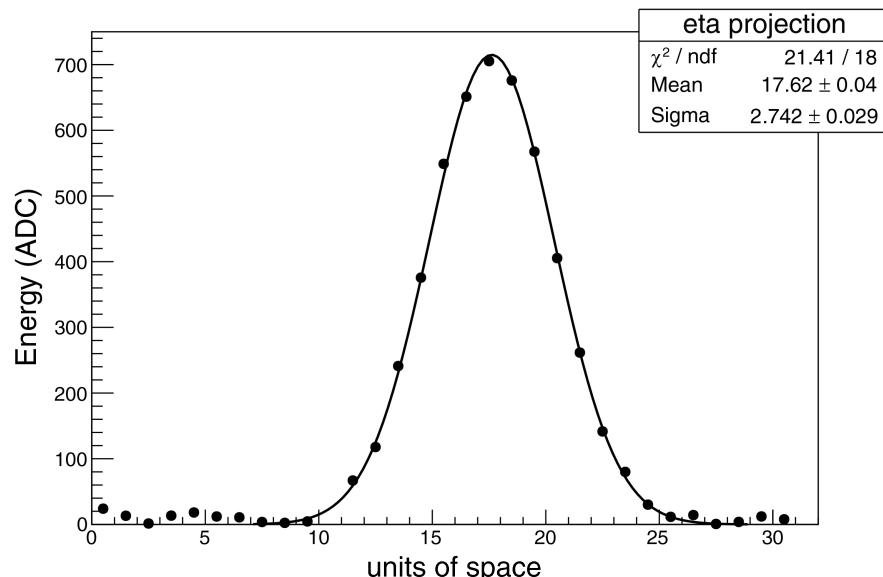
Figura 6.15: Reconstrução dos jatos localizados no BC central sofrendo influência de empilhamento de dois jatos vindo BC vizinhos.(Sinal do LArg).

A Figura 6.15 mostra a reconstrução da energia para as células na grade $\eta \times \phi$ usando o OF e estimativa do sinal de interesse do SPARSE-COF. A presença dos dois jatos vizinhos (um antes e outro depois de 50 ns) gera empilhamento de sinais na maioria das células presentes no argumento do jato. Assim, o método OF não é capaz de reconstruir a energia das células adequadamente, deformando a configuração gaussiana do jato central. Uma vez que o SPARSE-COF é mais resiliente ao *pileup*, a reconstrução do jato é realizada com menos erro.

Para quantificar o desempenho, a Figura 6.16 mostra a projeção do eixo $|\eta|$, juntamente com um *fit* gaussiano. Os valores verdadeiros para esses parâmetros são dados na Tabela 6.1, em unidades de largura de célula. O SPARSE-COF realiza uma reconstrução mais precisa, como pode ser observado a partir dos parâmetros do *fit*. O método OF apresenta um fator χ^2 ruim com uma largura de jato de 3,67, enquanto a largura verdadeira é 2,8. O jato reconstruído com o SPARSE-COF apresenta uma forma gaussiana mais precisa com uma largura de 2,74, um valor bastante mais próximo ao real do obtido com o OF.



(a) OF.



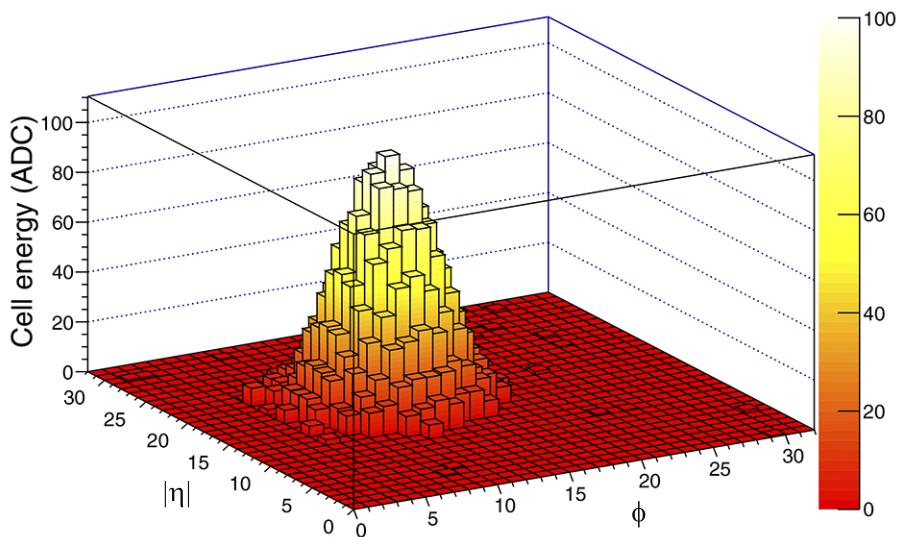
(b) SPARSE-COF.

Figura 6.16: Projeção em $|\eta|$ da reconstrução do jato do BC central (Sinal do LArg).

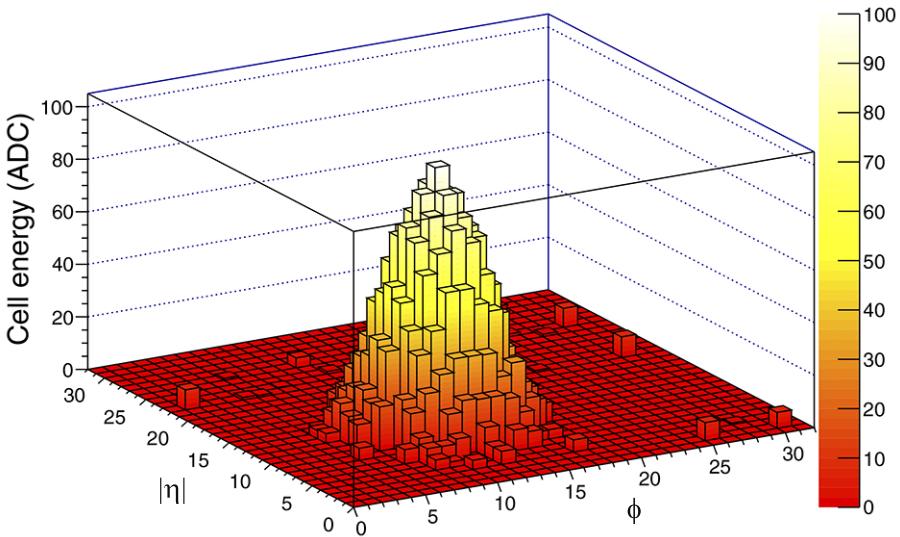
O método SPARSE-COF também é capaz de reconstruir os jatos OOT com um desempenho semelhante ao do central. Uma inspeção nos outros BC estimados mostra que o SPARSE-COF detecta um padrão acima do ruído em BCID-2 e BCID+2, como esperado. Isso é mostrado na Figura 6.17.

Os parâmetros de *fit* para todos os jatos reconstruídos, para as projeções η e ϕ , são mostrados na Tabela 6.1. Pode-se ver a partir desta tabela que o SPARSE-COF reconstrói os três jatos com boa precisão. Vale ressaltar que a informação de energia para os três jatos é extraída de apenas cinco amostras para cada célula da grade.

Portanto, este exemplo indica que o SPARSE-COF pode ser muito útil em algoritmos de identificação de partículas para calorímetros operando em condições de alta luminosidade. A possibilidade de reconstrução de eventos OOT traz novas perspectivas sobre as estatísticas de luminosidade integral e análise física final.



(a) BCID-2.



(b) BCID+2.

Figura 6.17: Reconstrução dos jatos OOT utilizando o método SPARSE-COF (Sinal do LArg).

Tabela 6.1: Parâmetros do *fit* para os três jatos reconstruídos utilizando os métodos OF e SPARSE-COF, em unidades de largura de célula (Sinal do LArg).

Método	BCID do Jato	Parâmetro	Proj. $ \eta $	Proj. ϕ
Valor Real	BCID-2	Mean	12,5	17,5
		Sigma	2,83	2,83
	BCID+0	Mean	17,5	14,5
		Sigma	2,83	2,83
	BCID+2	Mean	12,5	11,5
		Sigma	2,83	2,83
SPARSE-COF	BCID-2	Mean	12,4	17,5
		Sigma	2,56	2,56
	BCID+0	Mean	17,6	14,4
		Sigma	2,74	2,74
	BCID+2	Mean	12,5	11,5
		Sigma	2,60	2,63
OF	BCID+0	Mean	15,5	14,4
		Sigma	3,67	3,38

6.1.3 Conclusões

As simulações realizadas utilizando os pulsos do LArg e do TileCal apresentaram resultados consistentes com os encontrados no Capítulo 5.

Os métodos baseados em representação esparsa apresentaram-se mais vantajosos para o sinal LArg, já que a janela de observação é menor do que o comprimento do sinal de referência, e/ou em cenários com alto empilhamento de eventos. Em cenários com pouco empilhamento, como era esperado, o método OF possui desempenho satisfatório aliado a baixa complexidade computacional.

Também foi possível observar, que para altos níveis de empilhamento, não existe a necessidade da utilização do COF, bastando o método SPARSE apenas para realizar a estimativa.

6.2 Simulação Monte Carlo do LArg

Nesta seção, serão utilizadas as simulações de Monte Carlo do LArg [63]. As ferramentas de simulação Monte Carlo são fundamentais para tais tipos de experimentos, sendo utilizadas como ferramenta de projeto e de validação do experimento. Estas simulações são desenvolvidas por grupos específicos da colaboração, sendo bas-

tante complexas e constantemente atualizadas com dados provenientes do próprio experimento. Nestas simulações, essencialmente, todos os processos físicos conhecidos envolvendo a interação entre as partículas e matéria estão incluídos. O Monte Carlo utilizado também simula o detector ATLAS e seu sistema de calorimetria, podendo assim, fornecer a energia depositada nos canais de leitura, dos seus calorímetros, resultantes das interações das partículas com o material do detector.

As simulações Monte Carlo utilizadas nesta seção utilizaram o algoritmo PYTHIA. PYTHIA é um programa para a geração de eventos da física de altas energias, ou seja, para a descrição de colisões em altas energias entre partículas elementares, como e^+e^- , pp , $p\bar{p}$ e $\mu^+\mu^-$. Contém teoria e modelos para uma série de aspectos da física, incluindo interações leves e pesadas, distribuições de parton, jatos de parton de estado inicial e final, interações multiparton, fragmentação e decaimento [63]. Foram utilizados os bancos de dados:

- `mc12_14TeV.147806.PowhegPythia8_AU2CT10_Zee.merge.HITS.e1564_s1682_s1691`
- `mc12_14TeV.159000.ParticleGenerator_nu_E50.merge.HITS.e1564_s1682_s1691`

para gerar três simulações de colisões pp no LHC com energia no centro de massa de 14 TeV. O primeiro banco é utilizado para gerar os sinais *truth*, os quais devem ser estimados. Neste banco os sinais utilizados são referentes a deposição de energia do elétrons derivados do processo físico $Z \rightarrow ee$. Todos eventos nele encontrados são eventos de *minimum bias*. O segundo banco possui deposição de energia de vários tipos de eventos e é utilizado para gerar três diferentes níveis de luminosidade que resultam nos seguintes valores médios de interações por colisão:

- $\mu = 40$;
- $\mu = 80$;
- $\mu = 120$;

Quanto maior o número médio de interações por colisão, maior é o nível de empilhamento de sinais nos canais do calorímetro. Isto segue a mesma lógica dos diferentes níveis de ocupância tratados nas seções anteriores.

Para criação dos 3 conjuntos, foram utilizados todos os canais (células) da segunda camada da parte central barril do calorímetro eletromagnético, isto é, os canais que se encontram em $|\eta| \leq 0,7$ e em toda extensão de ϕ .

Deve ressaltar que o conjunto de dados foi igualmente dividido em dois: o **Conjunto de Desenvolvimento**, que é usado para o desenvolvimento dos algoritmos de estimação e o **Conjunto de Teste**, a partir do qual os métodos têm o seu desempenho avaliado, ambos com cinquenta mil eventos.

6.2.1 Métodos Avaliados

As análises realizadas no Capítulo 5 e na Seção 6.1, mostraram que para o LArg, os métodos baseados em representação esparsa apresentam desempenho superior ao OF e ao DM-COF em cenários com empilhamento de sinais. Desta forma, para a simulação de Monte Carlo do LArg, serão avaliados apenas métodos baseados em representação esparsa, sendo comparados ao OF, que é o algoritmo utilizado atualmente no LArg.

Além dos métodos SPARSE e SPARSE-COF, ambos implementados utilizando LP, foram avaliadas técnicas de representação esparsa mais eficientes do ponto de vista da complexidade computacional, como o LS-OMP, OMP e IRLS. Tais técnicas são boas candidatas para serem implementadas *on-line* no LArg.

6.2.2 Resultados e Análises

6.2.2.1 Estimação da Amplitude do Sinal de Interesse Para o Sinal do LArg

Inicialmente, os algoritmos, SPARSE-COF, SPARSE, LS-OMP, OMP, IRLS e OF foram utilizados para estimação da amplitude do sinal central da janela de observação de tamanho $N = 5$ amostras. Deve-se ressaltar que os métodos baseados em representação esparsa também são capazes de estimar as amplitudes de sinais *out-of-time* (OOT) (*pile-up*).

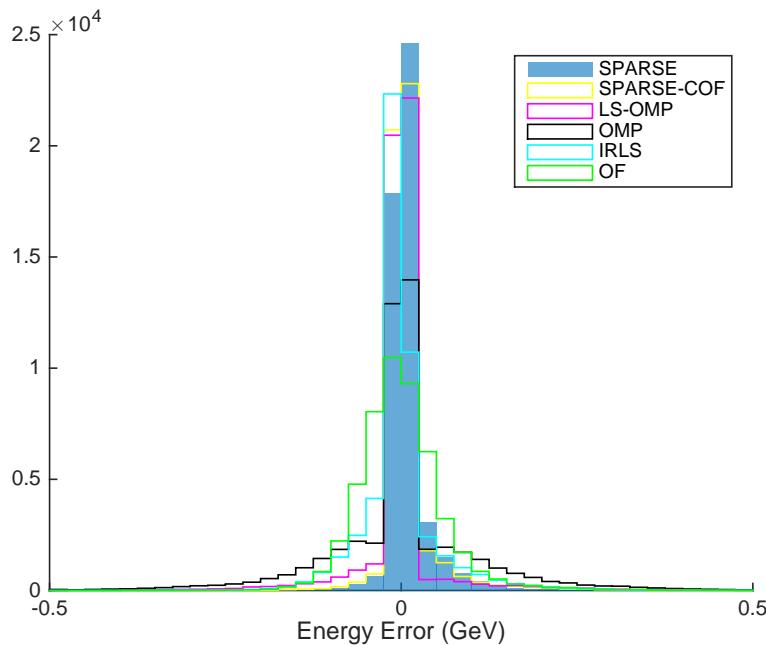


Figura 6.18: Histogramas dos erros relativos de estimação para $\mu = 40$ (Monte Carlo LArg).

A Figura 6.18 mostra os histogramas do erro relativo de estimativa para todos os métodos avaliados nesta seção, utilizando a simulação Monte Carlo com $\mu = 40$. Pode-se observar, pela forma do histograma do erro relativo, que os melhores desempenhos são obtidos pelo método SPARSE seguido pelo método SPARSE-COF, pois eles apresentam uma distribuição com a base mais fina e o topo da distribuição mais alto. Em seguida, encontram-se os métodos LS-OMP e IRLS. Como esperado, o método OF obteve o pior desempenho dentre os métodos avaliados.

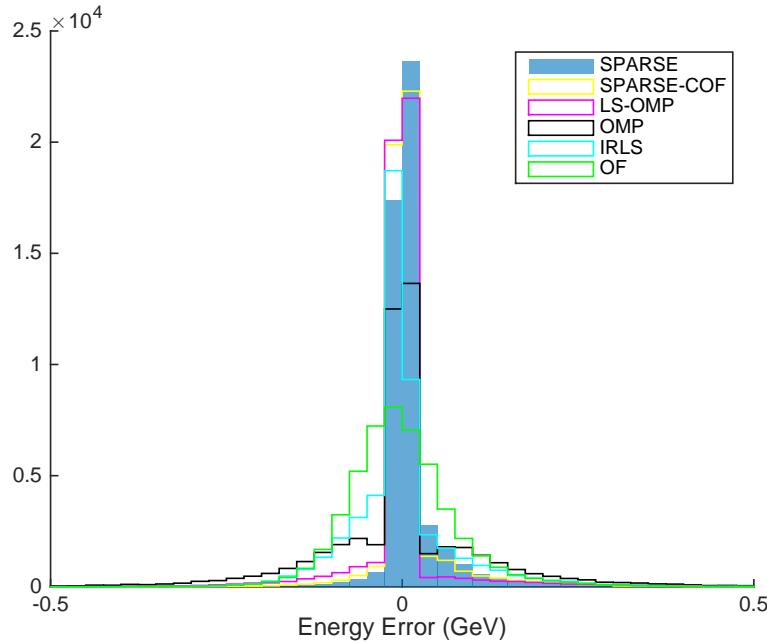


Figura 6.19: Histogramas dos erros relativos de estimação para luminosidade de $\mu = 80$ (Monte Carlo LArg).

A Figura 6.19 mostra os histogramas do erro relativo, utilizando a simulação Monte Carlo para $\mu = 80$. Pode-se observar que os histogramas seguem comportamento semelhante ao observado na Figura 6.18, aumentando um pouco a dispersão como era de se esperar para um maior nível de empilhamento de sinais.

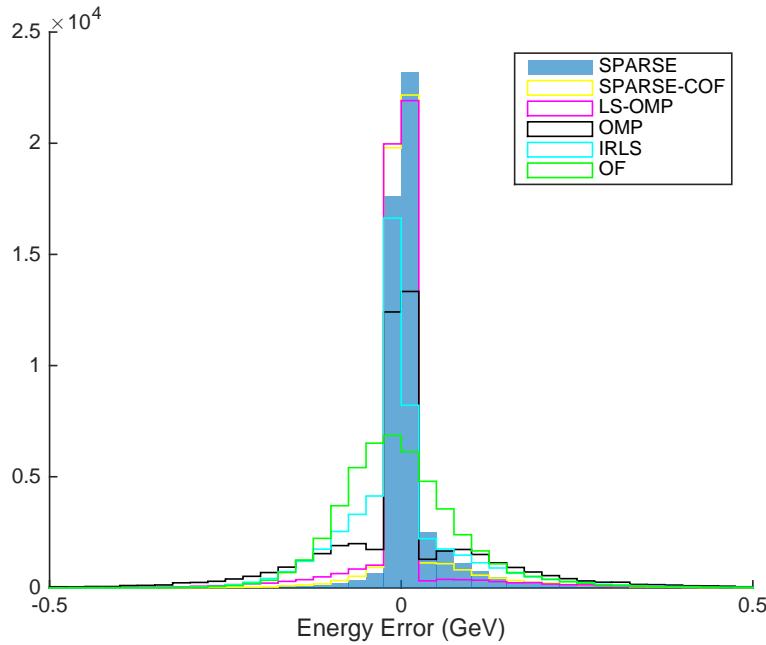


Figura 6.20: Histogramas dos erros relativos de estimação para luminosidade de $\mu = 120$ (Monte Carlo LArg).

A Figura 6.20 mostra a distribuição do erro relativo, para dados com $\mu = 120$. Novamente, o comportamento dos histogramas assemelham-se as figuras 6.18 e 6.19.

Pode-se, também, fazer a comparação dos diversos métodos através dos valor RMS do histograma do erro relativo, utilizando o cálculo do RMS robusto [60]. A Tabela 6.2 resume a comparação dos diferentes métodos avaliados para os diferentes níveis de empilhamento de sinais.

Tabela 6.2: Tabela de RMS dos histogramas dos erros relativos de estimação - valores expressos em GeV (Monte Carlo LArg).

	$\mu = 40$	$\mu = 80$	$\mu = 120$
SPARSE	$1,343 \pm 0,004 \cdot 10^{-4}$	$1,897 \pm 0,006 \cdot 10^{-4}$	$2,770 \pm 0,009 \cdot 10^{-4}$
SPARSE-COF	$1,584 \pm 0,005 \cdot 10^{-4}$	$1,951 \pm 0,006 \cdot 10^{-4}$	$2,327 \pm 0,008 \cdot 10^{-4}$
LS-OMP	$1,842 \pm 0,006 \cdot 10^{-4}$	$2,101 \pm 0,007 \cdot 10^{-4}$	$2,429 \pm 0,008 \cdot 10^{-4}$
OMP	$1,521 \pm 0,005 \cdot 10^{-2}$	$2,229 \pm 0,007 \cdot 10^{-2}$	$2,566 \pm 0,008 \cdot 10^{-2}$
IRLS	$1,135 \pm 0,004 \cdot 10^{-2}$	$2,397 \pm 0,008 \cdot 10^{-2}$	$3,76 \pm 0,01 \cdot 10^{-2}$
OF	$4,87 \pm 0,02 \cdot 10^{-2}$	$6,19 \pm 0,02 \cdot 10^{-2}$	$7,13 \pm 0,02 \cdot 10^{-2}$

Portanto, independente do valor do μ na faixa considerada na simulação Monte Carlo, os métodos SPARSE, SPARSE-COF e LS-OMP mostraram-se superiores aos demais métodos avaliados. Entretanto, devido a menor complexidade computacional do método LS-OMP em comparação com aos métodos SPARSE e SPARSE-COF

(Programação Linear), ele configura-se como o melhor candidato para estimativa de energia *on-line* na ROD do LArg.

6.2.2.2 Teste de Esparsidade e Unicidade



Figura 6.21: Porcentagem dos resultados em que pode-se atestar a unicidade e esparsidade ao ser aplicados ao algoritmo de estimação esparso (Monte Carlo LArg).

Para realizar o teste de Unicidade e Esparsidade, foi utilizado apenas um dos métodos esparsos, no caso o SPARSE. O teste foi aplicado aos três bancos utilizados nas análises e resultados abordados na secção anterior.

Verificou-se que pode-se aplicar o método de esparsidade com grande segurança nos dados do LArg, pois na grande maioria dos casos a unicidade da solução pode ser atestada. A Figura 6.21 mostra que a porcentagem de resultados em que é possível atestar a unicidade vai diminuindo com o aumento do número de interações por colisão. Entretanto, mais de 90% dos sinais do conjunto podem ser descritos por uma solução esparsa única, mesmo para dados com $\mu = 120$.

6.2.3 Conclusões

A avaliação dos métodos de estimativa em simulações Monte Carlo do LArg mostraram que os métodos baseados em representação esparsa são realmente a melhor opção neste calorímetro em cenários com empilhamento de eventos. Este resultado, confirmou e ratificou as análises realizadas nos capítulos e seções anteriores.

Adicionalmente, o método esparso LS-OMP obteve desempenho equivalente aos métodos SPARSE que utilizam Programação Linear, colocando-se como o melhor candidato para implementação *on-line* na ROD do LArg.

Finalmente, o teste de Esparsidade e Unicidade da solução indicou a validade da aplicação de técnicas baseadas em esparsidade para o problema da estimativa de energia no LArg para os três níveis de empilhamentos considerados nas simulações realizadas.

Capítulo 7

Conclusões

Nesta tese, foi proposta uma nova abordagem para o problema de estimação de energia baseada em representação esparsa para sinais de calorímetros que operam em experimentos com alta luminosidade e em cenários de empilhamento de eventos.

A principal motivação para este desenvolvimento foi o início do programa de atualização do LHC, ao final do *Run 1*, visando o aumento progressivo da sua luminosidade até 2026, quando terá início a operação do HL-LHC. O aumento da luminosidade e o consequente aumento do número de interações por colisão no LHC, trazem grandes desafios para os seus experimentos, entre eles o problema do empilhamento de sinais nos canais de leitura seus calorímetros. Desta forma, esta tese se insere dentro do contexto do programa de atualização do experimento ATLAS, tendo como foco principal a estimação de energia no LArg, calorímetro eletromagnético que é mais sensível ao problema do empilhamento de eventos devido à sua localização mais próxima ao feixe de partículas.

Na calorimetria do ATLAS e em outros experimentos, métodos lineares de estimação baseados na minimização da variância e sujeitos a restrição de não tendência do estimador têm sido amplamente utilizados e podem ser considerados como métodos clássicos de estimação. Este fato pode ser explicado pela simplicidade de implementação deste tipo de estimador, sendo implementado por simples filtros FIR, e também por sua operação em condições ótimas para casos em que o ruído de fundo seja gaussiano e o modelo do sinal de referência dos canais do calorímetro seja válido.

Em condições de empilhamento de sinais, ou seja, quando existe a sobreposição de sinais dentro da janela de observação utilizada para estimação, os métodos clássicos passam a operar em condições sub-ótimas. Nestes métodos, a formulação do sinal recebido não supõe a ocorrência de sobreposição de sinais, sendo, então, o empilhamento absorvido pelo ruído aditivo do modelo. Entretanto, os sinais empilhados modificam a distribuição estatística do ruído, o que leva os métodos clássicos a saírem da condição ótima de operação.

O abordagem para o problema de estimação proposta nesta tese utiliza como base a representação esparsa de dados. Nesta proposta, a formulação do modelo do sinal recebido é modificada para incorporar ocorrência do dos sinais empilhados provenientes de colisões adjacentes. Esta abordagem pode ser utilizada diretamente para estimação, sendo chamada nesta tese de método SPARSE, ou como pré-processamento para o COF, método que foi originalmente proposto para operar no TileCal em condições de empilhamento de sinais, sendo chamado nesta tese de SPARSE-COF.

Desta forma, a principal proposta desta tese foi uma nova abordagem para o problema de estimação de energia em calorímetros que: (a) modela o problema de estimação considerando o empilhamento como sinal; (b) através de representação esparsa estima-se a amplitude do sinal em cada *bunch crossings* (c) pode-se ou não utilizar o COF para melhorar a estimativa da energia depositada nos *bunch crossings* identificados pelo método esparso, dentro da janela de observação.

Apesar da matriz de estimação do SPARSE ser resultado de um problema de otimização com mais restrições do que o OF, o empilhamento de sinais é modelado como sinal e o ruído pode, então, ser considerado como dominado pela eletrônica de *front-end* dos calorímetros, ou seja, como um ruído branco e gaussiano como no caso LArg e do TileCal. Portanto, o método SPARSE operaria em condições próximas a ótima mesmo em cenários com empilhamentos de sinais, diferentemente do OF, o que resultaria no melhor desempenho dos métodos propostos em relação ao método clássico utilizado na calorimetria do ATLAS.

Os resultados apresentados no Capítulo 5, foram obtidos pela aplicação dos métodos de estimação em um banco de dados simulado. Esse banco de dados foi obtido a partir das simulações de diferentes pulsos de calorímetro, usualmente provenientes de um circuito RC-CR, em diferentes condições de empilhamento. Como esperado, os métodos SPARSE e SPARSE-COF trazem ganhos significativos de desempenho, principalmente em cenários onde a janela de observação não contém todo o pulso e para níveis relevantes de empilhamento de sinais. As análises realizadas ratificaram a motivação do uso de representação esparsa para estimação de energia em calorímetros operando em cenários de empilhamento de eventos. Em relação aos métodos utilizados para comparação, embora o método DM-COF também tenha sido projetado para ser utilizado em cenários com empilhamento de sinais, seu uso se restringe para os casos em que o sinal de referência está contido dentro da janela de observação e para níveis de empilhamento de sinais não muito altos. Já o método OF tem seu desempenho bastante afetado em condições de empilhamento, como era esperado já que a sua formulação não modela o problema de empilhamento de sinais.

O Capítulo 6 apresentou análises e resultados da aplicação dos métodos esparsos nos calorímetros do ATLAS. Inicialmente, foram utilizados banco de sinais simulados

a partir do sinal de referência do TileCal e do LArg do detector ATLAS no CERN. Em seguida, os métodos esparsos foram avaliados através de simulações Monte Carlo do LArg, simulando condições muito próximas aos do experimento real.

Os resultados obtidos foram consistentes com os resultados encontrados no Capítulo 5. Os métodos baseados em representação esparsa apresentaram-se mais vantajosos para o sinal LArg, já que a janela de observação é menor do que o comprimento do sinal de referência, e em cenários com alto empilhamento de eventos. Em cenários com pouco empilhamento, como era esperado, o método OF possui desempenho satisfatório aliado a baixa complexidade computacional. Também foi possível observar, que para altos níveis de empilhamento, não existe a necessidade da utilização do COF, bastando o método SPARSE apenas para realizar a estimação.

Através dos dados obtidos de simulações Monte Carlo do LArg, além da aplicação dos métodos SPARSE que utilizam programação linear, outros métodos esparsos com menor complexidade computacional foram avaliados. As análises demonstraram que o método esparso LS-OMP obteve desempenho equivalente aos métodos SPARSE, colocando-se como o melhor candidato para implementação *on-line* na ROD do LArg, por causa de sua simplicidade computacional. Ressaltando que só será possível a implementação desse método *on-line*, quando o calorímetro tiver passado pela Fase I de atualização, quando um novo hardware com maior capacidade irá substituir as ROD atuais.

7.1 Trabalhos Futuros

Como trabalhos futuros e desdobramentos desta tese, podemos listar os seguintes itens:

- Avaliar o impacto da estimativa de energia baseada em representação esparsa na reconstrução *offline* das características do objeto físico final, o que para análises físicas de alto nível são extremamente importantes.
- Aprofundar os estudos dos métodos esparsos de menor complexidade computacional comparados a utilização de programação linear, especialmente do método LS-OMP, que apresentou desempenho similar ao SPARSE-COF para as dados provenientes de simulações Monte Carlo do LArg
- Estudar formas de implementação no método LS-OMP em dispositivos lógicos programáveis, visando sua implementação para estimativa de energia *on-line* no LArg.
- Avaliar a possibilidade da utilização de métodos baseados em representação esparsa para estimativa de energia em tempo real no LArg, ou seja, no novo nível

0 de validação, dentro do contexto do programa de atualização do ATLAS.

Referências Bibliográficas

- [1] THE CERN COLLABORATION. “CERN - the European Organization for Nuclear Research”. Website: <http://public.web.cern.ch/public/>, Janeiro 2012.
- [2] THE ATLAS COLLABORATION. “The ATLAS Experiment”. Website: <http://atlas.ch/>, Janeiro 2012.
- [3] THE ATLAS COLLABORATION. “ATLAS Collaboration”. Website: <http://atlas.web.cern.ch/Atlas/Collaboration/>, Janeiro 2012.
- [4] THE ATLAS LEVEL-1 TRIGGER GROUP. *ATLAS Level-1 Trigger - Technical Design Report*. Relatório Técnico ATLAS TDR-12, CERN, 1998.
- [5] THE ATLAS COLLABORATION. *Liquid Argon Calorimeter Technical Design Report*. Relatório Técnico CERN/LHCC 96-41, CERN, 1996.
- [6] THE LHC COLLABORATION. “HiLumi - HL-LHC Project”. Website: <http://hilumilhc.web.cern.ch/about/hl-lhc-project>, Fevereiro 2017.
- [7] PERALVA, B. S. M., FILHO, L. M. A., CERQUEIRA, A. S., et al. *The Tile-Cal Energy Reconstruction for Collision Data Using the Matched Filter*. Relatório Técnico ATL-TILECAL-PROC-2013-023, CERN, Geneva, Nov 2013.
- [8] CALDWELL, A., ET AL. “Design and Implementation of a High Precision Readout System for the ZEUS Calorimeter”, *Nuclear Instruments and Methods in Physics Research A*, v. 321, n. 1-2, pp. 356–364, 1992.
- [9] DE JONG, P. J. *The Measurement of the Hadronic Energy Flow and Jet Production with the ZEUS Calorimeter in Deep Inelastic Scattering Events at HERA*. Tese de Doutorado, Amsterdam University, 1993.
- [10] TORRES, J. P. *Energy Reconstruction in the Hadronic Tile Calorimeter and Early SUSY Fully Hadronic Searches in ATLAS*. Tese de Doutorado, CSIC - Universitat de València, 2009.

- [11] EVANS, L. R., BRYANT, P. “LHC Machine”, *J. Instrum.*, v. 3, pp. S08001. 164 p, 2008. This report is an abridged version of the LHC Design Report (CERN-2004-003).
- [12] THE LHC COLLABORATION. “Informações Gerais e de Diluição”. Website: <http://lhc-machine-outreach.web.cern.ch/lhc-machine-outreach/>, Janeiro 2012.
- [13] THE ATLAS COLLABORATION. “The ATLAS Experiment at the CERN Large Hadron Collider”, *Journal of Instrumentation, JINST* 3 S08003, 2008.
- [14] COLLABORATION, T. A. *ATLAS: technical proposal for a general-purpose pp experiment at the Large Hadron Collider at CERN*. Relatório Técnico 94-43, CERN, 1994.
- [15] CHATRCHYAN, S., OTHERS. “The CMS Experiment at the CERN LHC”, *JINST*, v. 3, pp. S08004, 2008. doi: 10.1088/1748-0221/3/08/S08004.
- [16] COLLABORATION, T. A. “Observation of a new particle in the search for the Standard Model Higgs boson with the ATLAS detector at the LHC”, *Phys. Lett. B*, v. 716, n. arXiv:1207.7214. CERN-PH-EP-2012-218, pp. 1–29. 39 p, Aug 2012. Comments: 24 pages plus author list (38 pages total), 12 figures, 7 tables, revised author list.
- [17] THE ALICE COLLABORATION. “The ALICE experiment at the CERN LHC”, *Journal of Instrumentation, JINST* 3 S08002, 2008.
- [18] THE LHCb COLLABORATION. “The LHCb Detector at the LHC”, *Journal of Instrumentation, JINST* 3 S08005, 2008.
- [19] THE TOTEM COLLABORATION. *TOTEM Technical Design Report*. Relatório Técnico CERN/LHCC 2004-002, CERN, 2004.
- [20] THE LHCf COLLABORATION. *Technical Design Report of the LHCf experiment*. Relatório Técnico CERN/LHCC 2006-004, CERN, 2006.
- [21] DE ANDRADE FILHO, L. M. *Detecção e Reconstrução de Raios Cósmicos usando Calorimetria de Altas Energias*. Tese de Doutorado, Universidade Federal do Rio de Janeiro, 2009.
- [22] ATLAS GROUP. *Inner Detector Technical Design Report*. Relatório, CERN/LHCC/97-16, dezembro 1997.

- [23] ROS, E. “ATLAS Inner Detector”, *Nuclear Physics B*, v. 120, pp. 235 – 238, 2003.
- [24] WIGMANS, R. “Advances in Hadron Calorimetry”, *Annual Review of Nuclear and Particle Science*, v. 41, n. 1, pp. 133–185, 1991. doi: 10.1146/annurev.ns.41.120191.001025.
- [25] ATLAS GROUP. *Muon Spectrometer Technical Design Report*. Relatório 96-22, CERN, dezembro 1997.
- [26] ROS, E. “The Muon Spectrometer of the ATLAS Experiment”, *Nuclear Physics B*, v. 120, pp. 337 – 345, 2003.
- [27] THE ATLAS HLT/DAQ/DCS GROUP. *ATLAS High-Level Trigger, Data Acquisition and Controls*. Relatório Técnico ATLAS TDR-016, CERN, 2001.
- [28] LUNDBERG, J. “Performance of the ATLAS first-level trigger with first LHC data”, pp. 1 –5, may 2010. doi: 10.1109/RTC.2010.5750348.
- [29] ARMSTRONG, S., ANJOS, A., BAINES, J., et al. “Implementation and performance of the high level trigger electron and photon selection for the ATLAS experiment at the LHC”, *Nuclear Science Symposium Conference Record, 2004 IEEE*, v. 4, pp. 2038 – 2042 Vol. 4, oct. 2004. ISSN: 1082-3654.
- [30] ARFAOUI, S. “Performance of the ATLAS liquid argon calorimeter”, *Nuclear Science Symposium Conference Record (NSS/MIC), 2010 IEEE*, pp. 1699 –1702, 30 2010-nov. 6 2010. ISSN: 1095-7863. doi: 10.1109/NSSMIC.2010.5874064.
- [31] HERR, W., MURATORI, B. “Concept of luminosity”, 2006. Disponível em: <<https://cds.cern.ch/record/941318>>.
- [32] THE ATLAS COLLABORATION. *LHC Upgrade Plans: Options and Strategy*. Relatório Técnico CERN-ATS-2011-257, CERN, 2011.
- [33] THE ATLAS COLLABORATION. *ATLAS Letter of Intent Phase-I Upgrade*. Relatório Técnico CERN-LHCC-2011-012, CERN, 2011.
- [34] ERIKSSON, D., MUSCHTER, S., ANDERSON, K., et al. “A prototype for the upgraded readout electronics of TileCal”, *Journal of Instrumentation*, v. 7, 2012.

- [35] THE ATLAS COLLABORATION. *ATLAS Liquid Argon Calorimeter Phase-I Upgrade: Technical Design Report*. Relatório Técnico ATLAS TDR-022, CERN, 2013.
- [36] PEEBLES, P. Z. *Probability, random variables, and random signal principles*. ., McGraw Hill, 2001. ISBN: 9780073660073.
- [37] ABAZOV, V., ET AL. “The Upgraded D0 Detector”, *Nuclear Instruments and Methods in Physics Research A*, v. 565, n. 2, pp. 463–537, 2006.
- [38] TYLMAD, M., ET AL. “Pulse shapes for signal reconstruction in the ATLAS Tile Calorimeter”, *Proc. 16th IEEE-NPSS Real Time Conference RT'09*, pp. 543–547, 2009.
- [39] CLELAND, W., STERN, E. “Signal processing considerations for liquid ionization calorimeters in a high rate environment”, *Nuclear Instruments and Methods in Physics Research Section A: Accelerators, Spectrometers, Detectors and Associated Equipment*, v. 338, n. 2–3, pp. 467 – 497, 1994. ISSN: 0168-9002. doi: [http://dx.doi.org/10.1016/0168-9002\(94\)91332-3](http://dx.doi.org/10.1016/0168-9002(94)91332-3). Disponível em: <<http://www.sciencedirect.com/science/article/pii/0168900294913323>>.
- [40] FULLANA, E., ET AL. “Digital Signal Reconstruction in the ATLAS Hadronic Tile Calorimeter”, *IEEE Transaction On Nuclear Science*, v. 53, n. 4, pp. 2139–2143, 2006.
- [41] PAGANINI, P., VAN VULPEN, I. “Pulse amplitude reconstruction in the CMS ECAL using the weights method”. out. 2004.
- [42] KAY, S. *Fundamentals of Statistical Signal Processing: Estimation Theory*. Pearson, 1993.
- [43] KAY, S. M. *Fundamentals Of Statistical Signal Processing - Estimation Theory*. ., Prentice Hall, 1993. ISBN: 9788131728994.
- [44] THEODORIDIS, S., KOUTROUMBAS, K. *Pattern Recognition, Fourth Edition*. Academic Press, 2008. ISBN: 1597492728, 9781597492720.
- [45] SHANMUGAN, K. S., BREIPOHL, A. *Random Signals - detection, estimation and data analysis*. Wiley, 2001.
- [46] TREES, H. L. V. *Detection, Estimation and Modulation Theory, Part I*. Wiley, 2001.

- [47] BERTUCCIO, G., GATTI, E., SAMPIETRO, M., et al. “Sampling and optimum data processing of detector signals”, *Nuclear Instruments and Methods in Physics Research Section A: Accelerators, Spectrometers, Detectors and Associated Equipment*, v. 322, n. 2, pp. 271 – 279, 1992. ISSN: 0168-9002. doi: [http://dx.doi.org/10.1016/0168-9002\(92\)90040-B](http://dx.doi.org/10.1016/0168-9002(92)90040-B). Disponível em: <<http://www.sciencedirect.com/science/article/pii/016890029290040B>>.
- [48] CERN. “Liquid Argon Calorimeter Public Plots”. set. 2015. Disponível em: <<https://twiki.cern.ch/twiki/bin/view/AtlasPublic/LArCaloPublicResultsDetStatus>>.
- [49] FILHO, L. M. A., CERQUEIRA, A. S., DAMAZIO, D. O. *Calorimeter Signal Response Deconvolution for Online Energy Estimation in Presence of Pile-up*. Relatório Técnico ATL-TILECAL-INT-2012-008, CERN, Geneva, Nov 2012.
- [50] HAYKIN, S. *Neural Networks: A Comprehensive Foundation*. ., Prentice Hall, 1999. ISBN: 9780780334946.
- [51] ELAD, M. *Sparse and Redundant Representations: From Theory to Applications in Signal and Image Processing*. 1st ed. , Springer Publishing Company, Incorporated, 2010. ISBN: 144197010X, 9781441970107.
- [52] LUENBERGER, D., YE. *Linear and Nonlinear Programming*. Springer, 2008. doi: 10.1007/978-0-387-74503-9. Disponível em: <<http://dx.doi.org/10.1007/978-0-387-74503-9>>.
- [53] CANDES, E., TAO, T. “The Dantzig selector: Statistical estimation when p is much larger than n”, *The Annals of Statistics*, v. 35, n. 6, pp. 2313–2351, 12 2007. doi: 10.1214/009053606000001523. Disponível em: <<http://dx.doi.org/10.1214/009053606000001523>>.
- [54] DANTZIG, G. *Linear Programming and Extensions*. Princeton landmarks in mathematics and physics. Princeton University Press, 1963. ISBN: 9780691080000. Disponível em: <<http://books.google.com.br/books?id=iwzvAAAMAAJ>>.
- [55] ZHANG, Y. *Solving Large-Scale Linear Programs by Interior-Point Methods Under the MATLAB Environment*. Relatório técnico, Optimization Methods and Software, 1996.
- [56] MEHROTRA, S. “On the Implementation of a Primal-Dual Inteior Point Method”, *SIAM Jornal on Optimization*, v. 2, pp. 575–601, 1992.

- [57] NEMIROVSKI, A. S., TODD, M. J. “Interior-point methods for optimization”, *Acta Numerica*, v. 17, n. -1, pp. 191–234, 2008. doi: 10.1017/s0962492906370018. Disponível em: <<http://dx.doi.org/10.1017/s0962492906370018>>.
- [58] CHAPMAN, J. “ATLAS Simulation Computing Performance and Pile-Up Simulation in ATLAS”, *LPCC Detector Simulation Workshop-CERN*, 2011.
- [59] BANERJEE, S., ET AL. “CMS Simulation Software”, *Journal of Physics: Conference Series*, v. 396, n. 022003, 2012.
- [60] ROUSSEEUW, P., DRIESSEN, K. “A Fast Algorithm for the Minimum Covariance Determinant Estimator”, *Technometrics*, v. 41, n. 3, pp. 212–223, 1999.
- [61] ALESKA, M., ET AL. *ATLAS Liquid Argon Calorimeter Phase-I Upgrade Technical Design Report*. Cern-lhcc-2013-017, atlas-tdr-022, CERN, <http://cern.ch/lcg/tdr>, 2013.
- [62] CHEKANOV, S. “New approach for jet-shape identification of TeV-scale particles at the LHC”, .
- [63] C.AY, A. BUCKLEY, J. B. J. F. I. H. O. J. J. K. B. K. E. L. J. M. Z. Q. V. S. J. S. “Monte Carlo Generators in ATLAS software”, *17th International Conference on Computing in High Energy and Nuclear Physics (CHEP09)*, 2010.

Apêndice A

Sistema de Coordenadas do ATLAS

O sistema de coordenadas usado em experimentos com feixes não é o sistema polar. Trata-se de sistema adequado ao formato cilíndrico dos detectores dispostos ao redor do ponto de impacto, ou seja, um sistema que acompanha a direção dos feixes de partículas provenientes da colisão. As coordenadas empregadas são η , ϕ e z em contraposição a x , y e z . Os termos η e ϕ seguem a uma transformação não-linear de x e y .

$$\phi = \arctan \frac{x}{y} \quad (\text{A.1})$$

$$\eta = -\log(\tan \frac{\phi}{2}) \quad (\text{A.2})$$

A Figura A.1 pode ser explicativa quanto ao sistema. Em sua parte superior é possível ver um esquema do barril e da tampa de um detector, mostrando como se comportam as coordenadas quando tomamos por referência as coordenadas cartesianas x , y e z (marcadas em pontilhado). Nota-se que a variável ϕ representa a rotação e a variável η (também chamada de pseudo-rapidez) representa a direção de projeção das partículas, após a colisão.

Os valores dados das variáveis η e ϕ são apenas para referência do leitor. A variável ϕ , como é possível ver no canto direito da parte superior da figura, composta uma região em que dois valores são possíveis: 0 e 2π . Esta área é chamada de região *wrap-around*. Cálculos utilizando esta variável devem atentar para este fato.

Os detectores são simétricos, em relação ao eixo ϕ . A construção dos dispositivos é realizada em gomos.

Repara-se que quando alcança o eixo z , $\eta = 1$ indica que objetos com valores grandes em η representam colisões onde as partículas do feixe apenas se desviaram, não havendo, usualmente informações interessantes de análise pois representam cho-

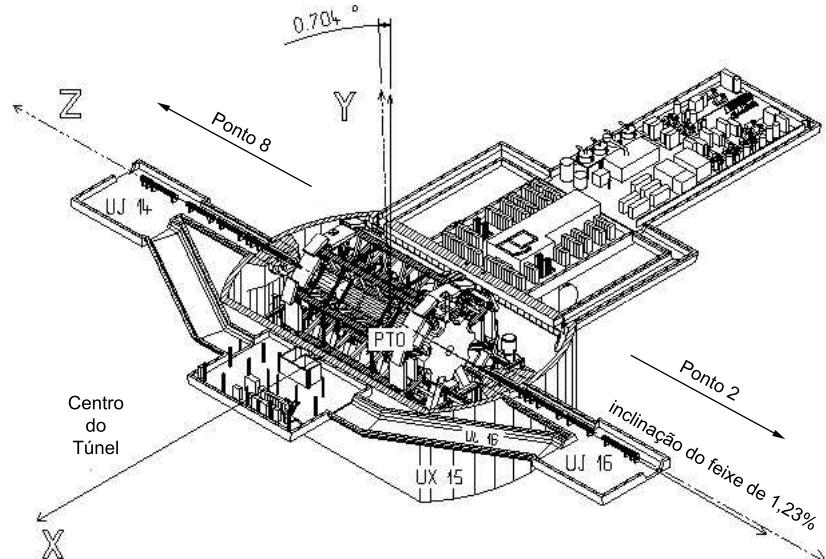


Figura A.1: O sistema de coordenadas do ATLAS.

ques elásticos. É comum utilizar-se detectores com baixa resolução quando $\eta > 3$.

Na parte inferior da Figura B.1, é possível vizualizar um exemplo de como um detector genérico é segmentado, acompanhando as coordenadas η e ϕ , tanto para o barril, quanto para uma tampa.